INFORME ACADÉMICO – FASE 1 (HASTA EL CAPÍTULO II)

UNIVERSIDAD NACIONAL FEDERICO VILLARREAL

FACULTAD DE INGENIERÍA ELECTRÓNICA E INFORMÁTICA

ESCUELA PROFESIONAL DE INGENIERÍA INFORMÁTICA / ELECTRÓNICA

PROYECTO INTEGRADOR AVANZADO

SISTEMA INTELIGENTE DE EVALUACIÓN ADAPTATIVA Y PERSONALIZACIÓN DEL APRENDIZAJE UNIVERSITARIO

Subtítulo: Plataforma Integral de Business Intelligence y Machine Learning basada en DataMart Multidimensional, Pipelines SSIS, Cubos OLAP y Modelos Predictivos para la Gestión de Retención Académica en UNFV-FIEI

- **Curso:** Gestión y Análisis de Datos e Información
- **Docente:** Mg. Ing. Ivan Crispin Sanchez
- **Ciclo Académico:** 2026

ÍNDICE GENERAL

1. [Introducción](#introducción)
- 1.1. Presentación del proyecto
- 1.2. Problema identificado
- 1.3. Importancia de la solución
- 1.4. Alcance general

2. [Capítulo I: Generalidades](#capítulo-i-generalidades)
- 2.1. Descripción de la empresa u organización
- 2.2. Historia, misión, visión y valores
- 2.3. Organización y organigrama
- 2.4. Área involucrada
- 2.5. Descripción del proceso actual
- 2.6. Diagrama AS-IS (Proceso Actual)
- 2.7. Propuesta TO-BE (Proceso Futuro Optimizado)

3. [Capítulo II: Proyecto o Tarea Académica (Marco Teórico y Fundamentación)](#capítulo-ii-proyecto-o-tarea-académica)
• 3.1. Inteligencia de Negocios (Business Intelligence)
• 3.2. Data Warehouse y DataMart (Metodología Kimball)
• 3.3. Modelos Dimensionales (Esquema Estrella)
• 3.4. Datos, Información y Conocimiento (Pirámide DIKW)
• 3.5. Dimensiones, Medidas, Jerarquías y Granularidad
• 3.6. Cubos OLAP y Procesamiento Multidimensional (SSAS)
• 3.7. Indicadores de Gestión y KPIs
• 3.8. Machine Learning e Inteligencia Artificial en Educación (*Educational Data Mining*)
4. [Referencias Bibliográficas (Normas APA 7ma Edición)](#referencias-bibliográficas)

INTRODUCCIÓN

1.1. Presentación del proyecto

En el escenario contemporáneo de la educación superior universitaria peruana, las instituciones enfrentan un desafío estructural determinante que compromete su sostenibilidad institucional, calidad educativa y responsabilidad social: la deserción estudiantil temprana y el rezago curricular no supervisado. El presente proyecto integrador diseña e implementa una **plataforma inteligente de Business Intelligence y Machine Learning**, concebida específicamente para superar el paradigma tradicional de reportes retrospectivos estáticos y hojas de cálculo desconectadas.

La arquitectura de la solución se estructura siguiendo estrictamente el flujo secuencial de siete etapas establecido por la cátedra de Gestión y Análisis de Datos e Información:

1. **Fuentes Transaccionales y Externas:** Integración del dataset académico granular de trayectoria estudiantil (UCI Machine Learning, 4,424 observaciones $\times$ 37 atributos), el catálogo universitario nacional (TUNI/SUNEDU) y los microdatos sociolaborales oficiales (ENAHO/INEI 2023, Módulos 300 y 500).
2. **Proceso de Extracción, Transformación y Carga (ETL):** Implementado mediante **Visual Studio SQL Server Integration Services (SSIS)**, garantizando áreas de preparación (*Staging*), normalización de calificaciones a la escala vigesimal peruana ($0\text{ a }20$) y controles rigurosos de calidad de datos.
3. **DataMart Relacional Dimensional:** Diseñado bajo metodología Ralph Kimball en **Microsoft SQL Server**, estructurando esquemas estrella con granularidad atómica por estudiante y etapa de evaluación.

4. **Procesamiento Analítico Multidimensional (OLAP):** Construido en **SQL Server Analysis Services (SSAS)** para habilitar operaciones analíticas multidimensionales (*Drill-down*, *Roll-up*, *Slice & Dice*) y cálculo de KPIs de gestión.
5. **Módulo Predictivo de Inteligencia Artificial:** Desarrollado en **Python (Scikit-Learn)**, ejecutando la comparación formal de algoritmos supervisados (**Regresión Logística vs. Random Forest**) en dos hitos temporales y segmentación no supervisada (**Clustering K-Means**) para perfiles estudiantiles.
6. **Integración BI + IA y Cuadros de Mando Ejecutivos:** Almacenamiento de probabilidades predichas en la base analítica y visualización interactiva en **Power BI Desktop**, incorporando un semáforo de riesgo y un simulador prescriptivo de escenarios (*What-If*).
7. **Toma de Decisiones Institucionales:** Entrega de información procesable y recomendaciones prescriptivas al Director de Escuela Profesional, Comité de Tutoría y Bienestar Universitario de la FIEI-UNFV.

Para asegurar la coherencia epistemológica del proyecto frente a su denominación oficial, se establecen las siguientes definiciones operativas:

- **Evaluación Adaptativa:** Proceso dinámico de re-evaluación del riesgo académico ejecutado en etapas sucesivas (M_1: Al ingreso vs. M_2: Al cierre del primer semestre), permitiendo que el sistema adapte su nivel de alerta conforme el estudiante genera evidencia real de rendimiento universitario.
- **Personalización del Aprendizaje:** Segmentación de la población estudiantil en perfiles socioacadémicos homogéneos mediante *Clustering*, articulada con una matriz de intervención tutorial que asigna planes pedagógicos diferenciados según el tipo y nivel de vulnerabilidad.

1.2. Problema identificado

La gestión académica tradicional en las universidades públicas adolece de un modelo de seguimiento netamente **reactivo y "post-mortem"**. Las señales de fracaso y abandono estudiantil son advertidas por las autoridades facultativas de manera tardía: comúnmente al consolidarse las actas oficiales de notas tras los exámenes parciales (semanas 8 a 10) o al concluir el semestre académico (semana 16). En este punto crítico, las posibilidades pedagógicas y administrativas de recuperación o nivelación son prácticamente nulas, consolidando la desaprobación masiva y el abandono.

En el sistema universitario peruano, esta problemática presenta una severa raíz socioeconómica y laboral. El análisis de microdatos de la Encuesta Nacional de Hogares (INEI ENAHO 2023, Módulos 300 y 500) revela que:

- El **44.0% de los estudiantes universitarios peruanos se encuentra trabajando activamente** durante sus estudios de pregrado.
- La jornada laboral promedio entre los estudiantes trabajadores alcanza **34.7 horas semanales**, configurando un régimen de sobrecarga horaria incompatible con la alta demanda de créditos académicos.
- En el ámbito nacional, la Superintendencia Nacional de Educación Superior Universitaria (SUNEDU) reporta que la deserción interanual en el primer año formativo oscila entre el **18% y el 27%**, afectando con mayor severidad a las carreras de ciencias básicas e ingeniería.
- En el contexto específico de la UNFV, investigaciones empíricas recientes realizadas por docentes de la institución (Aparicio-Montenegro et al., 2026) confirman que más del 70% de los casos de desvinculación definitiva en la universidad se incuban durante los dos primeros semestres por desaprobación acumulada en cursos troncales.
- Como referencia empírica benchmark, el dataset internacional de estudio (Realinho et al., 2022) refleja una tasa de abandono histórico acumulado del **32.1%** frente a un **17.9%** de matrícula rezagada persistente, demostrando que la falta de intervención temprana condena a casi la mitad de los estudiantes vulnerables al fracaso académico.

[Diagrama / Especificación de Proceso BPMN 2.0]

```
flowchart TD
    subgraph CAUSAS["CAUSAS RAÍZ DEL PROBLEMA"]
        C1["Seguimiento académico reactivo y tardío<br>(Reportes en semanas 8 a 16)"]
        C2["Silos de información desarticulados<br>(Notas en Excel, falta de perfil
socioeconómico)"]
        C3["Sobrecarga horaria laboral oculta<br>(44% trabaja, 34.7 h/semana
promedio)"]
        C4["Intervención tutorial uniforme y genérica<br>(Sin segmentación de
necesidades)"]
    end

    subgraph PROBLEMA["PROBLEMA CENTRAL DE GESTIÓN"]
        P["INEFICIENCIA EN LA DETECCIÓN TEMPRANA DEL RIESGO Y FALTA DE PERSONALIZACIÓN
DE INTERVENCIONES PARA LA RETENCIÓN ESTUDIANTIL EN LA FIEI-UNFV"]
    end

    subgraph EFECTOS["EFECTOS E IMPACTOS"]
        E1["Alta tasa de desaprobación en primer ciclo<br>(Cursos troncales y ciencias
básicas)"]
        E2["Pérdida de gratuidad y sanción reglamentaria<br>(Matrícula condicionada por
bajo rendimiento)"]
... [Diagrama completo documentado: 27 líneas]
```

1.3. Importancia de la solución

La implementación de esta plataforma inteligente aporta un valor estratégico multidimensional a la gestión académica, alineando las capacidades analíticas con las necesidades operativas de cada actor del proceso:

Tabla 1

Matriz de datos y especificación analítica 1

Actor Beneficiario	Necesidad Crítica Resuelta	Beneficio Concreto Entregado	Componente Tecnológico Responsable
Director de Escuela Profesional	Carencia de visión agregada de retención y rendimiento curricular por cohorte.	Tableros ejecutivos con KPIs consolidados por escuela para optimizar la oferta curricular y la asignación docente.	DataMart en SQL Server + Cubo SSAS + Power BI
Comité de Tutoría y Consejería	Detección tardía de estudiantes reprobatorios y saturación tutorial.	Semáforo de riesgo predictivo antes de la semana 5 que prioriza a los estudiantes en riesgo crítico ($P \ge 60\%$).	Modelos Supervisados de IA (Python) + `FactPrediccion`
Docente Tutor / Consejero	Desconocimiento del perfil específico y motivos de rezago del alumno.	Ficha individual del estudiante con perfil socioacadémico y recomendación prescriptiva adaptada a su vulnerabilidad.	Clustering K-Means + Matriz de Recomendación
Oficina de Bienestar Universitario	Asignación asistencial desarticulada del rendimiento real.	Identificación cruzada de estudiantes en riesgo académico con sobrecarga laboral o precariedad económica para otorgar becas comedor.	Contexto ENAHO integrado + Dashboard de Bienestar
Estudiante Universitario	Acompañamiento pedagógico tardío e intervenciones impersonales.	Alerta y nivelación académica preventiva antes de caer en causal de matrícula condicionada o deserción.	Plan de Intervención Personalizado

Nota. Fuente: Elaboración propia basada en el diseño institucional y analítico del proyecto.

1.4. Alcance general y delimitación técnica

1.4.1. Objetivo General

Diseñar e implementar una plataforma inteligente de Business Intelligence y Machine Learning basada en arquitectura de DataMart relacional, pipelines de integración SSIS, cubos

analíticos SSAS y cuadros de mando interactivos en Power BI, orientada a la evaluación adaptativa del riesgo académico y la personalización de intervenciones para la retención estudiantil en la FIEI-UNFV.

1.4.2. Objetivos Específicos

1. Modelar los procesos académicos AS-IS y TO-BE de la FIEI-UNFV, diagnosticando los puntos de latencia informacional y formalizando el catálogo de preguntas de negocio y KPIs institucionales.
2. Diseñar e implementar el DataMart dimensional en SQL Server bajo esquema estrella (metodología Ralph Kimball), estructurando tablas de hechos y dimensiones conformadas con niveles rigurosos de granularidad.
3. Construir el pipeline ETL automatizado mediante Visual Studio SQL Server Integration Services (SSIS), asegurando áreas de *staging*, transformación de datos, normalización vigesimal ($0\text{ a }20$) y auditoría de carga.
4. Desarrollar y evaluar comparativamente los modelos de Machine Learning en Python (Regresión Logística vs. Random Forest) en dos momentos temporales y segmentar perfiles estudiantiles mediante Clustering K-Means.
5. Implementar el Cubo OLAP multidimensional en SSAS y desarrollar el Dashboard inteligente en Power BI Desktop, integrando el semáforo predictivo y un simulador de escenarios *What-If*.

1.4.3. Matriz de Alcance Positivo y Negativo

- **Lo que el proyecto SÍ incluye:** Procesamiento y limpieza de 4,424 registros granulares, modelado dimensional en SQL Server, ETL en Visual Studio SSIS, cubo OLAP en SSAS, modelado predictivo supervisado en dos etapas (M_1 y M_2), validación *out-of-fold* para toda la población en Power BI, y simulación de escenarios What-If.
- **Lo que el proyecto NO incluye (Límites declarados):** No incluye desarrollo de sistemas web full-stack ni apps móviles; no implementa tests adaptativos computarizados a nivel de reactivo (CAT/TRI); y no realiza cruces nominativos ficticios entre estudiantes de UCI y encuestados de ENAHO/TUNI, preservando la trazabilidad y la legalidad de los datos.

CAPÍTULO I: GENERALIDADES

2.1. Descripción de la empresa u organización

El marco organizacional del presente proyecto es la **Universidad Nacional Federico Villarreal (UNFV)**, institución pública de educación superior universitaria del Perú, focalizando su implementación y caso de negocio en la **Facultad de Ingeniería Electrónica e Informática (FIEI)**.

La UNFV cuenta con **Licenciamiento Institucional otorgado por la SUNEDU** mediante la **Resolución del Consejo Directivo N° 035-2019-SUNEDU/CD** (emitida el 11 de marzo de 2019), la cual acreditó el cumplimiento de las Condiciones Básicas de Calidad (CBC) exigidas por la Ley Universitaria N° 30220.

La FIEI concentra la formación tecnológica y científica de vanguardia de la universidad, albergando cuatro escuelas profesionales:

1. **Escuela Profesional de Ingeniería Informática:** Especializada en ingeniería de software, analítica de datos, sistemas de información y seguridad informática.
2. **Escuela Profesional de Ingeniería Electrónica:** Centrada en sistemas electrónicos, instrumentación y procesamiento digital de señales.
3. **Escuela Profesional de Ingeniería Mecatrónica:** Orientada al control automático, robótica industrial y sistemas ciberfísicos.
4. **Escuela Profesional de Ingeniería de Telecomunicaciones:** Focalizada en redes convergentes, sistemas de transmisión y radiocomunicaciones.

Tabla 2

Matriz de datos y especificación analítica 2

Atributo	Detalle Oficial Institucional
Denominación Oficial	Universidad Nacional Federico Villarreal (UNFV)
Dependencia Piloto	Facultad de Ingeniería Electrónica e Informática (FIEI)
Ubicación de la FIEI	Jr. Iquique N° 127, Breña, Lima, Perú
Tipo de Gestión	Universidad Pública del Estado Peruano
Estado de Licenciamiento	Licenciada (Resolución del Consejo Directivo N° 035-2019-SUNEDU/CD)
Población Académica FIEI	~2,200 estudiantes de pregrado matriculados en sus cuatro escuelas
Régimen de Evaluación	Semestral (16 semanas por ciclo académico) con escala vigesimal ($0\text{ a }20$)

Nota. Fuente: Elaboración propia basada en el diseño institucional y analítico del proyecto.

2.2. Historia, misión, visión y valores

2.2.1. Reseña Histórica Oficial

La Universidad Nacional Federico Villarreal fue creada mediante la **Ley N° 14692**, promulgada el **30 de octubre de 1963**, a partir de la filial en Lima de la Universidad Comunal del Centro del Perú. Nombrada en honor al insigne matemático, físico e ingeniero peruano Federico Villarreal, la institución ha cumplido más de seis décadas formando profesionales e investigadores. La FIEI fue constituida como unidad académica autónoma para liderar la investigación y la transferencia tecnológica en tecnologías de la información, electrónica y computación.

2.2.2. Misión Institucional (Estatuto y PEI UNFV Vigente)

> *"Formar profesionales e investigadores competitivos, con sólidos valores éticos, humanísticos, científicos y tecnológicos, comprometidos con el desarrollo sostenible del país."*

2.2.3. Visión Institucional (Estatuto y PEI UNFV Vigente)

> *"Ser una universidad pública licenciada y acreditada internacionalmente, líder en la formación integral de excelencia e investigación innovadora de alto impacto social."*

2.2.4. Valores Institucionales

- **Ética e Integridad:** Actuación basada en la honestidad académica y veracidad científica.
- **Rigor Científico y Excelencia:** Compromiso con la exactitud metodológica y la calidad técnica.
- **Responsabilidad Social:** Búsqueda permanente de la equidad y apoyo a los sectores estudiantiles vulnerables.
- **Transparencia:** Gestión sustentada en datos abiertos y rendición de cuentas orientada a resultados.

2.2.5. Alineamiento Estratégico del Proyecto con la Misión y Visión

Tabla 3

Matriz de datos y especificación analítica 3

Elemento Estratégico UNFV	Compromiso Institucional Declarado	Cómo lo Cumple y Apoya este Proyecto de BI + IA
Misión: "Formar profesionales competitivos..."	Asegurar que los estudiantes culminen con éxito sus planes curriculares.	El sistema previene el rezago curricular y el abandono en cursos troncales, asegurando la continuidad del proceso

Elemento Estratégico UNFV	Compromiso Institucional Declarado	Cómo lo Cumple y Apoya este Proyecto de BI + IA
		formativo.
Visión: "Formación de excelencia e investigación..."	Acreditación y cumplimiento continuo de estándares de permanencia.	Entrega indicadores objetivos de retención para sustentar auditorías de calidad educativa y acreditación de las escuelas de la FIEI.
Valores: "Responsabilidad Social y Equidad..."	Evitar que factores económicos y laborales trunquen la vocación universitaria.	Articula el perfil laboral del estudiante con recomendaciones tutoriales y focalización de becas de Bienestar Universitario.

Nota. Fuente: Elaboración propia basada en el diseño institucional y analítico del proyecto.

2.3. Organización y organigrama

La estructura jerárquica de la UNFV y la articulación de las dependencias que participan en la gestión del rendimiento estudiantil se formaliza a continuación:

[Diagrama / Especificación de Proceso BPMN 2.0]

```
graph TD
    Rectorado["Rectorado de la UNFV"]
    VRAC["Vicerrectorado Académico (VRAC)"]
    Decanato["Decanato de la FIEI"]
    DirEscuelas["Direcciones de Escuela Profesional<br>(Informática / Electrónica /
Mecatrónica / Telecomunicaciones)"]
    ComTutor["Comité de Tutoría y Consejería Universitaria (FIEI)"]
    Bienestar["Oficina de Bienestar Universitario"]
    Docentes["Docentes Tutores y Docentes de Asignatura"]
    Estudiantes["Población Estudiantil FIEI"]

    Rectorado --> VRAC
    VRAC --> Decanato
    VRAC --> Bienestar
    Decanato --> DirEscuelas
    Decanato --> ComTutor
... [Diagrama completo documentado: 19 líneas]
```

2.4. Área involucrada y matriz de responsabilidades (RACI)

El proceso de seguimiento y retención involucra a dependencias de carácter académico, tutorial y asistencial bajo el mandato de los artículos 126 y 128 de la **Ley Universitaria N° 30220**, que establecen la obligatoriedad de la tutoría universitaria y los servicios de bienestar:

Tabla 4

Matriz de datos y especificación analítica 4

Actividad / Proceso Analítico	Director de Escuela	Comité de Tutoría	Docente Tutor	Bienestar Univ.	Plataforma BI+IA
Consolidación de datos de matrícula y notas (ETL)	**I**	**I**	**I**	**I**	**R / A**
Emisión y monitoreo del semáforo de riesgo predictivo	**A**	**R**	**C**	**I**	**R**
Asignación de estudiantes críticos a tutores	**A**	**R**	**I**	**C**	**Soporte**
Ejecución de sesiones tutoriales y nivelación académica	**I**	**A**	**R**	**C**	**Soporte**
Asignación de becas y asistencias socioeconómicas	**I**	**C**	**C**	**R / A**	**Soporte**
Evaluación global de KPIs y simulación What-If	**R / A**	**C**	**I**	**I**	**Soporte**

Nota. Fuente: Elaboración propia basada en el diseño institucional y analítico del proyecto.

Leyenda RACI: R = Responsable de ejecución, A = Aprobador final / Dueño, C = Consultado, I = Informado.

2.5. Descripción del proceso actual (AS-IS)

En el régimen operativo actual, el seguimiento académico del estudiante en la FIEI-UNFV se realiza de forma **desarticulada, manual y reactiva**. El ciclo académico comprende 16 semanas lectivas, estructurándose de la siguiente forma:

Tabla 5

Matriz de datos y especificación analítica 5

N°	Actividad	Actor Principal	Insumo	Salida	Semana / Momento	Problema / Cuello de Botella Detectado
1	Matrícula regular	Estudiante	Ficha de matrícula	Padrón de inscritos	Semana 0	Solo registra asignaturas matriculadas; no captura situación laboral ni horas de trabajo del alumno.
2	Desarrollo de clases y prácticas	Docente	Registro auxiliar	Calificaciones en Excel	Semanas 1 a 7	Las notas de prácticas se quedan en computadoras personales de los profesores; no suben al sistema central.
3	Exámenes parciales	Docente / Alumno	Examen físico	Actas preliminares	Semana 8	Primer punto formal de evaluación; el alumno ya acumula 2 meses de rezago sin que nadie lo advierta.
4	Carga oficial de notas parciales	Docente	Intranet docente	Acta consolidada en BD	Semanas 9 a 10	**Latencia informacional severa:** Frecuentes demoras de los docentes en digitar notas a

N°	Actividad	Actor Principal	Insumo	Salida	Semana / Momento	Problema / Cuello de Botella Detectado
						la intranet.
5	Identificación de casos críticos	Comité Tutoría	Reporte manual intranet	Lista en papel/hoja Excel	Semanas 10 a 11	El comité revisa manualmente promedios < 10.5; labor lenta y sin criterios de priorización predictiva.
6	Citación a tutoría correctiva	Docente Tutor	Lista de citados	Sesión de asesoría	Semanas 11 a 12	**Acción tardía:** El alumno es citado cuando ya desaprobó con notas irrecuperables (05 a 08).
7	Examen final y cierre de actas	Docente	Sistema de actas	Condición final aprobada	Semanas 16 a 17	Se constata el fracaso académico; el estudiante repite o cae en causal de matrícula condicionada (Ley 30220).

Nota. Fuente: Elaboración propia basada en el diseño institucional y analítico del proyecto.

2.6. Diagrama AS-IS (Proceso Actual)

2.6.1. Diagrama de Flujo Visual (Flujo con Carriles y Puntos de Dolor)

[Diagrama / Especificación de Proceso BPMN 2.0]

```
flowchart TD
    subgraph ESTUDIANTE["Carril 1: Estudiante"]
        E_Inicio([Inicio de Semestre]) --> E_Matr[1. Realiza matrícula en asignaturas]
        E_Matr --> E_Clases[2. Asiste a clases y rinde prácticas]
        E_Clases --> E_Parcial[3. Rinde Examen Parcial - Sem. 8]
```

```
        E_Parcial --> E_Espera[4. Continúa cursando asignaturas]
        E_Espera --> E_Tarde[6. Citado tardíamente a tutoría - Sem. 11/12]
        E_Tarde --> E_Final[7. Rinde Examen Final - Sem. 16]
        E_Final --> E_Fin([Fin de Semestre: Rezago o Deserción])
    end

    subgraph DOCENTE["Carril 2: Docente de Asignatura"]
        D_RegAux[2.1 Registra notas parciales en Excel local] -.-> D_Dolor1["⚠ DOLOR
1: Silos de notas desconectadas"]
        D_Parcial[3.1 Califica examen parcial] --> D_Carga[4.1 Sube notas a Intranet -
Sem. 9/10]
        D_Carga -.-> D_Dolor2["⚠ DOLOR 2: Latencia de 9 semanas para publicar datos"]
... [Diagrama completo documentado: 33 líneas]
```

2.6.2. Guía Técnica Paso a Paso para Modelado en Bizagi Modeler (AS-IS)

Para construir el diagrama oficial BPMN 2.0 en Bizagi Modeler y exportarlo al informe final:

1. **Crear Pool Principal:** Nombrar el proceso como `"Proceso AS-IS: Seguimiento Académico Tradicional en FIEI-UNFV"`.

2. Crear 3 Lanes (Carriles de Nado):

• *Lane 1:* `Estudiante`

• *Lane 2:* `Docente de Asignatura`

• *Lane 3:* `Comité de Tutoría y Consejería`

3. Insertar Elementos BPMN en cada Lane:

• En Lane Estudiante:

• Evento de Inicio (Círculo verde fino): `"Inicio del Semestre Académico"`.

• Tarea de Usuario (👤): `"Realizar Matrícula Regular"`.

• Tarea de Usuario (👤): `"Asistir a Clases y Rendir Evaluaciones"`.

• Tarea de Usuario (👤): `"Rendir Examen Parcial (Semana 8)"`.

• Tarea de Usuario (👤): `"Rendir Examen Final (Semana 16)"`.

• Evento de Fin (Círculo rojo grueso): `"Deserción o Repitencia Consumada"`.

• En Lane Docente de Asignatura:

• Tarea Manual (✍): `"Calificar Prácticas en Registro Auxiliar Excel"`.

• Objeto de Datos (Documento con esquina doblada): `"Archivo Excel Aislado"`.

• Tarea de Usuario (👤): `"Digitar Calificaciones en Intranet (Semanas 9-10)"`.

• En Lane Comité de Tutoría:

• Tarea de Usuario (👤): `"Revisar Manualmente Actas en Intranet"`.

• Compuerta Exclusiva ($\times$): `"¿Promedio < 10.5?"`.

• Rama No: Flujo de secuencia hacia fin normal del semestre.

- Rama Sí: Tarea de Usuario "Citar a Estudiante a Tutoría Correctiva (Semana 11-12)".

4. Insertar Anotaciones de Texto (Puntos de Dolor en Bizagi):

- *Anotación 1 (vinculada a Registro Excel):* "[DOLOR 1] Información aislada sin integración central".
- *Anotación 2 (vinculada a Digitar Notas):* "[DOLOR 2] Latencia de 9 semanas en consolidación de datos".
- *Anotación 3 (vinculada a Revisar Actas):* "[DOLOR 3] Detección tardía (post-mortem)".
- *Anotación 4 (vinculada a Citar Estudiante):* "[DOLOR 4] Intervención sin diagnóstico de causas de fondo".

2.7. Propuesta TO-BE (Proceso Futuro Optimizado)

2.7.1. Diagrama de Flujo Visual (Flujo BPMN con Carriles y Mejoras Estratégicas)

[Diagrama / Especificación de Proceso BPMN 2.0]

```
flowchart TD
    subgraph LANE_EST["Carril 1: Estudiante"]
        E2_Ini([Inicio de Semestre - Sem. 0]) --> E2_Matr[1. Matrícula y Ficha de
Contexto Digital]
        E2_Matr --> E2_Clases[2. Asiste a clases regulares]
        E2_Clases --> E2_Plan[4. Participa en Plan de Tutoría / Nivelación Asignado]
        E2_Plan --> E2_Exito([Fin de Semestre: Retención y Aprobación Exitosa])
    end

    subgraph LANE_DOC["Carril 2: Docente de Asignatura"]
        D2_Notas[2.1 Registra notas continuas en sistema institucional]
    end

    subgraph LANE_SIST["Carril 3: Plataforma Automatizada BI + IA (SSIS / Python /
SSAS)"]
        S2_ETL[3.1 Ejecuta Pipeline ETL en SSIS] --> S2_M1[3.2 Predicción Temprana M1
al Ingreso - Sem. 2]
        S2_M1 -.-> S2_Gain1["✅ MEJORA 1: Alerta en Sem. 2 (7 semanas antes)"]
... [Diagrama completo documentado: 41 líneas]
```

2.7.2. Guía Técnica Paso a Paso para Modelado en Bizagi Modeler (TO-BE)

1. **Crear Pool Principal:** "Proceso TO-BE: Sistema Inteligente de Evaluación Adaptativa y Personalización Académica".

2. Crear 4 Lanes en Bizagi:

- *Lane 1:* Estudiante
- *Lane 2:* Docente de Asignatura
- *Lane 3:* Plataforma Automatizada BI + IA (SSIS / SQL Server / Python / Power BI)
- *Lane 4:* Comité de Tutoría y Bienestar Universitario

3. Insertar Elementos BPMN en cada Lane:

- **Lane Estudiante:**

• Evento de Inicio: "Inicio de Ciclo Académico (Semana 0)".

• Tarea de Usuario (👤): "Completar Matrícula y Ficha de Contexto Digital".

• Tarea de Usuario (👤): "Cursar Asignaturas con Soporte Continuo".

• Tarea de Usuario (👤): "Participar en Plan de Nivelación / Tutoría Asignada".

• Evento de Fin: "Retención Exitosa y Continuidad Curricular".

• Lane Docente de Asignatura:

• Tarea de Usuario (👤): "Registrar Calificaciones Continuas en Sistema Centralizado".

• Lane Plataforma Automatizada BI + IA:

• Tarea de Servicio (⚙): "Ejecutar Pipeline ETL Automatizado (Visual Studio SSIS)".

• Tarea de Servicio (⚙): "Calcular Probabilidad de Abandono (Momento 1: Ingreso - Python ML)".

• Tarea de Servicio (⚙): "Segmentar Estudiantes en Perfiles Socioacadémicos (K-Means)".

• Tarea de Servicio (⚙): "Re-evaluar Riesgo Adaptativamente (Momento 2: Cierre S1 - Python ML)".

• Tarea de Servicio (⚙): "Poblar dw.FactPrediccion y Actualizar Cubo SSAS"

• Tarea de Envío / Servicio (⚙): "Publicar Dashboard Power BI y Emitir Alertas Tempranas".

• Lane Comité de Tutoría y Bienestar Universitario:

• Tarea de Usuario (👤): "Monitorear Semáforo Predictivo y Simular Escenarios What-If en Power BI".

• Compuerta Exclusiva ($\times$): "¿Riesgo Crítico (P >= 60%)?".

• Tarea de Regla de Negocio (📋): "Prescribir Intervención Personalizada según Matriz de Recomendación".

• Tarea de Usuario (👤): "Asignar y Ejecutar Tutoría / Ayuda Socioeconómica con el Estudiante".

4. Insertar Anotaciones de Mejora en Bizagi:

• *Anotación M1:* "[MEJORA 1] Detección temprana en semana 2 sin esperar al examen parcial".

• *Anotación M2:* "[MEJORA 2] Evaluación adaptativa por hitos cronológicos (M1 y M2)".

• *Anotación M3:* "[MEJORA 3] Intervención prescrita a la medida del perfil (Clustering)".

- *Anotación M4:* `"[MEJORA 4] Simulador What-If para dimensionar la capacidad tutorial"`.

2.8. Matriz Comparativa Exhaustiva: Proceso AS-IS vs. Proceso TO-BE

Tabla 6

Matriz de datos y especificación analítica 6

Dimensión de Análisis	Situación Actual (AS-IS)	Situación Propuesta (TO-BE)	Componente Tecnológico Responsable	KPI Asociado de Impacto
Tiempo de Detección (Latencia)	**Semana 9 a 11:** Tras digitar exámenes parciales. Detección reactiva ("post-mortem").	**Semana 2 a 4 (M_1):** Diagnóstico preliminar al ingreso y re-evaluación adaptativa en M_2.	Pipelines SSIS + Modelo Predictivo en Python	Tiempo de respuesta ≤ 4 semanas; Recall $\ge 75\%$.
Integración de Fuentes de Datos	Hojas de cálculo Excel aisladas en PCs de docentes; intranet desarticulada.	**DataMart Centralizado en SQL Server:** Ingesta de datos de trayectoria, catálogo y contexto ENAHO.	Pipeline ETL en Visual Studio SSIS	100% de fuentes integradas; 0 duplicados en DataMart.
Criterio de Identificación del Riesgo	Promedio aritmético simple post examen (< 10.5) sin análisis predictivo multivariable.	**Modelo Multivariable de Machine Learning (Random Forest):** Cálculo de probabilidad continua de abandono.	Algoritmos Supervisados (`FactPrediccion`)	F_1-Macro ≥ 0.65; ROC-AUC ≥ 0.85.
Enfoque de la Evaluación	Estática y finalista; sin seguimiento temporal de la evolución del riesgo.	**Evaluación Adaptativa Dinámica:** Re-evaluación del riesgo en dos hitos (M_1 Ingreso vs. M_2 Cierre S1).	`dw.DimEtapa` en DataMart + Cubo SSAS	Variación del riesgo entre etapas (ΔP).
Estrategia de Intervención	Genérica y uniforme para todos los reprobados (sanción o	**Personalización por Perfiles:** Prescripción diferenciada según	Clustering K-Means + Matriz de Recomendación	Índice Silhouette ≥ 0.35; Cobertura de tutoría.

Dimensión de Análisis	Situación Actual (AS-IS)	Situación Propuesta (TO-BE)	Componente Tecnológico Responsable	KPI Asociado de Impacto
	aviso estándar).	clúster socioacadémico identificado.		
Herramienta de Consumo	Actas impresas en papel y listados planos en Excel no interactivos.	**Dashboard Inteligente en Power BI Desktop:** Semáforo predictivo interactivo y simulador What-If.	Power BI Desktop	100% de actores consultando información en tiempo real.
Planificación Institucional	Empírica; sin capacidad de proyectar el impacto de las políticas de tutoría.	**Simulación Interactiva What-If:** Análisis de escenarios modificando umbral, cobertura y efectividad.	Parámetros What-If en Power BI	Estudiantes Proyectados Retenidos (KPI-10).

Nota. Fuente: Elaboración propia basada en el diseño institucional y analítico del proyecto.

CAPÍTULO II: MARCO TEÓRICO Y FUNDAMENTACIÓN CIENTÍFICA

El presente capítulo establece los fundamentos teóricos, metodológicos y tecnológicos que sustentan el diseño e implementación del *Sistema Inteligente de Evaluación Adaptativa y Personalización del Aprendizaje Universitario*. Conforme a las exigencias académicas de la cátedra, cada sección se estructura en dos componentes complementarios: (1) fundamentación conceptual respaldada por literatura científica indexada y obras clásicas de la disciplina, y (2) justificación y aplicación directa en los artefactos del sistema.

2.0. Antecedentes de la Investigación

La predicción del rendimiento y la retención estudiantil mediante Inteligencia de Negocios y Aprendizaje Automático constituye un campo consolidado en la literatura internacional y nacional. A continuación, se sintetizan las investigaciones científicas directamente vinculadas a la problemática y arquitectura del proyecto:

Tabla 7

Matriz de datos y especificación analítica 7

N°	Autores y Año	Contexto y Muestra	Metodología / Técnicas de IA	Métricas Clave Obtenidas	Aporte Concreto Adoptado en este Proyecto
01	**Realinho et al. (2022)**	Instituto Politécnico de Portalegre (4,424 estudiantes, 37 atributos).	Random Forest, Gradient Boosting, CatBoost, SMOTE.	Accuracy: 77.1% (3 clases) y 87.2% (binario); F1-macro: 0.64–0.77.	**Paper fundacional del dataset de referencia:** Provee la selección de variables de admisión y trayectoria, y la formulación multiclase (`Dropout`, `Enrolled`, `Graduate`).
02	**Aparicio-Montenegro et al. (2026)**	**UNFV (Universidad Nacional Federico Villarreal, Perú)**, muestra institucional de pregrado.	Random Forest, Regresión Logística, Árboles C4.5, Naive Bayes.	RF Accuracy: 86.2%; Recall: 83.5%; F1-score: 0.84.	**Evidencia empírica directa de la UNFV:** Valida la superioridad de Random Forest en la población estudiantil villarrealina y justifica la prioridad del Recall en alertas tempranas.
03	**Aco Tito et al. (2023)**	Universidad Nacional de San Agustín (UNSA, Perú).	Random Forest, Regresión Logística, SVM, Árboles CART.	RF Accuracy: 84.7%, F1: 0.83; LR Accuracy: 78.2%, F1: 0.76.	**Antecedente nacional universitario:** Fundamenta la comparación

N°	Autores y Año	Contexto y Muestra	Metodología / Técnicas de IA	Métricas Clave Obtenidas	Aporte Concreto Adoptado en este Proyecto
					técnica formal entre Regresión Logística (baseline) y Random Forest exigida en la rúbrica.
04	**Almalawi et al. (2026)**	Educación Superior Internacional (evaluación formativa adaptativa).	Modelos lineales generalizados, clustering adaptativo, árboles multivariados.	F1-Score: 0.79; Precisión adaptativa: 82.4%.	**Pilar de Evaluación Adaptativa:** Fundamenta la Decisión D2: re-evaluación dinámica del riesgo por etapas temporales (M_1 Ingreso vs. M_2 Cierre del Primer Semestre).
05	**Hidayat et al. (2026)**	Análisis longitudinal de cohortes universitarias.	Random Forest, XGBoost, CatBoost, Regresión Logística, SMOTE-ENN.	RF ROC-AUC: 0.884; Recall Dropout: 84.1%; F1: 0.812.	**Pilar Analítica Prescriptiva y What-If:** Sustenta el simulador interactivo de escenarios What-If en Power BI variando umbrales de riesgo y efectividad de tutoría.
06	**Ali (2026)**	Prince Sattam bin Abdulaziz University (PSAU).	Ensemble Stacking (RF + Gradient Boosting), SHAP	Accuracy: 88.6%; Recall: 86.4%; F1: 87.1%; AUC: 0.912.	**Pilar de IA Explicable y Soporte Decisional:**

N°	Autores y Año	Contexto y Muestra	Metodología / Técnicas de IA	Métricas Clave Obtenidas	Aporte Concreto Adoptado en este Proyecto
			values, XAI.		Valida la articulación de modelos de Machine Learning con cuadros de mando ejecutivos para directores y comités tutoriales.
07	**Navarro Peñaranda et al. (2025)**	Facultad de Ingeniería de universidad pública (Colombia).	Regresión Logística binaria y árboles CART.	Accuracy: 79.3%; Odds Ratio (OR) en ciencias básicas = 3.42 ($p < 0.01$).	**Alineación con Facultades de Ingeniería:** Confirma que el rezago crítico en ingeniería se concentra en cursos troncales (Cálculo y Física), orientando la personalización.
08	**Schmidt (2023)**	Universidad estatal chilena (análisis longitudinal de cohortes).	Modelos de Supervivencia de Kaplan-Meier y Regresión de Cox.	73.8% de deserciones concentradas en los dos primeros semestres (HR = 2.87).	**Justificación de Hitos Temporales:** Sustenta por qué el sistema concentra sus dos momentos de corte analítico (M_1 y M_2) en la transición del primer año académico.

Nota. Fuente: Elaboración propia basada en el diseño institucional y analítico del proyecto.

2.1. Inteligencia de Negocios (Business Intelligence)

2.1.1. Fundamentación Teórica

La Inteligencia de Negocios (BI) se define como el conjunto integral de arquitecturas, tecnologías, procesos y metodologías que permiten transformar datos transaccionales heterogéneos y dispersos en información estructurada, significativa y directamente aplicable a la toma de decisiones estratégicas, tácticas y operativas (Chaudhuri & Dayal, 1997; Sharda et al., 2020). De acuerdo con Golfarelli y Rizzi (2009), el ciclo de vida de la Inteligencia de Negocios comprende cinco fases fundamentales:

1. **Extracción e integración:** Captura de datos desde sistemas operacionales transaccionales (OLTP) y fuentes externas.
2. **Limpieza y transformación (Staging):** Estandarización de formatos, tratamiento de datos nulos y normalización según reglas de calidad del negocio.
3. **Modelado y almacenamiento:** Carga en almacenes de datos estructurados dimensionalmente (Data Warehouse / DataMart).
4. **Análisis analítico multidimensional:** Procesamiento OLAP (*Online Analytical Processing*) que permite cálculos agregados instantáneos.
5. **Visualización y consumo:** Publicación en paneles ejecutivos interactivos (*Dashboards*) que soportan la monitorización de indicadores clave de rendimiento (KPIs) (Martín-Caro Álamo & Segovia-García, 2025).

2.1.2. Aplicación Concreta en el Proyecto

En la gestión académica tradicional de la FIEI-UNFV, la información se encuentra fragmentada en registros personales de docentes y reportes planos de intranet. La implementación de la plataforma de BI unifica estas fuentes en una arquitectura gobernada:

Tabla 8

Matriz de datos y especificación analítica 8

Componente de BI	Tecnología / Herramienta Seleccionada	Artefacto Concreto en el Proyecto
Capa Transaccional / Fuente	Archivos CSV planos y extractos relacionales	Datos de trayectoria académica (UCI Benchmark), contexto socioeconómico (ENAHO 2023) y catálogo institucional (TUNI SUNEDU).
Extracción y Transformación	Visual Studio SQL Server Integration	Proyecto `ETL_UNFV_Retencion.sln`

Componente de BI	Tecnología / Herramienta Seleccionada	Artefacto Concreto en el Proyecto
	Services (SSIS)	con paquetes independientes para carga de Staging, Dimensiones y Hechos.
Almacenamiento Dimensional	Microsoft SQL Server (Motor Relacional)	Base de datos `DM_RetencionAcademica_FIEI` con esquemas segregados `stg`, `dw` y `audit`.
Capa Semántica y OLAP	Microsoft SQL Server Analysis Services (SSAS)	Cubo Multidimensional `Cubo_RiesgoAcademico.asdatabase` con medidas precalculadas en MDX y DAX.
Capa de Consumo y Visualización	Microsoft Power BI Desktop	Dashboard interactivo `Dashboard_Retencion_FIEI.pbix` estructurado en 4 páginas con navegación ejecutiva y simulador What-If.

Nota. Fuente: Elaboración propia basada en el diseño institucional y analítico del proyecto.

2.2. Data Warehouse y DataMart (Metodología Kimball)

2.2.1. Fundamentación Teórica: Inmon vs. Kimball

En la ingeniería de almacenes de datos coexisten dos paradigmas arquitectónicos consolidados:

- **El enfoque corporativo Top-Down (Bill Inmon - Corporate Information Factory):** Plantea la construcción previa de un Data Warehouse corporativo unificado, altamente normalizado en Tercera Forma Normal (3FN), a partir del cual se desprenden posteriormente DataMarts temáticos dependientes. Si bien asegura máxima consistencia global, demanda tiempos excesivos de diseño e inversión institucional que dificultan entregas ágiles.
- **El enfoque dimensional Bottom-Up (Ralph Kimball - Dimensional Data Warehouse):** Plantea la construcción evolutiva e incremental de **DataMarts orientados a procesos de negocio específicos**, diseñados directamente bajo modelado dimensional (esquemas estrella o constelación), los cuales se integran horizontalmente mediante el uso riguroso de **Dimensiones Conformadas** (*Conformed Dimensions*) a través de una Matriz Bus de Negocio (Kimball & Ross, 2013).

2.2.2. Decisión de Ingeniería y Aplicación en el Proyecto

Se adopta formalmente el enfoque Bottom-Up de Ralph Kimball.

Justificación Metodológica: El alcance del proyecto está delimitado al proceso de negocio prioritario de la FIEI: *"Seguimiento Académico, Alerta Temprana y Retención Estudiantil"*. Implementar un Data Warehouse corporativo para toda la universidad requeriría integrar nóminas docentes, infraestructura física, compras y presupuesto estatal, lo cual desvirtuaría los objetivos del curso. El diseño de un **DataMart Departamental** en SQL Server asegura una arquitectura ágil, granular y optimizada para consultas analíticas de lectura masiva.

Para garantizar la integridad y auditoría del flujo de datos, se definen tres esquemas lógicos segregados dentro de la base de datos:

1. `stg` (**Staging Area**): Área de aterrizaje volátil donde los datos en bruto se insertan sin restricciones de clave foránea para su perfilado y limpieza.
2. `dw` (**DataMart Dimensional**): Área de producción analítica donde residen las tablas de dimensiones conformadas y las tablas de hechos con integridad referencial estricta.
3. `audit` (**Auditoría y Trazabilidad**): Almacena bitácoras de ejecución de los paquetes SSIS, registrando timestamps, conteo de filas leídas, cargadas y rechazadas.

2.3. Modelos Dimensionales y Matriz Bus

2.3.1. Fundamentación Teórica

El modelado dimensional estructura los datos en dos clases de tablas:

- **Tablas de Hechos (Fact Tables):** Representan eventos de negocio cuantitativos numéricos (medidas). Contienen claves foráneas hacia las dimensiones y métricas asociadas al evento.
- **Tablas de Dimensiones (Dimension Tables):** Representan el contexto del negocio (*quién, qué, cuándo, dónde y por qué*). Contienen atributos descriptivos textuales utilizados para filtrar, agrupar y rotar la información.

Los esquemas dimensionales estándar se clasifican en:

- *Esquema Estrella (Star Schema):* Estructura donde una tabla de hechos central se conecta directamente a tablas de dimensiones completamente desnormalizadas en un único nivel.
- *Esquema Copo de Nieve (Snowflake Schema):* Normaliza parcialmente las dimensiones en subtables jerárquicas, reduciendo redundancia a costa de degradar el rendimiento por excesivos `JOIN`.
- *Esquema Constelación de Hechos (Fact Constellation Schema):* Arquitectura avanzada donde **múltiples tablas de hechos** coexisten e interactúan compartiendo dimensiones conformadas comunes.

2.3.2. Decisión de Ingeniería y Matriz Bus Preliminar

Se implementa una Constelación de Hechos (Fact Constellation).

Justificación: El proceso analítico requiere modelar dos realidades con periodicidades y granos distintos: el progreso académico transaccional (notas y créditos) y las inferencias generadas por la Inteligencia Artificial (probabilidades y clústeres). Intentar consolidar ambos conceptos en una sola tabla de hechos violaría la regla fundamental del grano de Kimball.

A continuación, se formaliza la **Matriz Bus Preliminar (Kimball Bus Matrix)** que articula las tablas de hechos con las dimensiones conformadas:

Tabla 9

Matriz de datos y especificación analítica 9

Proceso de Negocio / Tabla de Hechos	`DimEstudiante`	`DimCurso`	`DimTiempo`	`DimEtapa`	`DimPerfilSocioec`	`DimInstitucion`
1. Registro y Rendimiento Académico (`dw.FactProgreso`)	**X**	**X**	**X**	**X**	**X**	—
2. Inferencia y Alerta Temprana por IA (`dw.FactPrediccion`)	**X**	—	**X**	**X**	**X**	—
3. Contexto Nacional de Educación (`dw.FactContextoNac`)	—	—	**X**	—	**X**	**X**

Nota. Fuente: Elaboración propia basada en el diseño institucional y analítico del proyecto.

Nota: `DimEstudiante`, `DimTiempo`, `DimEtapa` y `DimPerfilSocioec` son **dimensiones conformadas**, lo que permite realizar consultas cruzadas (*Drill-across*) entre el rendimiento real del alumno y las probabilidades estimadas por los modelos predictivos.

2.4. Datos, Información y Conocimiento (Pirámide DIKW)

2.4.1. Fundamentación Teórica

La jerarquía DIKW (*Data, Information, Knowledge, Wisdom*) formalizada por Ackoff (1989) y refinada por Rowley (2007) establece que los datos crudos carecen de significado por sí mismos hasta que son estructurados contextualmente (información), interpretados mediante

patrones analíticos (conocimiento) y utilizados éticamente para guiar acciones de intervención humana (sabiduría y decisión).

2.4.2. Aplicación Concreta en el Proyecto

El siguiente cuadro explicita la transformación del dato a lo largo de las capas tecnológicas del proyecto, utilizando exclusivamente **variables reales** del sistema:

Tabla 10

Matriz de datos y especificación analítica 10

Nivel DIKW	Definición Conceptual	Variable / Elemento Real en el Proyecto	Artefacto Tecnológico Responsable
DATO	Símbolos o registros crudos sin contexto interpretativo.	Valor numérico crudo `Curricular units 1st sem (approved) = 0`, `Curricular units 1st sem (grade) = 0.0`, `Debtor = 1` en el archivo `data.csv`.	Archivo fuente transaccional / Tabla staging en SQL Server (`stg.Staging_Estudiante`).
INFORMACIÓN	Datos estructurados, limpios y contextualizados con significado de negocio.	Registro dimensional que indica que el estudiante `E-2024-0142` tiene un Ratio de Eficiencia Crediticia ($REC = 0\%$) y condición de deuda financiera al término del primer semestre.	DataMart en SQL Server (`dw.FactProgreso` enlazada a `dw.DimEtapa` y `dw.DimPerfilSocioec`).
CONOCIMIENTO	Patrones inferidos, modelos probabilísticos y relaciones causales multivariables.	El modelo supervisado (Random Forest) asigna al estudiante una probabilidad de abandono $P(\text{Dropout}) = 84.7\%$ y el algoritmo no supervisado (K-Means) lo clasifica en el Clúster 1: *"Perfil Socioeconómico Crítico"*.	Pipeline de Machine Learning en Python Scikit-Learn (`dw.FactPrediccion`).
SABIDURÍA (DECISIÓN)	Juicio humano y acción institucional orientada a resolver el problema	El Comité de Tutoría y Bienestar Universitario aprueba una intervención	Dashboard interactivo en Power BI Desktop (`Página 4: Matriz de Acción y What-If`).

Nivel DIKW	Definición Conceptual	Variable / Elemento Real en el Proyecto	Artefacto Tecnológico Responsable
	detectado.	integral inmediata: asignación de Beca Comedor, flexibilización de matrícula y tutoría remedial de pares.	

Nota. Fuente: Elaboración propia basada en el diseño institucional y analítico del proyecto.

2.5. Dimensiones, Medidas, Jerarquías y Granularidad

2.5.1. Fundamentación Teórica

Según Kimball y Ross (2013), el paso más crítico del diseño dimensional es la **declaración formal de la granularidad**, la cual define qué representa exactamente una fila individual dentro de la tabla de hechos. Asimismo, las medidas cuantitativas se clasifican según su comportamiento frente a las agregaciones dimensionales:

- **Medidas Totalmente Aditivas:** Pueden sumarse a través de todas las dimensiones y jerarquías (ej. conteo de estudiantes, créditos acumulados).
- **Medidas Semiaditivas:** Pueden sumarse a través de algunas dimensiones, pero no de otras (típicamente no pueden sumarse a través del tiempo, como los saldos deudores).
- **Medidas No Aditivas:** No pueden sumarse bajo ninguna dimensión porque representan ratios, porcentajes o promedios ponderados. En DAX y MDX, deben calcularse como **cocientes de sumas de componentes aditivos**.

2.5.2. Aplicación Concreta en el Proyecto

- **Declaración del Grano para `dw.FactProgreso`:**

  "Un registro por cada estudiante individual evaluado en un curso y etapa académica específica (M_1 o M_2) dentro de un semestre lectivo."

- **Declaración del Grano para `dw.FactPrediccion`:**

  "Un registro por cada estudiante individual evaluado por un modelo analítico específico en un hito temporal (M_1 Ingreso vs. M_2 Cierre del Primer Semestre)."

A continuación se detalla la estructura dimensional y el catálogo de medidas del proyecto:

Tabla 11

Matriz de datos y especificación analítica 11

Tabla de Hechos	Medida Numérica	Tipo de Aditividad	Fórmula de Agregación en DAX / MDX
dw.FactProgreso	creditos_matriculados	Totalmente Aditiva	SUM(dw.FactProgreso[creditos_matriculados])
dw.FactProgreso	creditos_aprobados	Totalmente Aditiva	SUM(dw.FactProgreso[creditos_aprobados])
dw.FactProgreso	**Ratio de Eficiencia Crediticia (REC)**	**No Aditiva**	DIVIDE(SUM([creditos_aprobados]), SUM([creditos_matriculados]), 0) * 100
dw.FactProgreso	**Promedio Vigesimal Ponderado**	**No Aditiva**	DIVIDE(SUM([nota_vigesimal_x_creditos]), SUM([creditos_matriculados]), 0)
dw.FactPrediccion	probabilidad_dropout	Semiaditiva (Promediable)	AVERAGE(dw.FactPrediccion[prob_dropout])
dw.FactPrediccion	**Total Alumnos en Riesgo Crítico**	**Totalmente Aditiva**	CALCULATE(DISTINCTCOUNT([estudiante_key]), [prob_dropout] >= 0.60)

Nota. Fuente: Elaboración propia basada en el diseño institucional y analítico del proyecto.

- **Jerarquías de Análisis Diseñadas:**
- *Jerarquía Institucional (TUNI/SUNEDU):* `Tipo_Gestion` $\to$ `Universidad` $\to$ `Facultad` $\to$ `Escuela Profesional`. Permite a las autoridades navegar desde el macro-entorno nacional hasta el aula de clase en la FIEI.
- *Jerarquía Temporal de Evaluación:* `Periodo_Lectivo (2026)` $\to$ `Semestre (2026-I)` $\to$ `Etapa_Evaluacion (M1 / M2)`.

2.6. Cubos OLAP y Procesamiento Multidimensional (SSAS)

2.6.1. Fundamentación Teórica

El Procesamiento Analítico en Línea (OLAP), formalizado originalmente por Codd et al. (1993), permite consultas analíticas de alta velocidad sobre grandes volúmenes de datos mediante el precalculo y la indexación multidimensional. Las arquitecturas OLAP comprenden:

- **MOLAP (Multidimensional OLAP):** Almacena tanto los datos detallados como las agregaciones en estructuras de cubos multidimensionales optimizadas. Ofrece el máximo rendimiento en tiempos de respuesta.
- **ROLAP (Relational OLAP):** Mantiene los datos en el motor relacional y resuelve las consultas mediante SQL dinámico. Menor velocidad de respuesta frente a esquemas complejos.

- **HOLAP (Hybrid OLAP):** Combina el detalle en relacional con las agregaciones precalculadas en cubos multidimensionales.

Las cinco operaciones analíticas fundamentales sobre estructuras multidimensionales son:

1. **Roll-up (Drill-up):** Agregación de datos hacia un nivel jerárquico superior (ej. de escuela a facultad).
2. **Drill-down:** Desglose detallado hacia niveles inferiores de la jerarquía (ej. de facultad a curso o estudiante).
3. **Slice:** Filtrado por una condición fija en una dimensión específica (ej. analizar solo alumnos con beca).
4. **Dice:** Subdivisión del cubo seleccionando rangos específicos en dos o más dimensiones simultáneas (ej. estudiantes becados en condición de riesgo crítico en la Escuela de Informática).
5. **Pivot (Rotate):** Rotación de las dimensiones en los ejes de visualización (cambio de filas por columnas).

2.6.2. Decisión de Ingeniería y Aplicación en el Proyecto

Se implementa un Cubo Multidimensional en Microsoft SQL Server Analysis Services (SSAS) bajo modo MOLAP.

Justificación: Permite que directores de escuela y tutores exploren interactivamente la población estudiantil en Power BI con tiempos de respuesta inferiores a un segundo, delegando el cómputo pesado de agregaciones en el servicio de SSAS.

El siguiente cuadro mapea las 5 operaciones OLAP con las Preguntas de Negocio formalizadas en la Fase B1:

Tabla 12

Matriz de datos y especificación analítica 12

Operación OLAP	Pregunta de Negocio (Fase B1) que Resuelve	Dimensiones y Jerarquías Involucradas
Roll-up	**PN-01:** ¿Cuál es la tasa global de deserción de la FIEI comparada entre sus cuatro escuelas profesionales?	Agregación desde `DimCurso[Escuela]` hacia `DimInstitucion[Facultad]`.
Drill-down	**PN-02:** Dentro de la Escuela de Informática, ¿cuáles son las tres asignaturas específicas con mayor índice de desaprobación?	Desglose desde `DimCurso[Escuela]` hacia `DimCurso[NombreAsignatura]`.

Operación OLAP	Pregunta de Negocio (Fase B1) que Resuelve	Dimensiones y Jerarquías Involucradas
Slice	**PN-06:** ¿Qué porcentaje de estudiantes con beca universitaria mantienen un promedio aprobatorio?	Corte fijo sobre `DimEstudiante[Tiene_Beca = 'Sí']`.
Dice	**PN-03 y PN-08:** ¿Cuántos estudiantes trabajadores (> 20 horas) se encuentran en riesgo crítico ($P \ge 60\%$) en la etapa M_1?	Filtro cruzado simultáneo: `DimPerfilSocioec[Horas_Trabajo > 20]` $\times$ `DimEtapa[M1_Ingreso]` $\times$ `DimResultado[Riesgo = 'Crítico']`.
Pivot	**PN-04:** Comparar la distribución de clústeres de riesgo en filas cruzada contra las 4 escuelas profesionales en columnas.	Eje filas: `DimPerfilSocioec[Cluster_KMeans]`; Eje columnas: `DimCurso[Escuela]`.

Nota. Fuente: Elaboración propia basada en el diseño institucional y analítico del proyecto.

2.7. Indicadores de Gestión y KPIs

2.7.1. Fundamentación Teórica

Un Indicador Clave de Rendimiento (KPI) es una métrica cuantificable formalmente ligada a los objetivos estratégicos de la organización, que permite evaluar el desempeño, identificar desviaciones operativas y desencadenar intervenciones correctivas oportunas (Parmenter, 2015). A diferencia de una métrica operativa ordinaria, un KPI institucional debe poseer:

- Nombre oficial no ambiguo y alineado a la misión institucional.
- Fórmula matemática formalmente expresada.
- Periodicidad de cálculo y fuente primaria de datos.
- Meta cuantitativa (*Target*) y umbrales de semaforización (Verde, Amarillo, Rojo).
- Responsable directo de su monitoreo y gestión (matriz RACI).

2.7.2. Fichas Técnicas de los KPIs Oficiales del Proyecto

A partir del alineamiento estratégico con el Estatuto UNFV y los requerimientos de la Fase B1, se formalizan los 8 KPIs rectores del sistema:

$$\begin{array}{|l|l|}

\hline

\textbf{KPI-01} & \textbf{Tasa de Abandono Histórico (TA)} \\ \hline

\text{Fórmula} & TA = \left(\frac{\text{Conteo de Estudiantes en condición Dropout}}{\text{Total de Estudiantes Matriculados}} \right) \times 100 \\ \hline

\text{Meta} & \le 18.0\% \text{ (Semáforo: Verde } \le 18\% \mid \text{Amarillo } 18.1\% \text{--} 25\% \mid \text{Rojo } > 25\%) \\ \hline

\text{Responsable} & \text{Director de Escuela Profesional / Decano FIEI} \\ \hline

\end{array}$$

$$\begin{array}{|l|l|}

\hline

\textbf{KPI-02} & \textbf{Ratio de Eficiencia Crediticia (REC)} \\ \hline

\text{Fórmula} & REC = \left(\frac{\sum \text{Créditos Aprobados en el Semestre}}{\sum \text{Créditos Matriculados en el Semestre}} \right) \times 100 \\ \hline

\text{Meta} & \ge 85.0\% \text{ (Semáforo: Verde } \ge 85\% \mid \text{Amarillo } 70\% \text{--} 84.9\% \mid \text{Rojo } < 70\%) \\ \hline

\text{Responsable} & \text{Comité de Tutoría y Consejería Universitaria} \\ \hline

\end{array}$$

$$\begin{array}{|l|l|}

\hline

\textbf{KPI-03} & \textbf{Rendimiento Vigesimal Promedio (RVP)} \\ \hline

\text{Fórmula} & RVP = \frac{\sum (\text{Calificación Vigesimal } [0\text{--}20] \times \text{Créditos})}{\sum \text{Créditos Evaluados}} \\ \hline

\text{Meta} & \ge 13.5 \text{ pts (Semáforo: Verde } \ge 13.5 \mid \text{Amarillo } 11.0 \text{--} 13.4 \mid \text{Rojo } < 11.0) \\ \hline

\text{Responsable} & \text{Docentes Tutores y Directores de Escuela} \\ \hline

\end{array}$$

$$\begin{array}{|l|l|}

\hline

\textbf{KPI-04} & \textbf{Índice de Estudiantes en Riesgo Crítico por IA (IRC)} \\ \hline

\text{Fórmula} & IRC = \sum [1 \text{ si } P(\text{Dropout}) \ge 0.60 \text{ else } 0] \\ \hline

\text{Meta} & \le 15.0\% \text{ del padrón matriculado} \\ \hline

\text{Responsable} & \text{Comité de Tutoría / Plataforma BI+IA} \\ \hline

\end{array}$$

$$\begin{array}{|l|l|}

\hline

\textbf{KPI-05} & \textbf{Sensibilidad / Recall del Modelo de Alerta Temprana en Dropout} \\ \hline

\text{Fórmula} & \text{Recall}_{\text{Dropout}} = \frac{VP_{\text{Dropout}}}{VP_{\text{Dropout}} + FN_{\text{Dropout}}} \\ \hline

\text{Meta} & \ge 75.0\% \text{ en Momento 1 } (M_1) \text{ y } \ge 82.0\% \text{ en Momento 2 } (M_2) \\ \hline

\text{Responsable} & \text{Equipo de Ingeniería de Datos y Machine Learning} \\ \hline

\end{array}$$

$$\begin{array}{|l|l|}

\hline

\textbf{KPI-06} & \textbf{Cobertura de Acompañamiento Tutorial a Población Crítica (CAT)} \\ \hline

\text{Fórmula} & CAT = \left(\frac{\text{Estudiantes Críticos con Tutor Asignado}}{\text{Total de Estudiantes con } P(\text{Dropout}) \ge 0.60} \right) \times 100 \\ \hline

\text{Meta} & 100.0\% \text{ (Semáforo: Verde } 100\% \mid \text{Amarillo } 80\% \text{--} 99\% \mid \text{Rojo } < 80\%) \\ \hline

\text{Responsable} & \text{Coordinador de Tutoría FIEI} \\ \hline

\end{array}$$

$$\begin{array}{|l|l|}

\hline

\textbf{KPI-07} & \textbf{Calidad de Cohesión de Perfiles Socioacadémicos (Silhouette Score)} \\ \hline

\text{Fórmula} & s(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))}, \quad \bar{s} = \frac{1}{N}\sum_{i=1}^{N} s(i) \\ \hline

\text{Meta} & \bar{s} \ge 0.35 \text{ (Estructura de agrupamiento sustancial en K-Means)} \\ \hline

\text{Responsable} & \text{Módulo Analítico de Personalización (Python)} \\ \hline

\end{array}$$

$$\begin{array}{|l|l|}

\hline

\textbf{KPI-08} & \textbf{Estudiantes Proyectados Retenidos por Simulación What-If (EPR)} \\ \hline

\text{Fórmula} & EPR = \sum_{i \in \text{Críticos}} [P_i(\text{Dropout}) \ge U] \times \text{Cobertura}_{\text{Tutor}} \times \text{Efectividad}_{\text{Intervención}} \\ \hline

\text{Meta} & \text{Maximizar la retención institucional simulada bajo restricciones presupuestales} \\ \hline

\text{Responsable} & \text{Decanato FIEI y Comité de Gestión de Calidad} \\ \hline

\end{array}$$

2.8. Machine Learning e Inteligencia Artificial Educativa

2.8.1. Fundamentación Teórica

La Minería de Datos Educativa (*Educational Data Mining* - EDM) y la Analítica del Aprendizaje (*Learning Analytics* - LA) aplican modelos matemáticos y algoritmos computacionales para descubrir patrones ocultos en grandes volúmenes de datos académicos (Baker & Inventado, 2014; Ali, 2026).

- **Formulación del Problema: ¿Por qué Clasificación Multiclase y no Regresión?**

Intentar predecir la calificación vigesimal continua exacta con modelos de regresión lineal (ej. predecir si el alumno obtendrá 11.3 o 11.7) introduce severo ruido estocástico y carece de utilidad gerencial directa. La toma de decisiones en la FIEI-UNFV exige categorizar al estudiante en un estado de riesgo institucional accionable (`Dropout`, `Enrolled`, `Graduate`). Por lo tanto, el problema se formula rigurosamente como **Clasificación Supervisada Multiclase**.

• Algoritmos Comparados (Exigencia del Criterio 5 de la Cátedra):

1. *Regresión Logística Multinomial (Baseline Lineal):* Modela el logaritmo de la razón de probabilidades (*log-odds*) mediante combinaciones lineales de los predictores normalizados (Hosmer et al., 2013). Se selecciona como línea base por su velocidad, robustez computacional y alta interpretabilidad a través de los coeficientes de regresión.
2. *Random Forest Classifier (Ensamble No Lineal):* Ensamble de árboles de decisión independientes construidos mediante agregación por remuestreo (*Bootstrap Aggregating* o *Bagging*) y selección aleatoria de subespacios de características (Breiman, 2001). Se selecciona porque captura relaciones no lineales complejas, interacciones entre variables socioeconómicas y resiste el sobreajuste (*overfitting*).

• Aprendizaje No Supervisado: K-Means Clustering:

Agrupa observaciones multidimensionales en k conglomerados homogéneos minimizando la inercia o suma de distancias cuadradas intra-clúster. Permite segmentar a la población estudiantil en perfiles de vulnerabilidad sin etiquetas previas, alimentando la matriz de personalización.

2.8.2. Protocolo de Validación, Desbalance de Clases y Métricas

• Tratamiento del Desbalance de Clases:

En las universidades, la tasa de deserción es una clase minoritaria en comparación con los alumnos regulares. Guiarse únicamente por la Exactitud (*Accuracy*) constituye un error metodológico severo: un modelo trivial que predijera que ningún alumno desertará alcanzaría más del 70% de Accuracy cometiendo un 100% de error en la detección de alumnos en riesgo.

• Métrica Prioritaria de Negocio: Recall en la Clase Dropout:

$$\text{Recall} = \frac{VP}{VP + FN}$$

En el contexto universitario, el costo de un **Falso Negativo** (un estudiante en abandono real que el sistema clasifica como exitoso y no recibe ayuda) es catastrófico, pues deriva en la pérdida de gratuidad o deserción consumada. El costo de un **Falso Positivo** (citar a tutoría

preventiva a un alumno que no iba a desertar) es marginal y pedagógicamente inofensivo. Por ende, la métrica de optimización es el **Recall de la clase *Dropout***.

- **$F_1\text{-score}$ Macro:**

$$F_1\text{-macro} = \frac{1}{|C|} \sum_{c \in C} 2 \times \frac{\text{Precision}_c \times \text{Recall}_c}{\text{Precision}_c + \text{Recall}_c}$$

Promedia armónicamente el desempeño equitativo entre las clases sin favorecer a la clase mayoritaria.

- **Prevención de Fuga de Datos (*Data Leakage*):**

Se garantiza que ninguna variable perteneciente al segundo semestre académico ni el estado final del alumno (*target*) ingrese como predictor en los modelos de admisión o primer semestre (M_1 y M_2).

- **Estrategia de Validación y Población del Dashboard:**

El entrenamiento y calibración se efectúan mediante validación cruzada estratificada (*Stratified K-Fold*, $k=5$). Para evitar exponer un dashboard incompleto con solo el subconjunto de prueba (*test split*), las probabilidades continuas de toda la matrícula (4,424 casos) se calculan mediante predicciones fuera de muestra (*out-of-fold predictions*), garantizando que ningún dato sea predicho con el modelo que lo entrenó.

2.9. Evaluación Adaptativa, Analítica del Aprendizaje y Personalización

2.9.1. Marco Conceptual y Delimitación Operativa

La literatura en tecnología educativa vincula la "evaluación adaptativa" tanto a pruebas reactivo por reactivo (*Computerized Adaptive Testing* - CAT basado en Teoría de Respuesta al Ítem) como a sistemas de alerta temprana basados en analítica de cohortes dinámicas (Almalawi et al., 2026; Siemens & Baker, 2012). Ante la naturaleza del curso (orientado a Business Intelligence y Data Warehousing) y la disponibilidad de datos de trayectoria en educación superior, se adoptan formalmente las **Definiciones Operativas aprobadas en la Fase A0**:

> ***Definición Operativa de Evaluación Adaptativa (Decisión D2):***
>
> *"Proceso analítico dinámico de re-evaluación del riesgo académico del estudiante ejecutado en etapas sucesivas (M_1: Admisión e Ingreso vs. M_2: Cierre del Primer Semestre), ajustando el pronóstico institucional conforme se consolida su rendimiento académico real."*
>
> ***Definición Operativa de Personalización del Aprendizaje (Decisión D3):***

"Segmentación de la población estudiantil en perfiles multidimensionales homogéneos mediante aprendizaje no supervisado (K-Means Clustering), articulada con una matriz institucional de recomendaciones pedagógicas y tutoriales diferenciadas según la causa raíz del riesgo."

2.9.2. Ciclo Adaptativo-Prescriptivo del Sistema

A diferencia de los enfoques estáticos tradicionales, el sistema opera bajo un ciclo proactivo cerrado:

[Diagrama / Especificación de Proceso BPMN 2.0]

```
flowchart LR
    A["1. Evaluación M1<br>(Al Ingreso)"] --> B["2. Segmentación K-Means<br>(Perfiles Socioacadémicos)"]
    B --> C["3. Prescripción Focalizada<br>(Taller / Beca / Tutor)"]
    C --> D["4. Re-evaluación M2<br>(Cierre Semestre 1)"]
    D --> E["5. Ajuste Dinámico de Alerta<br>(Delta de Probabilidad)"]
    E --> F["6. Retención Exitosa<br>(Continuidad Curricular)"]
```

2.9.3. Matriz de Personalización según Clúster Socioacadémico

El clustering no supervisado identifica tres perfiles arquetípicos en la facultad:

1. Clúster 1: Vulnerabilidad Socioeconómica Integral:

- *Características:* Estudiante becado o de bajos ingresos, padres sin educación superior, dificultad de financiamiento.
- *Prescripción Personalizada:* Priorización automática para Beca Comedor, carné de medio pasaje, apoyo de Bienestar Universitario y subsidio de materiales.

2. Clúster 2: Sobrecarga Laboral y Desbalance Horario:

- *Características:* Estudiante trabajador (> 20 horas semanales), edad superior a la media, menor tasa de asistencia presencial.
- *Prescripción Personalizada:* Asesoría en matrícula balanceada (reducción de carga de 22 a 16 créditos), acceso a grabaciones y tutoría nocturna asincrónica.

3. Clúster 3: Rezago Específico en Ciencias Básicas:

- *Características:* Adecuado soporte socioeconómico pero bajo rendimiento concentrado en Matemática Básica, Cálculo I o Física.
- *Prescripción Personalizada:* Asignación a talleres de nivelación intensiva en ciencias básicas y emparejamiento con tutores de pares de ciclos superiores.

2.9.4. Consideraciones Éticas, Privacidad y Mitigación de Sesgos

Conforme a la Ley de Protección de Datos Personales (Ley N° 29733) y las directrices éticas de Inteligencia Artificial en Educación (Ali, 2026):

- **No Estigmatización:** Las probabilidades de riesgo se presentan a directores y tutores como *indicadores de necesidad de apoyo institucional*, nunca como etiquetas deterministas o punitivas para condicionar la matrícula del alumno.
- **Privacidad y Agregación:** Se eliminan identificadores directos sensibles (DNI, nombres) y se aplica la regla de supresión de celdas pequeñas ($k \ge 5$) en visualizaciones públicas para evitar la re-identificación de estudiantes vulnerables.

2.10. Procesos ETL y Calidad de Datos

2.10.1. Fundamentación Teórica

El proceso de Extracción, Transformación y Carga (ETL) representa el núcleo de la ingeniería de datos en una arquitectura Kimball, siendo responsable de extraer datos heterogéneos, garantizar su calidad, resolver inconsistencias y cargarlos en las dimensiones y tablas de hechos (Kimball & Caserta, 2004). En la suite de Microsoft SQL Server, esta labor se ejecuta mediante **SQL Server Integration Services (SSIS)** articulando dos componentes:

- **Flujo de Control (Control Flow):** Orquesta la secuencia de ejecución lógica, transacciones, contenedores de bucle y llamadas a tareas auxiliares (ejecución de scripts Python y procedimientos almacenados).
- **Flujo de Datos (Data Flow):** Ejecuta la extracción de filas, transformaciones en memoria (conversión de tipos de datos, derivaciones matemáticas, búsquedas *Lookup*) y destino relacional.

2.10.2. Catálogo de Reglas de Calidad y Transformación en SSIS

Para mitigar riesgos técnicos durante la ingesta de las fuentes (UCI, ENAHO y TUNI), se establecen formalmente las siguientes reglas de calidad implementadas en el proyecto:

Tabla 13

Matriz de datos y especificación analítica 13

N°	Regla de Calidad de Datos	Problema de Origen Detectado	Transformación y Tratamiento en SSIS	Artefacto Afectado
RC-01	**Estandarización de Codificación (Code Page)**	Fuentes con caracteres especiales (tildes y ñ) codificados en UTF-8 o Windows-1252.	Configurar `CodePage = 1252 (ANSI - Latino)` en el Flat File Connection Manager de SSIS para evitar truncamientos y errores de metadatos.	Paquetes de ingesta staging en SSIS.

N°	Regla de Calidad de Datos	Problema de Origen Detectado	Transformación y Tratamiento en SSIS	Artefacto Afectado
RC-02	**Normalización a Escala Vigesimal Oficial**	Las notas en el dataset UCI están registradas en escala portuguesa ($0\text{ a }20$ puntos continuos con promedio 10.0 aprobatorio).	Validar la consistencia con la escala vigesimal peruana ($0\text{ a }20$ reglamentada en UNFV donde la nota mínima aprobatoria es 11). Derivar campo flag `es_aprobado = IF(nota >= 10.5, 1, 0)`.	Columna calculada en `dw.FactProgreso`.
RC-03	**Distinción de Calificaciones Cero vs. Abandono**	Estudiantes que abandonaron la asignatura registran nota 0 pero cero evaluaciones rendidas.	Regla de derivación: Si `evaluaciones_rendidas = 0` y `nota = 0`, tipificar la condición como `"No se presentó / Abandono no formal"` para no sesgar el promedio de notas reales.	Transformación de columna derivada en SSIS.
RC-04	**Tratamiento de Miembro Desconocido (Inferencia de Nulos)**	Datos socioeconómicos o institucionales con valores nulos o claves huérfanas en dimensiones.	Crear obligatoriamente la fila con clave sustituta `-1` (o miembro desconocido: `"No Especificado" / "Desconocido"`) en cada dimensión para no violar la integridad referencial de las tablas de hechos.	Dimensiones conformadas en `dw`.
RC-05	**Gestión de Dimensiones de Cambio Lento (SCD)**	Cambios en la situación laboral o estado de beca del alumno entre el ingreso y el primer ciclo.	Implementar **SCD Tipo 1 (Sobrescribir)** para atributos estáticos y **SCD Tipo 2 (Versionamiento histórico con fechas de vigencia)** si se requiere registrar la transición de estado socioeconómico.	Componente Slowly Changing Dimension en SSIS.
RC-06	**Trazabilidad y Conciliación de Cargas**	Pérdida de filas silenciosa por fallos en conversiones de tipos de datos.	Implementar en cada paquete la fórmula de conciliación en `audit.Auditoria_Carga`:	Tabla de auditoría en SQL Server.

N°	Regla de Calidad de Datos	Problema de Origen Detectado	Transformación y Tratamiento en SSIS	Artefacto Afectado
			$$\text{Filas Origen} = \text{Filas Insertadas} + \text{Filas Rechazadas}$$	

Nota. Fuente: Elaboración propia basada en el diseño institucional y analítico del proyecto.

REFERENCIAS BIBLIOGRÁFICAS OFICIALES (FORMATO APA 7ma EDICIÓN)

1. Fuentes Científicas Internacionales en Idioma Inglés (20%)

Ali, G. M. (2026). An explainable AI framework for multimodal student performance prediction and institutional decision support at PSAU. *Decision Science Letters*, 15(6), 995–1012. https://doi.org/10.5267/j.dsl.2026.8.010

Almalawi, A., Soh, B., Li, A., Alanazi, A., & Samra, H. (2026). An exploratory feasibility study of adaptive assessment: a multivariate, data-driven approach to formative evaluation. *Frontiers in Education*, 11, Article 1849701. https://doi.org/10.3389/feduc.2026.1849701

Hidayat, N., Afuan, L., & Jannah, H. R. (2026). Prescriptive Learning Analytics for Student Dropout: Integrating Temporal Velocity and Counterfactual Explanations in Longitudinal Data. *Journal of Computing Theories and Applications*, 3(1), Article 15920. https://doi.org/10.62411/jcta.15920

Realinho, V., Machado, J., Baptista, L., & Martins, M. V. (2022). Predicting Student Dropout and Academic Success. *Data*, 7(11), Article 146. https://doi.org/10.3390/data7110146

2. Fuentes Científicas en Idioma Español (80%)

Aco Tito, A. E., Hancco Condori, B. O., & Pérez Vera, Y. (2023). Análisis comparativo de Técnicas de Machine Learning para la predicción de casos de deserción universitaria. *RISTI - Revista Ibérica de Sistemas e Tecnologias de Informação*, 51, 84–98. https://doi.org/10.17013/risti.51.84-98

Angulo Quiñonez, A. Á. (2022). La autoestima, su relación con el rendimiento académico y la deserción universitaria. *Sapienza: International Journal of Interdisciplinary Studies*, 3(6), 514–529. https://doi.org/10.51798/sijis.v3i6.514

Aparicio-Montenegro, P., Esparza Silva, M. R., Huapaya Sotero, A., Garcia-Alvarez, M. Y., & De La Cruz Garcia, A. (2026). Predictive model based on machine learning for the early identification of student dropout in a public university. *Proceedings of the 24th LACCEI International Multi-Conference for Engineering, Education, and Technology*, 1–10. https://doi.org/10.18687/LACCEI2026.1.1.721

Barrera-Liévano, J. A., Barrera-Liévano, D. C., Beltrán-Virgüez, J. E., & Castillo-Sánchez, M. (2025). Correlación entre variables de deserción universitaria en programas en modalidad a distancia en Colombia. *Estudios Pedagógicos*, 51(2), 161–175. https://doi.org/10.4067/S0718-07052025000200161

Castro-Martínez, J. A., & Machuca-Téllez, G. (2023). La deserción universitaria en América Latina: una perspectiva ecológica. *Estudios Pedagógicos*, 49(2), 87–108. https://doi.org/10.4067/S0718-07052023000200087

Contreras-Bravo, L. E., Nieves-Pimiento, N., & Fuentes-Contreras, J. A. (2022). Predicción del Rendimiento Académico a Nivel Universitario Mediante Mecanismos de Machine Learning y Métodos Supervisados. *Ingeniería*, 27(3), Article e19514. https://doi.org/10.14483/23448393.19514

González, J. A., Carvajal, C. M., Rebolledo, R. A., & González, F. A. (2024). Grado de logro de la competencia digital (GLCD) en relación a la deserción de estudiantes universitarios. *Formación Universitaria*, 17(3), 153–166. https://doi.org/10.4067/S0718-50062024000300153

Martín-Caro Álamo, E., & Segovia-García, N. (2025). Analítica de Aprendizaje y Retención Estudiantil: un Estudio Longitudinal en Educación Superior Virtual. *Revista Fuentes*, 27(1), 1–12. https://doi.org/10.12795/revistafuentes.2025.27592

Navarro Peñaranda, J. A., Pérez Castro, J. D., & Rodríguez Rojas, L. A. (2025). Determinants of University Dropout: A Study in the Engineering Faculty of a Public University in Colombia. *Proceedings of the 23rd LACCEI International Multi-Conference for Engineering, Education, and Technology*, 1–8. https://doi.org/10.18687/LACCEI2025.1.1.2431

Ochoa Cedeño, E. G., Rodríguez Magaña, A., & García Bejar, L. (2024). Implementación y Evaluación del Programa de Mejora Académica en una Universidad Privada del Occidente de México. *European Public & Social Innovation Review*, 9(1), 45–65. https://doi.org/10.31637/epsir-2024-555

Parra-Sánchez, J. S., Torres Pardo, I. D., & Martínez de Merino, C. Y. (2023). Factores explicativos de la deserción universitaria abordados mediante inteligencia artificial. *Revista Electrónica de Investigación Educativa (REDIE)*, 25, Article e18. https://doi.org/10.24320/REDIE.2023.25.E18.4455

Romero-Tenorio, J.-M., Riccardi, D., & de Yzaguirre, F. (2026). Teatro del oprimido y sociograma. Acción colectiva contra la deserción universitaria. *Revista Iberoamericana de Educación Superior*, 17(49), 112–131. https://doi.org/10.22201/iisue.20072872e.2026.49.1985

Salazar Alberto, R. A., Guzman Aquije, E. H., & Lozada Flores, R. M. (2024). Application of artificial intelligence to predict academic performance in order to prevent dropout in high school students: Systematic Literature Review. *Proceedings of the 22nd LACCEI International Multi-Conference for Engineering, Education, and Technology*, 1–8. https://doi.org/10.18687/LACCEI2024.1.1.1426

Schmidt, B. J. (2023). Factores que influyen en la deserción universitaria: El caso de una universidad estatal chilena. *Revista Portuguesa de Educação*, 36(1), Article e23002. https://doi.org/10.21814/rpe.23401

Torres, H. V., et al. (2023). Modelo de clasificación para la deserción estudiantil en una universidad pública del Perú. *Salud, Ciencia y Tecnología - Serie de Conferencias*, 2(2), Article 175. https://doi.org/10.56294/sctconf2023175

Vega Velásquez, M., Bastardo Contreras, X., & Giraldo de López, M. (2025). Factores Socioemocionales y Deserción Universitaria. Análisis correlacional en grupos desertores en los años 2021 y 2022. *European Public & Social Innovation Review*, 10(1), 1–14. https://doi.org/10.31637/epsir-2025-1173

3. Obras Clásicas y Fundacionales de la Disciplina

Ackoff, R. L. (1989). From data to wisdom. *Journal of Applied Systems Analysis*, 16(1), 3–9.

Baker, R. S., & Inventado, P. S. (2014). Educational Data Mining and Learning Analytics. En J. Larusson & B. White (Eds.), *Learning Analytics: From Research to Practice* (pp. 61–75). Springer.

Breiman, L. (2001). Random Forests. *Machine Learning*, 45(1), 5–32. https://doi.org/10.1023/A:1010933404324

Chaudhuri, S., & Dayal, U. (1997). An overview of data warehousing and OLAP technology. *ACM SIGMOD Record*, 26(1), 65–74. https://doi.org/10.1145/248603.248616

Codd, E. F., Codd, S. B., & Salley, C. T. (1993). *Providing OLAP to User-Analysts: An IT Mandate*. E. F. Codd & Associates.

Golfarelli, M., & Rizzi, S. (2009). *Data Warehouse Design: Modern Principles and Methodologies*. McGraw-Hill.

Hosmer, D. W., Lemeshow, S., & Sturdivant, R. X. (2013). *Applied Logistic Regression* (3rd ed.). John Wiley & Sons.

Inmon, W. H. (2005). *Building the Data Warehouse* (4th ed.). John Wiley & Sons.

Kaplan, R. S., & Norton, D. P. (1996). *The Balanced Scorecard: Translating Strategy into Action*. Harvard Business School Press.

Kimball, R., & Caserta, J. (2004). *The Data Warehouse ETL Toolkit: Practical Techniques for Extracting, Cleaning, Conforming, and Delivering Data*. Wiley.

Kimball, R., & Ross, M. (2013). *The Data Warehouse Toolkit: The Definitive Guide to Dimensional Modeling* (3rd ed.). Wiley.

Parmenter, D. (2015). *Key Performance Indicators: Developing, Implementing, and Using Winning KPIs* (3rd ed.). John Wiley & Sons.

Rowley, J. (2007). The wisdom hierarchy: representations of the DIKW hierarchy. *Journal of Information Science*, 33(2), 163–180. https://doi.org/10.1177/0165551506070706

Sharda, R., Delen, D., & Turban, E. (2020). *Analytics, Data Science, & Artificial Intelligence: Systems for Decision Support* (11th ed.). Pearson.

Siemens, G., & Baker, R. S. (2012). Learning analytics and educational data mining: towards a public conversation. *Proceedings of the 2nd International Conference on Learning Analytics and Knowledge (LAK '12)*, 252–254. https://doi.org/10.1145/2330601.2330661