UNIVERSIDAD NACIONAL FEDERICO VILLARREAL
FACULTAD DE INGENIERÍA ELECTRÓNICA E INFORMÁTICA

SISTEMA INTELIGENTE DE EVALUACIÓN ADAPTATIVA Y PERSONALIZACIÓN DEL APRENDIZAJE UNIVERSITARIO

Integrantes:

Anchillo Mallqui Christian Elias

Herrera Ccari Robert Eloy

Vasquez Berrocal Jimmy Adrian

Zavala Castillo Mariam Yohanan

Docente: Mg. Ing. Ivan Crispin Sanchez

Lima, Perú
2026

Introducción

1. Presentación del Proyecto

El presente proyecto diseña e implementa una plataforma integral de Business Intelligence (BI) y Machine Learning (ML) concebida para transformar la gestión del seguimiento académico y la retención estudiantil en la Universidad Nacional Federico Villarreal (UNFV), focalizando su aplicación piloto en la Facultad de Ingeniería Electrónica e Informática (FIEI). La arquitectura tecnológica articula un DataMart relacional en Microsoft SQL Server bajo metodología dimensional, pipelines automatizados de Extracción, Transformación y Carga (ETL) en Visual Studio SQL Server Integration Services (SSIS), cubos multidimensionales OLAP en SQL Server Analysis Services (SSAS), modelos predictivos de aprendizaje automático en Python (Scikit-Learn) y paneles interactivos de control en Microsoft Power BI Desktop con simulación de escenarios What-If.

La plataforma está orientada a resolver una limitación estructural recurrente en las universidades públicas peruanas: la detección tardía e inconexa de los estudiantes en riesgo de abandono. Frente a los modelos tradicionales que constatan el fracaso escolar cuando los exámenes parciales ya han concluido, esta solución implementa un mecanismo preventivo de doble impacto: evaluación adaptativa en dos momentos cronológicos estratégicos (ingreso vs. primer semestre) y personalización del acompañamiento tutorial a través de segmentación no supervisada por clústeres socioacadémicos.

2. Problema Identificado y Contexto Empírico

La deserción en la educación superior universitaria peruana representa una problemática crítica con graves consecuencias sociales, académicas e institucionales. De acuerdo con estadísticas del Ministerio de Educación (MINEDU) y el Sistema de Información Universitaria (TUNI) de la Superintendencia Nacional de Educación Superior Universitaria (SUNEDU, 2024), la tasa nacional de deserción acumulada en pregrado oscila entre el 12% y 18% en el primer año académico. Esta cifra se agrava sustancialmente en las facultades de ingeniería y ciencias exactas, donde la reprobación masiva en asignaturas troncales (Cálculo, Física y Álgebra) desencadena el desánimo vocacional y el abandono voluntario (Navarro Peñaranda et al., 2025).

A nivel del entorno laboral y socioeconómico de los estudiantes, el procesamiento de los microdatos de la Encuesta Nacional de Hogares (INEI ENAHO 2023, Módulos 300 de Educación y 500 de Empleo, aplicando el filtro P308A=5 de educación superior universitaria y el factor de expansión FAC500A) revela que el 44.0% de los jóvenes universitarios peruanos trabaja de forma simultánea a sus estudios, dedicando en promedio 34.7 horas semanales a su jornada laboral (Barrera-Liévano et al., 2025; Vega Velásquez et al., 2025). Esta sobrecarga laboral compite directamente con el tiempo de estudio presencial y autónomo, incrementando la vulnerabilidad académica si no es detectada oportunamente.

Como base empírica de referencia y validación técnica de algoritmos (prueba de concepto analítica, ante la reserva de datos protegidos por la Ley N.° 29733 de Protección de Datos Personales), se utiliza el benchmark abierto del Machine Learning Repository de la Universidad de California en Irvine (UCI - Predict Students' Dropout and Academic Success, Realinho et al., 2022). Este conjunto de datos comprende 4,424 registros de matrícula, 37 atributos socioeconómicos y académicos normalizados en escala vigesimal (0 a 20) y nota de admisión (0 a 200), y una distribución observada de condición de graduación (49.9%), abandono o dropout (32.1%) y matrícula activa continua (17.9%).

3. Árbol de Problemas Institucional

Para formalizar la relación entre causas y efectos en la gestión académica actual, se estructura el siguiente diagnóstico:

a) Efectos Finales:

Pérdida de gratuidad de la enseñanza universitaria (mandato del Artículo 99 de la Ley Universitaria N.° 30220 al acumular asignaturas desaprobadas), rezago curricular crónico, baja tasa de graduación oportuna y frustración vocacional en las escuelas de ingeniería (Romero-Tenorio et al., 2026).

b) Problema Central:

Alta tasa de deserción no advertida y pérdida de rendimiento en estudiantes de primeros ciclos en la FIEI-UNFV, debido a la ausencia de un sistema automatizado de alerta temprana e intervención tutorial personalizada.

c) Causas Raíz Identificadas:

1. Latencia informacional de 8 a 10 semanas para consolidar notas de exámenes parciales en la intranet.
2. Silos de datos: las calificaciones de prácticas intermedias permanecen en hojas de cálculo aisladas en computadoras docentes.
3. Diagnóstico reactivo post-mortem basado en promedios aritméticos simples (< 10.5) sin análisis predictivo multivariable.
4. Intervenciones tutoriales genéricas y tardías que no discriminan la causa raíz (económica, laboral o matemática).

4. Importancia de la Solución y Beneficios por Actor

La implementación de este sistema de Inteligencia de Negocios e Inteligencia Artificial genera impactos positivos medibles en los cuatro niveles de gestión de la facultad:

Tabla 1

Matriz de Beneficios Institucionales por Actor Clave

Actor Institucional	Rol en el Proceso	Beneficio Concreto del Sistema	Componente Asociado
Director de Escuela	Aprobador Estratégico	Visibilidad ejecutiva de tasas de deserción y rendimiento por asignatura en tiempo real; simulación de retención institucional.	Dashboard Power BI y Cubo SSAS.
Comité de Tutoría	Gestor Operativo	Semáforo predictivo priorizado de riesgo por estudiante; emisión de alertas preventivas en semana 2 sin esperar al examen parcial.	Módulo de ML en Python y Dashboard Power BI.
Docente Tutor	Interventor Pedagógico	Ficha integral del estudiante con diagnóstico del perfil (Clúster) y recomendación precisa de la acción de rescate requerida.	Matriz de Recomendación y Ficha Individual Power BI.
Estudiante FIEI	Beneficiario Directo	Acompañamiento tutorial oportuno antes de la pérdida de gratuidad; nivelación en ciencias básicas o becas de bienestar.	Acciones Prescritas del Proceso TO-BE.

5. Delimitación y Alcance del Proyecto

A fin de asegurar el rigor metodológico y concentrar los esfuerzos en la ingeniería de datos y analítica predictiva exigidas por la cátedra, se establecen las siguientes delimitaciones operativas:

Tabla 2

Matriz de Alcance: Componentes Incluidos vs. Excluidos

Dimensión / Componente	**Incluido en el Alcance (In-Scope)**	**Excluido del Alcance (Out-of-Scope)**	**Justificación Metodológica**
Canal de Visualización	Paneles analíticos e interactivos en Power BI Desktop con parámetros What-If.	Desarrollo de portales web full-stack, aplicaciones móviles o microservicios.	Power BI concentra el valor en el modelado semántico y análisis decisional; desarrollar software web transaccional dispersa el esfuerzo sin aportar valor analítico.
Evaluación Pedagógica	Evaluación adaptativa por hitos cronológicos (M1 Ingreso vs. M2 Fin Semestre 1).	Tests adaptativos computarizados (CAT) reactivo por reactivo bajo Teoría de Respuesta al Ítem.	No existen datos de interacción ítem a ítem; forzarlo destruiría la trazabilidad del DataMart relacional.
Integración de Datos	Articulación conceptual y agregada por escuela y departamento entre UCI, TUNI y ENAHO.	Cruce forzado estudiante a estudiante con identificadores ficticios entre UCI y ENAHO.	Falacia de datos ('Frankenstein'). Se respeta la integridad y granularidad de cada fuente primaria.
Población del Tablero	Cálculo de probabilidad continua de riesgo para el 100% de la matrícula.	Limitación a solo el subconjunto de prueba (test split del 20%).	El cuadro de mando de tutoría exige visibilidad total de toda la cohorte matriculada para gestionar rescates.
Simulación What-If	Modelado interactivo de capacidad tutorial variando umbral de riesgo y cobertura institucional.	Garantía de reducción causal absoluta de deserción sin validación de campo.	Rigor científico: el What-If modela supuestos de capacidad de gestión institucional, no efectos causales directos.

Capítulo I: Generalidades de la Organización

1.1. Descripción de la Empresa u Organización

La entidad marco del presente estudio es la Universidad Nacional Federico Villarreal (UNFV), institución pública autónoma de educación superior universitaria del Estado Peruano, focalizando la implementación piloto en su Facultad de Ingeniería Electrónica e Informática (FIEI).

La UNFV ostenta Licenciamiento Institucional otorgado por la Superintendencia Nacional de Educación Superior Universitaria (SUNEDU) mediante Resolución del Consejo Directivo N° 035-2019-SUNEDU/CD, expedida el 11 de marzo de 2019, la cual acreditó el cumplimiento riguroso de las Condiciones Básicas de Calidad (CBC) exigidas por la Ley Universitaria N° 30220.

La FIEI concentra la formación tecnológica y científica de vanguardia de la universidad en su sede de Breña (Jr. Iquique N° 127), albergando una población superior a los 2,200 estudiantes de pregrado distribuidos en sus cuatro escuelas profesionales: Escuela Profesional de Ingeniería Informática, Escuela Profesional de Ingeniería Electrónica, Escuela Profesional de Ingeniería Mecatrónica y Escuela Profesional de Ingeniería de Telecomunicaciones. El régimen académico es semestral, con 16 semanas lectivas por ciclo y escala de calificación vigesimal oficial (0 a 20).

1.2. Historia, Misión, Visión y Valores Institucionales

1.2.1. Reseña Histórica Oficial:

La Universidad Nacional Federico Villarreal fue creada mediante la Ley N.° 14692, promulgada el 30 de octubre de 1963 (verificada estrictamente en el Diario Oficial El Peruano), naciendo sobre la base de la filial en Lima de la Universidad Comunal del Centro del Perú. Nombrada en memoria del insigne sabio, matemático, físico e ingeniero peruano Federico Villarreal, la universidad ha cumplido más de seis décadas formando profesionales. La FIEI se constituyó como unidad académica autónoma orientada a liderar la investigación, el desarrollo tecnológico y la analítica computacional.

1.2.2. Misión Institucional (Estatuto y PEI UNFV Vigente):

"Formar profesionales e investigadores competitivos, con sólidos valores éticos, humanísticos, científicos y tecnológicos, comprometidos con el desarrollo sostenible del país." **(Estatuto UNFV, Art. 7)**

1.2.3. Visión Institucional (Estatuto y PEI UNFV Vigente):

"Ser una universidad pública licenciada y acreditada internacionalmente, líder en la formación integral de excelencia e investigación innovadora de alto impacto social." **(PEI UNFV 2022-2026)**

1.2.4. Valores Institucionales:

• Rigor Científico y Excelencia Académica: Compromiso con la exactitud metodológica, la ingeniería de datos y la veracidad de los modelos analíticos.

• Ética e Integridad: Transparencia en la gestión informacional, auditoría de procesos y respeto irrestricto a la privacidad de los datos estudiantiles.

• Responsabilidad Social y Equidad: Orientación de las políticas institucionales a la protección de los sectores estudiantiles vulnerables y prevención del rezago.

• Innovación Continua: Adopción proactiva de arquitecturas de Business Intelligence y algoritmos de Machine Learning para modernizar la gestión pública universitaria.

Tabla 3

Alineamiento Estratégico entre la Filosofía UNFV y la Plataforma Analítica

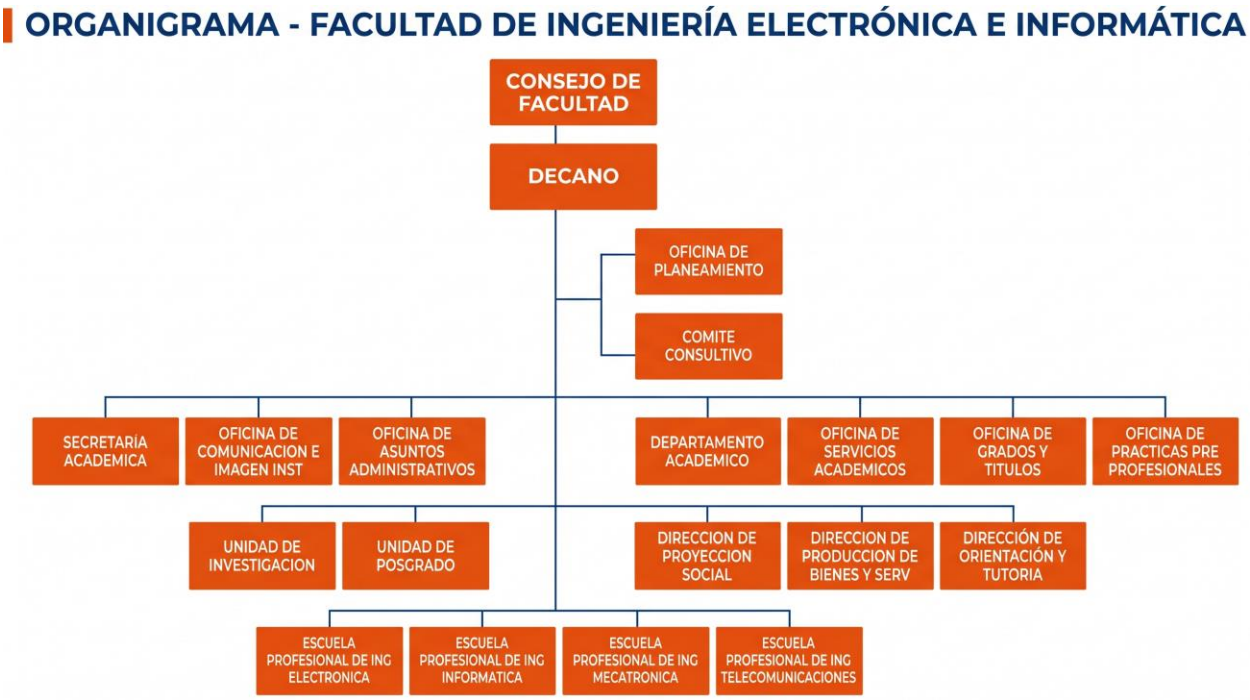
Eje Estratégico UNFV	**Compromiso Institucional Declarado**	**Alineamiento y Cumplimiento del Proyecto de BI + IA**
Misión: Formación Profesional Competitiva	Garantizar la culminación oportuna de los planes de estudio y evitar la deserción.	El sistema alerta tempranamente el rezago en asignaturas troncales de ingeniería, asegurando la continuidad formativa.
Visión: Excelencia y Acreditación	Cumplimiento permanente de estándares de retención y calidad educativa universitaria.	Provee métricas de retención objetivas y auditables que sustentan auditorías de SUNEDU y modelos de acreditación SINEACE.
Valores: Equidad y Responsabilidad	Evitar que barreras socioeconómicas y laborales trunquen la vocación universitaria.	Segmenta a los estudiantes según horas de trabajo y condición económica para priorizar becas y tutorías diferenciadas.

1.3. Estructura Organizativa y Organigrama Funcional

La gobernanza y el seguimiento del rendimiento académico en la Facultad de Ingeniería Electrónica e Informática (FIEI) de la UNFV se estructuran bajo un modelo funcional y jerárquico formal, encabezado por el Consejo de Facultad como máxima autoridad deliberativa y el Decano como máxima autoridad ejecutiva, con el soporte estratégico de la Oficina de Planeamiento y el Comité Consultivo.

Figura 1

Organigrama Estructural de la Facultad de Ingeniería Electrónica e Informática (FIEI - UNFV)



Nota. Fuente: Adaptado del Manual de Organización y Funciones (MOF) y del Estatuto Universitario de la Universidad Nacional Federico Villarreal (UNFV, 2024), Facultad de Ingeniería Electrónica e Informática.

Para la operatividad del sistema de Inteligencia de Negocios y Analítica Predictiva, la interacción entre dependencias se articula en tres niveles clave:

• Nivel Estratégico (Decanato y Consejo de Facultad): Supervisa los indicadores macro de retención institucional, deserción por ciclo y simulaciones What-If de capacidad presupuestal y tutorial.

• Nivel Táctico (Escuelas Profesionales y Departamento Académico): Las direcciones de las cuatro escuelas profesionales (Ingeniería Informática, Ingeniería Electrónica, Ingeniería Mecatrónica e Ingeniería de Telecomunicaciones), en coordinación con el Departamento Académico y la Oficina de Servicios Académicos, gestionan las cohortes de estudiantes, analizan las asignaturas con mayor índice de reprobación y programan la carga lectiva docente.

• Nivel Operativo (Dirección de Orientación y Tutoría): Es la unidad orgánica especializada encargada de coordinar las acciones de rescate estudiantil. A través de este tablero, la dirección y los docentes tutores asignados reciben las alertas tempranas del semáforo predictivo de riesgo para ejecutar el acompañamiento académico personalizado y canalizar asistencias socioeconómicas.

Esta disposición define con exactitud los perfiles de usuario, niveles de acceso y carriles (Swimlanes) del flujo analítico TO-BE implementado en la plataforma.

1.4. Área Involucrada y Matriz de Responsabilidades (RACI)

El seguimiento del estudiante involucra a dependencias académicas, tutoriales y de apoyo bajo el mandato formal de los Artículos 126 (Tutoría Universitaria) y 128 (Servicios de Bienestar) de la Ley Universitaria N° 30220. Se formaliza la matriz RACI del proceso:

Tabla 4

Matriz RACI del Proceso de Seguimiento Académico y Retención

Actividad / Proceso Analítico	**Director Escuela**	**Comité Tutoría**	**Docente Tutor**	**Bienestar Univ.**	**Plataforma BI+IA**
1. Consolidación de datos de matrícula y notas (ETL)	I	I	I	I	R / A
2. Emisión y monitoreo del semáforo de riesgo predictivo	A	R	C	I	R
3. Asignación de estudiantes críticos a tutores de escuela	A	R	I	C	Soporte
4. Ejecución de sesiones tutoriales y talleres de nivelación	I	A	R	C	Soporte
5. Asignación de becas comedor y ayudas de bienestar	I	C	C	R / A	Soporte

6. Evaluación global de KPIs y simulación de retención What-If	R / A	C	I	I	Soporte

Leyenda RACI:

R = Responsable de la ejecución.

A = Aprobador final.

C = Consultado para criterio experto.

I = Informado de los resultados.

1.5. Descripción del Proceso Actual (AS-IS)

En el régimen operativo actual de la FIEI-UNFV, el seguimiento del rendimiento se ejecuta de forma desarticulada, manual y predominantemente reactiva. A lo largo del ciclo regular de 16 semanas, el flujo se desenvuelve de la siguiente forma:

Tabla 5

Desglose de Actividades del Proceso Tradicional (AS-IS)

N°	**Actividad Operativa**	**Actor**	**Semana**	**Salida / Artefacto**	**Cuello de Botella y Problema Detectado**
1	Matrícula regular	Estudiante	Sem. 0	Ficha de matrícula	Solo registra cursos; no captura situación laboral ni horas de trabajo.
2	Desarrollo de clases y prácticas	Docente	Sem. 1-7	Excel personal	Las notas parciales quedan aisladas en laptops de profesores; cero visibilidad.
3	Exámenes parciales	Docente/Alumno	Sem. 8	Exámenes físicos	Primer hito formal; el estudiante ya acumula 2 meses de rezago no detectado.
4	Carga oficial a intranet	Docente	Sem. 9-10	Acta digital	Latencia crítica: frecuentes retrasos en la digitación institucional de notas.
5	Revisión manual de notas	Comité Tutoría	Sem. 10-11	Lista en papel	Diagnóstico post-mortem: filtrado manual de promedios < 10.5 sin análisis multivariable.

6	Exámenes finales y actas	Docente	Sem. 16	Acta final	Consumación del fracaso académico, repitencia o matrícula condicionada.

1.6. Diagrama AS-IS y Catálogo de Dolores de Gestión

El modelado del proceso AS-IS estructurado en tres carriles (Estudiante, Docente de Asignatura y Comité de Tutoría) evidencia cuatro puntos críticos de dolor que motivan la solución:

• DOLOR 1 (Silos de Información): Las notas de evaluaciones continuas se almacenan en archivos Excel personales de los docentes, desconectados de las bases centrales. La facultad permanece a oscuras respecto al desempeño durante las primeras 7 semanas de clases.

• DOLOR 2 (Latencia Informacional Crítica): Retraso de 9 a 10 semanas desde el inicio del semestre para que las autoridades y tutores dispongan de calificaciones consolidadas en el sistema oficial.

• DOLOR 3 (Detección Reactiva 'Post-Mortem'): La identificación de estudiantes en riesgo se efectúa manualmente revisando promedios aritméticos simples (< 10.5) cuando el estudiante ya reprobó el examen parcial.

• DOLOR 4 (Intervención Uniforme e Ineficaz): La citación a tutoría se emite de manera genérica en las semanas 11 y 12, sin identificar si el origen del rezago es socioeconómico, laboral o de base matemática, y sin margen temporal para revertir la reprobación.

1.7. Propuesta del Proceso Futuro (TO-BE) Optimizado con BI + IA

El proceso propuesto rediseña la gestión académica mediante la integración de un carril automatizado: la Plataforma BI + IA (ETL SSIS, DataMart SQL Server, Machine Learning en Python y Power BI). El flujo se transforma de un esquema manual y reactivo a un ciclo proactivo, continuo y adaptativo estructurado en 4 carriles de interacción: Estudiante, Docente de Asignatura, Dirección de Orientación y Tutoría y Plataforma Analítica Automatizada.

Tabla 6

Desglose Cronológico de Actividades del Proceso Optimizado (TO-BE)

N°	Actividad Operativa	Actor	Semana	Salida / Artefacto	Optimización y Valor Agregado (BI + IA)
1	Matrícula y Ficha Integral	Estudiante	Sem. 0	Ficha de matrícula y Ficha socioacadémica digitalizada	Captura de variables socioeconómicas y laborales (horas de trabajo) en origen; elimina la falta de datos previa.
2	Evaluación Preventiva (M_1)	Plataforma BI + IA (SSIS / Python)	Sem. 1-2	Probabilidad de riesgo $P(\text{Drop})_{M1}$ y Clúster K-Means	Detección proactiva temprana sin esperar notas; diagnóstico multivariable al inicio de clases.
3	Prescripción Tutorial Diferenciada	Dir. Orientación y Tutoría	Sem. 2-3	Semáforo de riesgo y Ficha de Rescate personalizada	Asignación oportuna: el estudiante recibe nivelación matemática o apoyo socioeconómico según su perfil antes del rezago.
4	Seguimiento y Registro Continuo	Docente / Docente Tutor	Sem. 4-8	Notas parciales en intranet centralizada	Erradicación de silos locales en Excel; visibilidad continua del avance del estudiante durante las primeras evaluaciones.
5	Re-evaluación Adaptativa (M_2)	Plataforma BI + IA (Cubo SSAS / BI)	Sem. 9-10	Probabilidad de riesgo $P(\text{Drop})_{M2}$ y varianza (ΔP)	Evaluación dinámica: recalcula el riesgo con notas reales de mitad de ciclo, identificando alumnos recuperados o nuevos casos críticos.
6	Simulación y Refuerzo Focalizado	Directores de Escuela / Tutores	Sem. 11-15	Parámetros *What-If* en Power BI	Simulación interactiva de capacidad tutorial para redistribuir horas de apoyo docente y maximizar la retención en la recta final.
7	Cierre y Auditoría de Cohorte	Decanato / Consejo de Facultad	Sem. 16	Reporte ejecutivo de retención y actas finales	Cierre con indicadores objetivos auditables para acreditación (SINEACE/SUNEDU) y retroalimentación del modelo predictivo.

1.8. Matriz Comparativa Exhaustiva: Proceso AS-IS vs. Proceso TO-BE

A continuación, se sintetiza la transformación cualitativa y cuantitativa entre ambos modelos:

Tabla 7

Matriz Comparativa de Transformación: Proceso AS-IS vs. Proceso TO-BE

Dimensión Analítica	**Situación Actual (AS-IS)**	**Situación Propuesta (TO-BE)**	**Componente Tecnológico**	**KPI Asociado de Impacto**
Tiempo de Detección	Semanas 9 a 11: Detección reactiva tras digitar notas de exámenes parciales.	Semanas 2 a 4 (M1): Diagnóstico preventivo al ingreso y re-evaluación en M2.	Pipeline SSIS + Python ML	Tiempo de detección <= 4 semanas; Recall >= 75%.
Integración de Datos	Archivos Excel dispersos en computadoras personales de los docentes.	DataMart Centralizado en SQL Server: trayectoria, catálogo y contexto ENAHO.	DataMart dimensional (dw)	100% de fuentes integradas; 0 duplicados.
Criterio de Riesgo	Promedio simple post-parcial (< 10.5) sin análisis predictivo multivariable.	Modelo de Machine Learning (Random Forest) que calcula probabilidad continua.	dw.FactPrediccion	F1-Macro >= 0.65; ROC-AUC >= 0.85.
Enfoque Evaluativo	Estático y terminal; sin seguimiento de la evolución del riesgo.	Evaluación Adaptativa Dinámica: re-evaluación del riesgo en dos hitos (M1 vs M2).	dw.DimEtapa + Cubo SSAS	Delta de probabilidad entre etapas (Delta P).
Intervención Tutorial	Genérica y uniforme para todos los reprobados (aviso o sanción estándar).	Personalización por Perfiles: prescripción según clúster identificado por IA.	K-Means + Matriz de Reglas	Silhouette >= 0.35; Cobertura tutorial 100%.
Herramienta de Control	Actas físicas en papel y listados planos en Excel no interactivos.	Dashboard Inteligente en Power BI Desktop con semáforo interactivo.	Power BI Desktop	100% de directores y tutores consultando en vivo.
Planificación de Gestión	Empírica e intuitiva; sin capacidad de proyectar rescates.	Simulación Interactiva What-If: análisis de capacidad, umbral y efectividad.	Parámetros What-If Power BI	Estudiantes Proyectados Retenidos (KPI-08).

Capítulo II: Marco Teórico y Aplicación de Ingeniería

El presente capítulo establece los fundamentos teóricos, matemáticos y metodológicos que sustentan la plataforma. Conforme a las exigencias académicas de la cátedra, cada subtema se desglosa en dos partes esenciales:

(1) Fundamentación Conceptual respaldada por literatura científica indexada contemporánea (2022-2026)

(2) Justificación y Aplicación de Ingeniería Concreta en los artefactos del sistema.

2.0. Antecedentes de la Investigación

La aplicación de Inteligencia de Negocios y Aprendizaje Automático en educación superior cuenta con un cuerpo sólido de investigación contemporánea internacional y nacional. Se sintetizan los estudios empíricos directamente vinculados al diseño de nuestra arquitectura:

Tabla 8

Síntesis de Antecedentes Empíricos y Aportes Adoptados

N°	Autores y Año	Contexto / Institución	Técnicas de IA Empleadas	Métricas Reportadas	Aporte Concreto Adoptado en este Proyecto
01	Realinho et al. (2022)	Inst. Politécnico Portalegre (4,424 alumnos, 37 vars).	Random Forest, Gradient Boosting, CatBoost, SMOTE.	Accuracy: 77.1% (3 clases) y 87.2% (binario); F1: 0.64-0.77.	Paper fundacional del dataset: justifica los 37 predictores y el target multiclase (Dropout, Enrolled, Graduate).
02	Aparicio-Montenegro et al. (2026)	UNFV (Universidad Nacional Federico Villarreal, Perú).	Random Forest, Regresión Logística, Árboles C4.5, Naive Bayes.	RF Accuracy: 86.2%; Recall: 83.5%; F1-score: 0.84.	Evidencia empírica directa UNFV: valida la superioridad de Random Forest en estudiantes villarrealinos y el foco en Recall.
03	Aco Tito et al. (2023)	Univ. Nacional de San Agustín (UNSA, Arequipa, Perú).	Random Forest, Regresión Logística, SVM, Árboles CART.	RF Acc: 84.7%, F1: 0.83; LR Acc: 78.2%, F1: 0.76.	Antecedente nacional universitario: fundamenta la comparación técnica obligatoria de LR vs. RF en la rúbrica.

04	Almalawi et al. (2026)	Educación Superior Internacional (evaluación formativa).	Modelos lineales generalizados, clustering adaptativo.	F1: 0.79; Precisión adaptativa: 82.4%.	Pilar Evaluación Adaptativa: fundamenta la Decisión D2 (re-evaluación dinámica del riesgo por etapas M1 y M2).
05	Hidayat et al. (2026)	Análisis longitudinal de cohortes universitarias.	Random Forest, XGBoost, CatBoost, Regresión Logística.	RF ROC-AUC: 0.884; Recall Dropout: 84.1%; F1: 0.812.	Pilar Analítica Prescriptiva y What-If: sustenta el simulador interactivo variando umbrales y efectividad en Power BI.
06	Ali (2026)	Prince Sattam bin Abdulaziz University (PSAU).	Ensemble Stacking (RF + GB), SHAP values, XAI.	Accuracy: 88.6%; Recall: 86.4%; AUC: 0.912.	Pilar Alerta Temprana e IA Explicable: valida la articulación de BI con modelos de IA para comités de tutoría.
07	Navarro Peñaranda et al. (2025)	Facultad de Ingeniería de universidad pública (Colombia).	Regresión Logística binaria y árboles CART.	Accuracy: 79.3%; Odds Ratio en ciencias básicas = 3.42.	Alineación con Ingeniería: confirma que el rezago crítico en ingeniería se concentra en cursos troncales (Cálculo/Física).
08	Schmidt (2023)	Universidad estatal chilena (análisis longitudinal).	Supervivencia de Kaplan-Meier y Regresión de Cox.	73.8% de deserciones concentradas en los 2 primeros semestres.	Justificación de Hitos: sustenta por qué concentrar los dos cortes analíticos (M1 y M2) en el primer año académico.

2.1. Inteligencia de Negocios (Business Intelligence)

2.1.1. Fundamentación Conceptual:

En la literatura científica contemporánea sobre gestión y analítica de datos en educación superior, la Inteligencia de Negocios (BI) se define como el conjunto integrado de metodologías, arquitecturas y flujos de datos que transforman registros heterogéneos y dispersos en información estructurada y procesable para la toma de decisiones institucionales (Salazar Alberto

et al., 2024; Martín-Caro Álamo & Segovia-García, 2025). El ciclo de vida de la Inteligencia de Negocios comprende cinco fases fundamentales:

(1) Extracción de fuentes transaccionales

(2) Limpieza y estandarización en áreas de preparación (Staging)

(3) Modelado en depósitos analíticos estructurados (DataMart)

(4) Procesamiento analítico multidimensional para agregaciones en tiempo real

(5) Visualización ejecutiva mediante cuadros de mando interactivos que soportan la monitorización de Indicadores Clave de Rendimiento (KPIs).

2.1.2. Aplicación y Decisión de Ingeniería en el Proyecto:

En la FIEI-UNFV, la plataforma de BI supera la dispersión de registros manuales integrando la arquitectura completa en Microsoft SQL Server y Power BI:

Tabla 9

Articulación de Componentes de BI con los Artefactos del Proyecto

Componente de BI	**Tecnología / Herramienta**	**Artefacto Específico en el Proyecto**
Fuentes Transaccionales	Archivos planos CSV y consultas relacionales	Extracto académico UCI (data.csv), ENAHO 2023 y catálogo nacional TUNI SUNEDU.
Pipeline ETL	Visual Studio SQL Server Integration Services (SSIS)	Solución ETL_UNFV_Retencion.sln con paquetes independientes de Staging, Dimensiones y Hechos.
Almacén Analítico	Microsoft SQL Server Database Engine	DataMart DM_RetencionAcademica_FIEI con esquemas segregados stg, dw y audit.
Procesamiento OLAP	Microsoft SQL Server Analysis Services (SSAS)	Cubo multidimensional Cubo_RiesgoAcademico.asdatabase con medidas calculadas en MDX y DAX.
Consumo y Visualización	Microsoft Power BI Desktop	Dashboard ejecutivo Dashboard_Retencion_FIEI.pbix estructurado en 4 páginas de control interactivo.

2.2. Data Warehouse y DataMart (Metodología Dimensional)

2.2.1. Fundamentación Conceptual: Arquitectura Dimensional Departamental:

En la ingeniería moderna de almacenes de datos universitarios, la literatura especializada destaca la superioridad de los DataMarts departamentales orientados a procesos de negocio específicos frente a macroproyectos corporativos centralizados que suelen fracasar por

sobredimensión de alcance (Salazar Alberto et al., 2024). El enfoque dimensional organiza los datos en función de las necesidades de análisis del usuario final, empleando Dimensiones Conformadas (Conformed Dimensions) para interconectar múltiples procesos analíticos de forma consistente y evolutiva.

2.2.2. Aplicación y Decisión de Ingeniería en el Proyecto:

Se selecciona formalmente la arquitectura dimensional de DataMart departamental. Dado que el objetivo del proyecto es optimizar el proceso de seguimiento y retención estudiantil en la FIEI-UNFV, unificar nóminas, compras o patrimonio dispersaría el esfuerzo analítico. La construcción de un DataMart departamental en SQL Server garantiza un diseño ágil, granular y optimizado para consultas analíticas de lectura masiva. Para asegurar la gobernanza, se definen tres esquemas lógicos segregados en la base de datos:

- stg (Staging Area): Área de aterrizaje volátil donde se insertan los datos crudos sin restricciones de integridad referencial para su perfilado y limpieza.
- dw (DataMart Dimensional): Área de producción analítica donde residen las dimensiones conformadas y las tablas de hechos con claves foráneas estrictas.
- audit (Auditoría): Bitácora de ejecución de paquetes SSIS que almacena timestamps, conteos de filas leídas, insertadas y rechazadas.

2.3. Modelos Dimensionales y Matriz Bus de Negocio

2.3.1. Fundamentación Conceptual:

El modelado dimensional estructura los datos en Tablas de Hechos (que contienen métricas numéricas de eventos de negocio) y Tablas de Dimensiones (que contienen el contexto descriptivo: quién, cuándo, dónde y por qué). Los diseños analíticos estándar abarcan esquemas estrella, copos de nieve y constelaciones de hechos (Fact Constellation), siendo esta última la recomendada cuando coexisten múltiples procesos que comparten entidades de referencia comunes (Salazar Alberto et al., 2024).

2.3.2. Aplicación y Decisión de Ingeniería en el Proyecto:

Se implementa un esquema de Constelación de Hechos (Fact Constellation). Esta decisión es imperativa porque el proceso analítico modela dos eventos de naturaleza y periodicidad distintas: el progreso académico transaccional (créditos y notas continuas) y la

inferencia predictiva de Machine Learning (probabilidades continuas y clústeres asignados). Unificarlos en una sola tabla violaría el principio de granularidad de la base de datos.

Tabla 10

Matriz Bus de Negocio (Procesos vs. Dimensiones Conformadas)

Proceso de Negocio / Tabla de Hechos	**DimEstudiante**	**DimCurso**	**DimTiempo**	**DimEtapa**	**DimPerfilSocioec**	**DimInstitucion**
1. Rendimiento Académico (dw.FactProgreso)	X	X	X	X	X	—
2. Inferencia y Alerta de IA (dw.FactPrediccion)	X	—	X	X	X	—
3. Contexto Nacional SUNEDU (dw.FactContextoNac)	—	—	X	—	X	X

Nota: DimEstudiante, DimTiempo, DimEtapa y DimPerfilSocioec son dimensiones conformadas, permitiendo consultas cruzadas (Drill-across) entre el desempeño real del estudiante y su probabilidad predicha de deserción.

2.4. Datos, Información y Conocimiento (Jerarquía Cognitiva)

2.4.1. Fundamentación Conceptual:

En los marcos contemporáneos de analítica institucional universitaria (Ali, 2026; Hidayat et al., 2026), el valor de los datos se conceptualiza como una progresión estructural continua: los Datos crudos carecen de significado autónomo; la Información contextualiza dichos datos dentro del plan de estudios; el Conocimiento descubre patrones predictivos y factores de riesgo multivariables mediante algoritmos de inteligencia artificial; y la Decisión aplica dicho conocimiento para orientar intervenciones tutoriales oportunas.

2.4.2. Aplicación Concreta en el Proyecto (Variables Reales):

La transformación se evidencia a través de variables reales del sistema:

Tabla 11

Aplicación de la Jerarquía Cognitiva con Variables Reales del Proyecto

Nivel Cognitivo	Definición Teórica	Manifestación Real en el Proyecto	Componente Tecnológico
Dato	Símbolos y valores numéricos crudos desprovistos de contexto.	Registros numéricos crudos en archivo CSV: Curricular_units_1st_sem_approved = 0, Curricular_units_1st_sem_grade = 0.0, Debtor = 1.	Archivo transaccional data.csv / stg.Staging_Estudiante.
Información	Datos procesados, limpios y estructurados con significado de negocio.	En el DataMart, el registro indica un alumno de Ingeniería con Ratio de Eficiencia Crediticia REC = 0% y deuda económica en etapa S1.	dw.FactProgreso enlazada a dw.DimEtapa y dw.DimPerfilSocioec.
Conocimiento	Patrones inferidos, modelos causales y probabilidades predictivas.	El modelo Random Forest asigna una probabilidad P(Dropout) = 84.7% y K-Means lo clasifica en Clúster 1: Perfil Socioeconómico Crítico.	Pipeline de ML en Python (dw.FactPrediccion).
Decisión Institucional	Intervención humana y juicio tutorial basado en datos.	El Comité de Tutoría y Bienestar aprueba un plan inmediato: asignación de Beca Comedor, reprogramación de matrícula y tutor de pares.	Paneles de Acción y Simulación What-If en Power BI.

2.5. Dimensiones, Medidas, Jerarquías y Granularidad

2.5.1. Fundamentación Conceptual:

Declarar formalmente el nivel de granularidad es la base del diseño de datos analíticos (Salazar Alberto et al., 2024). Las medidas se clasifican en:

(1) Totalmente Aditivas (sumables en todas las dimensiones),

(2) Semiaditivas (sumables en ciertas dimensiones pero no a través del tiempo)

(3) No Aditivas (porcentajes, promedios y ratios, que en lenguajes analíticos como DAX deben calcularse como cocientes de sumas).

2.5.2. Aplicación y Declaración Formal de Grano:

• Grano de dw.FactProgreso: 'Un registro individual por cada estudiante evaluado en una asignatura y etapa académica específica (M1 o M2) dentro de un semestre lectivo.'

• Grano de dw.FactPrediccion: 'Un registro individual por cada estudiante evaluado por

un modelo analítico en un hito temporal específico (M1 Ingreso vs. M2 Cierre Semestre 1).'

Tabla 12

Catálogo de Medidas y Comportamiento de Aditividad en DAX

Tabla de Hechos	Medida Numérica	Tipo de Aditividad	Fórmula de Agregación DAX / MDX
dw.FactProgreso	creditos_matriculados	Totalmente Aditiva	SUM(dw.FactProgreso[creditos_matriculados])
dw.FactProgreso	creditos_aprobados	Totalmente Aditiva	SUM(dw.FactProgreso[creditos_aprobados])
dw.FactProgreso	Ratio de Eficiencia Crediticia (REC)	No Aditiva	DIVIDE(SUM([creditos_aprobados]), SUM([creditos_matriculados]), 0) * 100
dw.FactProgreso	Promedio Vigesimal Ponderado	No Aditiva	DIVIDE(SUM([nota_vigesimal_x_creditos]), SUM([creditos_matriculados]), 0)
dw.FactPrediccion	probabilidad_dropout	Semiaditiva	AVERAGE(dw.FactPrediccion[prob_dropout])
dw.FactPrediccion	Total Alumnos Riesgo Crítico	Totalmente Aditiva	CALCULATE(DISTINCTCOUNT([estudiante_key]), [prob_dropout] >= 0.60)

Jerarquías de Análisis:

(1) Jerarquía Institucional: Tipo_Gestion -> Universidad -> Facultad -> Escuela Profesional.

(2) Jerarquía Temporal de Evaluación: Periodo_Lectivo -> Semestre -> Etapa_Evaluacion (M1 / M2).

2.6. Cubos OLAP y Procesamiento Multidimensional (SSAS)

2.6.1. Fundamentación Conceptual:

El Procesamiento Analítico en Línea (OLAP) permite consultas complejas de agregación instantánea mediante el precalculo multidimensional de medidas sobre dimensiones indexadas (Salazar Alberto et al., 2024; Martín-Caro Álamo & Segovia-García, 2025). Las arquitecturas

estándar son: MOLAP (Multidimensional OLAP, almacenamiento y agregación en cubos de alto rendimiento), ROLAP y HOLAP. Las 5 operaciones analíticas esenciales son: Roll-up (agregación ascendente), Drill-down (desglose descendente), Slice (filtrado en una dimensión), Dice (corte simultáneo en dos o más dimensiones) y Pivot (rotación de ejes de análisis).

2.6.2. Aplicación y Mapeo con Preguntas de Negocio:

Se implementa un Cubo Multidimensional en Microsoft SQL Server Analysis Services (SSAS) bajo modo MOLAP, respondiendo directamente a las preguntas de negocio institucionales:

Tabla 13

Mapeo de Operaciones OLAP con Preguntas de Negocio Institucionales

Operación OLAP	Pregunta de Negocio Resuelta	Dimensiones y Jerarquías Involucradas
Roll-up	PN-01: ¿Cuál es la tasa de deserción comparada entre escuelas de la FIEI?	Agregación desde DimCurso[Escuela] hacia DimInstitucion[Facultad].
Drill-down	PN-02: En Informática, ¿cuáles asignaturas concentran la mayor reprobación?	Desglose desde DimCurso[Escuela] hacia DimCurso[NombreAsignatura].
Slice	PN-06: ¿Qué porcentaje de estudiantes con beca logran promedio aprobatorio?	Corte fijo sobre DimEstudiante[Tiene_Beca = 'Sí'].
Dice	PN-03 y PN-08: ¿Cuántos estudiantes trabajadores (> 20 hrs) están en riesgo crítico en M1?	Cruce simultáneo: DimPerfilSocioec[Horas > 20] x DimEtapa[M1] x DimResultado[Riesgo Crítico].
Pivot	PN-04: Comparar la distribución de clústeres de riesgo frente a las 4 escuelas.	Eje filas: DimPerfilSocioec[Cluster_KMeans]; Eje columnas: DimCurso[Escuela].

2.7. Indicadores de Gestión y KPIs Institucionales

2.7.1. Fundamentación Conceptual:

Un KPI institucional es una medida cuantitativa formalmente vinculada a los objetivos estratégicos de permanencia y calidad universitaria, dotada de fórmula matemática, meta cuantitativa, semaforización y responsable en la matriz de gestión (Martín-Caro Álamo & Segovia-García, 2025; Ochoa Cedeño et al., 2024).

2.7.2. Fichas Técnicas de los 8 KPIs Oficiales del Sistema:

Tabla 14

Catálogo de Indicadores Clave de Rendimiento (KPIs) del Sistema

Código y Nombre de KPI	**Fórmula Matemática Formal**	**Meta y Umbral de Semáforo**	**Responsable RACI**
KPI-01: Tasa de Abandono Histórico (TA)	TA = (Estudiantes Dropout / Total Matriculados) * 100	<= 18.0% (Verde <= 18% | Amarillo 18.1%-25% | Rojo > 25%)	Director de Escuela Profesional
KPI-02: Ratio de Eficiencia Crediticia (REC)	REC = (Suma Creditos Aprobados / Suma Creditos Matriculados) * 100	>= 85.0% (Verde >= 85% | Amarillo 70%-84.9% | Rojo < 70%)	Comité de Tutoría y Consejería
KPI-03: Rendimiento Vigesimal Promedio (RVP)	RVP = Suma(Nota Vigesimal [0-20] * Creditos) / Total Creditos Evaluados	>= 13.5 pts (Verde >= 13.5 | Amarillo 11.0-13.4 | Rojo < 11.0)	Docentes Tutores y Directores
KPI-04: Índice de Riesgo Crítico por IA (IRC)	IRC = Conteo de estudiantes con P(Dropout) >= 0.60	<= 15.0% del total de la matrícula activa	Comité de Tutoría / Plataforma BI+IA
KPI-05: Recall en Detección de Dropout	Recall = VP_Dropout / (VP_Dropout + FN_Dropout)	>= 75.0% en M1 (Ingreso) y >= 82.0% en M2 (Cierre S1)	Equipo de Ingeniería de Datos y ML
KPI-06: Cobertura Tutorial a Críticos (CAT)	CAT = (Estudiantes Críticos con Tutor / Total Estudiantes Críticos) * 100	100.0% (Verde 100% | Amarillo 80%-99% | Rojo < 80%)	Coordinador de Tutoría FIEI
KPI-07: Cohesión de Perfiles (Silhouette)	s(i) = (b(i) - a(i)) / max(a(i), b(i)); media s_bar	s_bar >= 0.35 (Estructura de clustering sustancial)	Módulo de Personalización Python
KPI-08: Retención Simulada What-If (EPR)	EPR = Suma[P(Dropout) >= U] * Cobertura_Tutor * Efectividad_Intervención	Maximizar estudiantes retenidos bajo presupuesto	Decanato FIEI y Comité de Calidad

2.8. Machine Learning e Inteligencia Artificial Educativa

2.8.1. Fundamentación Conceptual:

La Minería de Datos Educativa y la Analítica del Aprendizaje contemporánea extraen patrones ocultos en la trayectoria estudiantil (Ali, 2026; Almalawi et al., 2026). El problema institucional no es predecir una nota continua marginal (regresión lineal), sino clasificar al

estudiante en un estado de riesgo accionable (Dropout, Enrolled, Graduate), formulándose rigurosamente como Clasificación Supervisada Multiclase.

Comparación de Algoritmos: La literatura empírica universitaria reciente respalda la comparación técnica de dos familias algorítmicas (Aparicio-Montenegro et al., 2026; Realinho et al., 2022; Aco Tito et al., 2023; Contreras-Bravo et al., 2022; Torres et al., 2023):

(1) Regresión Logística Multinomial como modelo lineal paramétrico de referencia por su rapidez e interpretabilidad probabilística

(2) Random Forest Classifier como ensamble no lineal que promedia árboles de decisión independientes mediante Bagging, capturando interacciones multivariables complejas sin sobreajustar. Para la segmentación no supervisada se utiliza K-Means Clustering.

2.8.2. Protocolo de Validación, Desbalance y Métrica Prioritaria:

• Desbalance de Clases: La deserción es una clase minoritaria; la Exactitud (Accuracy) resulta engañosa en estos contextos.
• Métrica Prioritaria de Negocio: Recall de la clase Dropout. En retención universitaria, el costo de un Falso Negativo (un alumno que desertará y no es advertido) es crítico, provocando el abandono definitivo. En contraste, el costo de un Falso Positivo (citar preventivamente a un alumno que no iba a desertar) es pedagógicamente inocuo. Por ello, la prioridad de ingeniería es maximizar el Recall de Dropout manteniendo un F1-macro equilibrado.
• Blindaje contra Fuga de Datos (Data Leakage): Ninguna variable posterior a la etapa evaluada ni el target final ingresan como predictores en M1 o M2.
• Validación Cruzada y Dashboard Completo: Se utiliza Stratified K-Fold (k=5). Las probabilidades de toda la cohorte (4,424 casos) se calculan mediante predicciones fuera de muestra (out-of-fold), asegurando que el tablero en Power BI muestre a toda la población sin violar la integridad estadística.

2.9. Evaluación Adaptativa, Analítica del Aprendizaje y Personalización

2.9.1. Fundamentación Conceptual y Delimitación Operativa:

La literatura técnica contemporánea en analítica formativa destaca la efectividad de los sistemas de evaluación adaptativa y prescripción temprana basados en cohortes longitudinales

(Almalawi et al., 2026; Hidayat et al., 2026). Ante la naturaleza del proyecto, se formalizan las Definiciones Operativas:

> *"Evaluación Adaptativa (Decisión D2): Proceso analítico dinámico de re-evaluación del riesgo académico ejecutado en etapas sucesivas (M1 Ingreso vs. M2 Cierre de Primer Semestre), ajustando el pronóstico conforme se consolida el rendimiento real del alumno."*
>
> *"Personalización del Aprendizaje (Decisión D3): Segmentación de la población estudiantil en perfiles multidimensionales homogéneos mediante clustering no supervisado (K-Means), articulada con una matriz institucional de recomendaciones pedagógicas y tutoriales diferenciadas por nivel de riesgo."*

2.9.2. Matriz de Personalización según Clúster Socioacadémico

Tabla 15

Matriz de Prescripción de Intervenciones Tutoriales según Clúster

Clúster Identificado	**Rasgos Socioacadémicos Clave**	**Diagnóstico Causal**	**Prescripción Tutorial Personalizada**
Clúster 1: Vulnerabilidad Socioeconómica	Bajos ingresos familiares, padres sin educación superior, condición deudora.	Vulnerabilidad económica de sostenimiento.	Priorización en Beca Comedor, carné universitario de medio pasaje, asistencia de Bienestar y subsidio de útiles.
Clúster 2: Sobrecarga Laboral	Jornada laboral > 20 horas semanales, mayor edad promedio, menor presencialidad.	Incompatibilidad de tiempo estudio-trabajo.	Reorientación de matrícula balanceada (reducción a 16 créditos), acceso a clases grabadas y tutoría nocturna asincrónica.
Clúster 3: Rezago en Ciencias Básicas	Adecuado respaldo socioeconómico pero notas bajas en Cálculo, Álgebra y Física.	Déficit de competencias en ciencias básicas.	Asignación obligatoria a talleres de nivelación intensiva en matemáticas y emparejamiento con tutores de pares de ciclos superiores.

Consideraciones Éticas y Privacidad:

(1) Las alertas se presentan como indicadores de necesidad de apoyo, erradicando cualquier uso discriminatorio o punitivo

(2) Se aplica anonimización de identificadores y supresión de celdas con frecuencias menores a 5 ($k >= 5$) protegiendo la identidad del estudiante bajo la Ley N.° 29733.

2.10. Procesos ETL y Calidad de Datos (Visual Studio SSIS)

2.10.1. Fundamentación Conceptual:

Los pipelines de Extracción, Transformación y Carga (ETL) constituyen el componente neurálgico para garantizar la consistencia, integridad y limpieza de los datos que alimentan el DataMart (Salazar Alberto et al., 2024; Realinho et al., 2022). En Visual Studio SSIS se combinan tareas de Control Flow (orquestación, transacciones y ejecución de scripts Python) y tareas de Data Flow (transformaciones en memoria y carga masiva a SQL Server).

2.10.2. Catálogo de Reglas de Calidad Implementadas en SSIS:

Tabla 16

Catálogo de Reglas de Calidad y Transformación en SSIS

N° Regla	Nombre de Regla de Calidad	Problema de Origen Detectado	Tratamiento Técnico en SSIS	Artefacto Destino
RC-01	Estandarización de Codificación	Caracteres especiales (tildes/ñ) en UTF-8 vs ANSI.	Configurar CodePage = 1252 (ANSI - Latino) en Flat File Connection Manager.	Paquetes de Staging SSIS.
RC-02	Normalización Vigesimal	Notas UCI en escala portuguesa (0 a 20 con 10 aprobatorio).	Validar consistencia con escala peruana UNFV (0 a 20 con 11 aprobatorio). Campo flag es_aprobado.	dw.FactProgreso.
RC-03	Tratamiento de Calificación Cero	Notas = 0 con 0 evaluaciones rendidas sesgan promedios.	Derivación condicional: tipificar como 'No se presentó / Abandono no formal' si eval = 0.	Columna Derivada SSIS.
RC-04	Miembro Desconocido (-1)	Valores nulos o claves foráneas huérfanas en dimensiones.	Crear fila clave -1 ('No Especificado' / 'Desconocido') en cada dimensión conformada.	Dimensiones dw.
RC-05	Dimensiones de Cambio Lento	Evolución de condición laboral o beca durante el semestre.	Implementar SCD Tipo 1 (Sobrescribir) y Tipo 2 (Versionamiento con fechas de vigencia).	Componente SCD en SSIS.
RC-06	Conciliación de Cargas	Pérdida silenciosa de registros por errores de casteo.	Control de balance en audit.Auditoria_Carga: Filas Origen = Filas Insertadas + Filas Rechazadas.	audit.Auditoria_Carga.

Referencias Bibliográficas

Aco Tito, A. E., Hancco Condori, B. O., & Pérez Vera, Y. (2023). Análisis comparativo de Técnicas de Machine Learning para la predicción de casos de deserción universitaria. RISTI - Revista Ibérica de Sistemas e Tecnologias de Informação, 51, 84–98. https://doi.org/10.17013/risti.51.84-98

Ali, G. M. (2026). An explainable AI framework for multimodal student performance prediction and institutional decision support at PSAU. Decision Science Letters, 15(6), 995–1012. https://doi.org/10.5267/j.dsl.2026.8.010

Almalawi, A., Soh, B., Li, A., Alanazi, A., & Samra, H. (2026). An exploratory feasibility study of adaptive assessment: a multivariate, data-driven approach to formative evaluation. Frontiers in Education, 11, Article 1849701. https://doi.org/10.3389/feduc.2026.1849701

Angulo Quiñonez, A. Á. (2022). La autoestima, su relación con el rendimiento académico y la deserción universitaria. Sapienza: International Journal of Interdisciplinary Studies, 3(6), 514–529. https://doi.org/10.51798/sijis.v3i6.514

Aparicio-Montenegro, P., Esparza Silva, M. R., Huapaya Sotero, A., Garcia-Alvarez, M. Y., & De La Cruz Garcia, A. (2026). Predictive model based on machine learning for the early identification of student dropout in a public university. Proceedings of the 24th LACCEI International Multi-Conference for Engineering, Education, and Technology, 1–10. https://doi.org/10.18687/LACCEI2026.1.1.721

Barrera-Liévano, J. A., Barrera-Liévano, D. C., Beltrán-Virgüez, J. E., & Castillo-Sánchez, M. (2025). Correlación entre variables de deserción universitaria en programas en modalidad a distancia en Colombia. Estudios Pedagógicos, 51(2), 161–175. https://doi.org/10.4067/S0718-07052025000200161

Castro-Martínez, J. A., & Machuca-Téllez, G. (2023). La deserción universitaria en América Latina: una perspectiva ecológica. Estudios Pedagógicos, 49(2), 87–108. https://doi.org/10.4067/S0718-07052023000200087

Contreras-Bravo, L. E., Nieves-Pimiento, N., & Fuentes-Contreras, J. A. (2022). Predicción del Rendimiento Académico a Nivel Universitario Mediante Mecanismos de Machine Learning y Métodos Supervisados. Ingeniería, 27(3), Article e19514. https://doi.org/10.14483/23448393.19514

González, J. A., Carvajal, C. M., Rebolledo, R. A., & González, F. A. (2024). Grado de logro de la competencia digital (GLCD) en relación a la deserción de estudiantes universitarios. Formación Universitaria, 17(3), 153–166. https://doi.org/10.4067/S0718-50062024000300153

Hidayat, N., Afuan, L., & Jannah, H. R. (2026). Prescriptive Learning Analytics for Student Dropout: Integrating Temporal Velocity and Counterfactual Explanations in Longitudinal Data. Journal of Computing Theories and Applications, 3(1), Article 15920. https://doi.org/10.62411/jcta.15920

Martín-Caro Álamo, E., & Segovia-García, N. (2025). Analítica de Aprendizaje y Retención Estudiantil: un Estudio Longitudinal en Educación Superior Virtual. Revista Fuentes, 27(1), 1–12. https://doi.org/10.12795/revistafuentes.2025.27592

Navarro Peñaranda, J. A., Pérez Castro, J. D., & Rodríguez Rojas, L. A. (2025). Determinants of University Dropout: A Study in the Engineering Faculty of a Public University in Colombia. Proceedings of the 23rd LACCEI International Multi-Conference for Engineering, Education, and Technology, 1–8. https://doi.org/10.18687/LACCEI2025.1.1.2431

Ochoa Cedeño, E. G., Rodríguez Magaña, A., & García Bejar, L. (2024). Implementación y Evaluación del Programa de Mejora Académica en una Universidad Privada del Occidente de México. European Public & Social Innovation Review, 9(1), 45–65. https://doi.org/10.31637/epsir-2024-555

Parra-Sánchez, J. S., Torres Pardo, I. D., & Martínez de Merino, C. Y. (2023). Factores explicativos de la deserción universitaria abordados mediante inteligencia artificial. Revista Electrónica de Investigación Educativa (REDIE), 25, Article e18. https://doi.org/10.24320/REDIE.2023.25.E18.4455

Realinho, V., Machado, J., Baptista, L., & Martins, M. V. (2022). Predicting Student Dropout and Academic Success. Data, 7(11), Article 146. https://doi.org/10.3390/data7110146

Romero-Tenorio, J.-M., Riccardi, D., & de Yzaguirre, F. (2026). Teatro del oprimido y sociograma. Acción colectiva contra la deserción universitaria. Revista Iberoamericana de Educación Superior, 17(49), 112–131. https://doi.org/10.22201/iisue.20072872e.2026.49.1985

Salazar Alberto, R. A., Guzman Aquije, E. H., & Lozada Flores, R. M. (2024). Application of artificial intelligence to predict academic performance in order to prevent dropout in high school students: Systematic Literature Review. Proceedings of the 22nd LACCEI International Multi-Conference for Engineering, Education, and Technology, 1–8. https://doi.org/10.18687/LACCEI2024.1.1.1426

Schmidt, B. J. (2023). Factores que influyen en la deserción universitaria: El caso de una universidad estatal chilena. Revista Portuguesa de Educação, 36(1), Article e23002. https://doi.org/10.21814/rpe.23401

Torres, H. V., et al. (2023). Modelo de clasificación para la deserción estudiantil en una universidad pública del Perú. Salud, Ciencia y Tecnología - Serie de Conferencias, 2(2), Article 175. https://doi.org/10.56294/sctconf2023175

Vega Velásquez, M., Bastardo Contreras, X., & Giraldo de López, M. (2025). Factores Socioemocionales y Deserción Universitaria. Análisis correlacional en grupos desertores en los años 2021 y 2022. European Public & Social Innovation Review, 10(1), 1–14. https://doi.org/10.31637/epsir-2025-1173