UNIVERSIDAD NACIONAL FEDERICO VILLARREAL

FACULTAD DE INGENIERÍA ELECTRÓNICA E INFORMÁTICA

Escuelas Profesionales de Ingeniería Informática, Electrónica, Mecatrónica y Telecomunicaciones

SISTEMA INTELIGENTE DE EVALUACIÓN ADAPTATIVA Y PERSONALIZACIÓN DEL APRENDIZAJE UNIVERSITARIO

Plataforma Integral de Business Intelligence y Machine Learning basada en DataMart Multidimensional, Pipelines SSIS, Cubos OLAP y Modelos Predictivos para la Gestión de Retención Académica en UNFV-FIEI

INFORME ACADÉMICO – PRIMER ENTREGABLE

Introducción, Capítulo I (Generalidades) y Capítulo II (Marco Teórico y Aplicación)

Asignatura: Gestión y Análisis de Datos e Información (GADI) – Ciclo 2026

Docente: Mg. Ing. Ivan Crispin Sanchez

Equipo de Investigación y Desarrollo – FIEI UNFV

Lima, Perú

2026

Índice General

INTRODUCCIÓN **3**
1. Presentación del Proyecto y Contexto **3**
2. Definición y Diagnóstico del Problema de Negocio **3**
3. Árbol de Problemas: Causas, Problema Central y Efectos **4**
4. Importancia de la Solución y Justificación por Actores **5**
5. Alcance General del Proyecto y Limitaciones Metodológicas **6**
CAPÍTULO I: GENERALIDADES DE LA ORGANIZACIÓN **8**
1.1. Descripción de la Empresa u Organización (UNFV - FIEI) **8**
1.2. Historia, Misión, Visión y Valores Institucionales **8**
1.3. Organización y Organigrama Funcional **10**
1.4. Área Involucrada y Matriz de Responsabilidades (RACI) **10**
1.5. Descripción del Proceso Actual (AS-IS) de Seguimiento Académico **11**
1.6. Diagrama del Proceso Actual (AS-IS) y Catálogo de Dolores **12**
1.7. Propuesta del Proceso Futuro (TO-BE) Optimizado con BI + IA **12**
1.8. Matriz Comparativa Exhaustiva: Proceso AS-IS vs. Proceso TO-BE **13**
CAPÍTULO II: MARCO TEÓRICO Y APLICACIÓN DE INGENIERÍA **15**
2.0. Antecedentes de la Investigación **15**
2.1. Inteligencia de Negocios (Business Intelligence) **17**
2.2. Data Warehouse y DataMart (Metodología Kimball) **18**
2.3. Modelos Dimensionales y Matriz Bus de Kimball **19**
2.4. Datos, Información y Conocimiento (Pirámide DIKW) **20**
2.5. Dimensiones, Medidas, Jerarquías y Granularidad **21**
2.6. Cubos OLAP y Procesamiento Multidimensional (SSAS) **22**
2.7. Indicadores de Gestión y KPIs Institucionales **23**
2.8. Machine Learning e Inteligencia Artificial Educativa **24**
2.9. Evaluación Adaptativa, Analítica del Aprendizaje y Personalización **25**
2.10. Procesos ETL y Calidad de Datos (Visual Studio SSIS) **27**
REFERENCIAS BIBLIOGRÁFICAS OFICIALES (APA 7MA EDICIÓN) **29**

Introducción

1. Presentación del Proyecto

El presente proyecto diseña e implementa una plataforma integral de Business Intelligence (BI) y Machine Learning (ML) concebida para transformar la gestión del seguimiento académico y la retención estudiantil en la Universidad Nacional Federico Villarreal (UNFV), focalizando su aplicación piloto en la Facultad de Ingeniería Electrónica e Informática (FIEI). La arquitectura tecnológica articula un DataMart relacional en Microsoft SQL Server bajo metodología dimensional de Ralph Kimball, pipelines automatizados de Extracción, Transformación y Carga (ETL) en Visual Studio SQL Server Integration Services (SSIS), cubos multidimensionales OLAP en SQL Server Analysis Services (SSAS), modelos predictivos de aprendizaje automático en Python (Scikit-Learn) y paneles interactivos de control en Microsoft Power BI Desktop con simulación de escenarios What-If.

La plataforma está orientada a resolver una limitación estructural recurrente en las universidades públicas peruanas: la detección tardía e inconexa de los estudiantes en riesgo de abandono. Frente a los modelos tradicionales que constatan el fracaso escolar cuando los exámenes parciales ya han concluido, esta solución implementa un mecanismo preventivo de doble impacto: evaluación adaptativa en dos momentos cronológicos estratégicos (ingreso vs. primer semestre) y personalización del acompañamiento tutorial a través de segmentación no supervisada por clústeres socioacadémicos.

2. Problema Identificado y Contexto Empírico

La deserción en la educación superior universitaria peruana representa una problemática crítica con graves consecuencias sociales, académicas e institucionales. De acuerdo con estadísticas del Ministerio de Educación (MINEDU) y el Sistema de Información Universitaria (TUNI) de la Superintendencia Nacional de Educación Superior Universitaria (SUNEDU, 2024), la tasa nacional de deserción acumulada en pregrado oscila entre el 12% y 18% en el primer año académico. Esta cifra se agrava sustancialmente en las facultades de ingeniería y ciencias exactas, donde la reprobación masiva en asignaturas troncales (Cálculo, Física y Álgebra) desencadena el desánimo vocacional y el abandono voluntario.

A nivel del entorno laboral y socioeconómico de los estudiantes, el procesamiento de los microdatos de la Encuesta Nacional de Hogares (INEI ENAHO 2023, Módulos 300 de Educación y 500 de Empleo, aplicando el filtro P308A=5 de educación superior universitaria y el factor de expansión FAC500A) revela que el 44.0% de los jóvenes universitarios peruanos trabaja de forma simultánea a sus estudios, dedicando en promedio 34.7 horas semanales a su jornada laboral. Esta sobrecarga laboral compite directamente con el tiempo de estudio presencial y autónomo, incrementando la vulnerabilidad académica si no es detectada oportunamente.

Como base empírica de referencia y validación técnica de algoritmos (prueba de concepto analítica, ante la reserva de datos protegidos por la Ley N.° 29733 de Protección de Datos Personales), se utiliza el benchmark abierto del Machine Learning Repository de la Universidad de California en Irvine (UCI - Predict Students' Dropout and Academic Success, Realinho et al., 2022). Este conjunto de datos comprende 4,424 registros de matrícula, 37 atributos socioeconómicos y académicos normalizados en escala vigesimal (0 a 20) y nota de admisión (0 a 200), y una distribución observada de condición de graduación (49.9%), abandono o dropout (32.1%) y matrícula activa continua (17.9%).

3. Árbol de Problemas Institucional

Para formalizar la relación entre causas y efectos en la gestión académica actual, se estructura el siguiente diagnóstico:

a) Efectos Finales:

Pérdida de gratuidad de la enseñanza universitaria (mandato del Artículo 99 de la Ley Universitaria N.° 30220 al acumular asignaturas desaprobadas), rezago curricular crónico, baja tasa de graduación oportuna y frustración vocacional en las escuelas de ingeniería.

b) Problema Central:

Alta tasa de deserción no advertida y pérdida de rendimiento en estudiantes de primeros ciclos en la FIEI-UNFV, debido a la ausencia de un sistema automatizado de alerta temprana e intervención tutorial personalizada.

c) Causas Raíz Identificadas:

1. Latencia informacional de 8 a 10 semanas para consolidar notas de exámenes parciales en la intranet.
2. Silos de datos: las calificaciones de prácticas intermedias permanecen en hojas de cálculo aisladas en computadoras docentes.
3. Diagnóstico reactivo post-mortem basado en promedios aritméticos simples (< 10.5) sin análisis predictivo multivariable.
4. Intervenciones tutoriales genéricas y tardías que no discriminan la causa raíz (económica, laboral o matemática).

4. Importancia de la Solución y Beneficios por Actor

La implementación de este sistema de Inteligencia de Negocios e Inteligencia Artificial genera impactos positivos medibles en los cuatro niveles de gestión de la facultad:

Tabla 1

Matriz de Beneficios Institucionales por Actor Clave

Actor Institucional	Rol en el Proceso	Beneficio Concreto del Sistema	Componente Asociado
Director de Escuela	Aprobador Estratégico	Visibilidad ejecutiva de tasas de deserción y rendimiento por asignatura en tiempo real; simulación de retención institucional.	Dashboard Power BI (Páginas 1 y 4) y Cubo SSAS.
Comité de Tutoría	Gestor Operativo	Semáforo predictivo priorizado de riesgo por estudiante; emisión de alertas preventivas en semana 2 sin esperar al examen parcial.	Módulo de ML en Python y Dashboard Power BI (Página 2).
Docente Tutor	Interventor Pedagógico	Ficha integral del estudiante con diagnóstico del perfil (Clúster) y recomendación precisa de la acción de rescate requerida.	Matriz de Recomendación y Ficha Individual Power BI.
Estudiante FIEI	Beneficiario Directo	Acompañamiento tutorial oportuno antes de la pérdida de gratuidad; nivelación en ciencias básicas o becas de bienestar.	Acciones Prescritas del Proceso TO-BE.

Nota. Fuente: Elaboración propia basada en el diseño metodológico e institucional del proyecto.

5. Delimitación y Alcance del Proyecto

A fin de asegurar el rigor metodológico y concentrar los esfuerzos en la ingeniería de datos y analítica predictiva exigidas por la cátedra, se establecen las siguientes delimitaciones operativas:

Tabla 2

Matriz de Alcance: Componentes Incluidos vs. Excluidos

Dimensión / Componente	Incluido en el Alcance (In-Scope)	Excluido del Alcance (Out-of-Scope)	Justificación Metodológica
Canal de Visualización	Paneles analíticos e interactivos en Power BI Desktop con parámetros What-If.	Desarrollo de portales web full-stack, aplicaciones móviles o microservicios.	El curso evalúa BI y Data Engineering; programar interfaces web dispersa el tiempo sin aportar puntaje en la rúbrica.
Evaluación Pedagógica	Evaluación adaptativa por hitos cronológicos (M1 Ingreso vs. M2 Fin Semestre 1).	Tests adaptativos computarizados (CAT) reactivo por reactivo bajo Teoría de Respuesta al Ítem.	No existen datos de interacción ítem a ítem; forzarlo destruiría la trazabilidad del DataMart relacional.
Integración de Datos	Articulación conceptual y agregada por escuela y departamento entre UCI, TUNI y ENAHO.	Cruce forzado estudiante a estudiante con identificadores ficticios entre UCI y ENAHO.	Falacia de datos ('Frankenstein'). Se respeta la integridad y granularidad de cada fuente primaria.
Población del Tablero	Cálculo de probabilidad continua de riesgo para el 100% de la matrícula (4,424 estudiantes).	Limitación a solo el subconjunto de prueba (test split del 20%).	El cuadro de mando de tutoría exige visibilidad total de toda la cohorte matriculada para gestionar rescates.
Simulación What-If	Modelado interactivo de capacidad tutorial variando umbral de riesgo y cobertura institucional.	Garantía de reducción causal absoluta de deserción sin validación de campo.	Rigor científico: el What-If modela supuestos de capacidad de gestión institucional, no efectos causales directos.

Nota. Fuente: Elaboración propia basada en el diseño metodológico e institucional del proyecto.

Capítulo I: Generalidades de la Organización

1.1. Descripción de la Empresa u Organización

La entidad marco del presente estudio es la Universidad Nacional Federico Villarreal (UNFV), institución pública autónoma de educación superior universitaria del Estado Peruano, focalizando la implementación piloto en su Facultad de Ingeniería Electrónica e Informática (FIEI).

La UNFV ostenta Licenciamiento Institucional otorgado por la Superintendencia Nacional de Educación Superior Universitaria (SUNEDU) mediante Resolución del Consejo Directivo N° 035-2019-SUNEDU/CD, expedida el 11 de marzo de 2019, la cual acreditó el cumplimiento riguroso de las Condiciones Básicas de Calidad (CBC) exigidas por la Ley Universitaria N° 30220.

La FIEI concentra la formación tecnológica y científica de vanguardia de la universidad en su sede de Breña (Jr. Iquique N° 127), albergando una población superior a los 2,200 estudiantes de pregrado distribuidos en sus cuatro escuelas profesionales: Escuela Profesional de Ingeniería Informática, Escuela Profesional de Ingeniería Electrónica, Escuela Profesional de Ingeniería Mecatrónica y Escuela Profesional de Ingeniería de Telecomunicaciones. El régimen académico es semestral, con 16 semanas lectivas por ciclo y escala de calificación vigesimal oficial (0 a 20).

1.2. Historia, Misión, Visión y Valores Institucionales

1.2.1. Reseña Histórica Oficial:

La Universidad Nacional Federico Villarreal fue creada mediante la Ley N.° 14692, promulgada el 30 de octubre de 1963 (verificada estrictamente en el Diario Oficial El Peruano), naciendo sobre la base de la filial en Lima de la Universidad Comunal del Centro del Perú. Nombrada en memoria del insigne sabio, matemático, físico e ingeniero peruano Federico Villarreal, la universidad ha cumplido más de seis décadas formando profesionales. La FIEI se constituyó como unidad académica autónoma orientada a liderar la investigación, el desarrollo tecnológico y la analítica computacional.

1.2.2. Misión Institucional (Estatuto y PEI UNFV Vigente):

"Formar profesionales e investigadores competitivos, con sólidos valores éticos, humanísticos, científicos y tecnológicos, comprometidos con el desarrollo sostenible del país." **(Estatuto UNFV, Art. 7)**

1.2.3. Visión Institucional (Estatuto y PEI UNFV Vigente):

"Ser una universidad pública licenciada y acreditada internacionalmente, líder en la formación integral de excelencia e investigación innovadora de alto impacto social." **(PEI UNFV 2022-2026)**

1.2.4. Valores Institucionales:

• Rigor Científico y Excelencia Académica: Compromiso con la exactitud metodológica, la ingeniería de datos y la veracidad de los modelos analíticos.
• Ética e Integridad: Transparencia en la gestión informacional, auditoría de procesos y respeto irrestricto a la privacidad de los datos estudiantiles.
• Responsabilidad Social y Equidad: Orientación de las políticas institucionales a la protección de los sectores estudiantiles vulnerables y prevención del rezago.
• Innovación Continua: Adopción proactiva de arquitecturas de Business Intelligence y algoritmos de Machine Learning para modernizar la gestión pública universitaria.

Tabla 3

Alineamiento Estratégico entre la Filosofía UNFV y la Plataforma Analítica

Eje Estratégico UNFV	Compromiso Institucional Declarado	Alineamiento y Cumplimiento del Proyecto de BI + IA
Misión: Formación Profesional Competitiva	Garantizar la culminación oportuna de los planes de estudio y evitar la deserción.	El sistema alerta tempranamente el rezago en asignaturas troncales de ingeniería, asegurando la continuidad formativa.
Visión: Excelencia y Acreditación	Cumplimiento permanente de estándares de retención y calidad educativa universitaria.	Provee métricas de retención objetivas y auditables que sustentan auditorías de SUNEDU y modelos de acreditación SINEACE.
Valores: Equidad y Responsabilidad	Evitar que barreras socioeconómicas y laborales trunquen la vocación universitaria.	Segmenta a los estudiantes según horas de trabajo y condición económica para priorizar becas y tutorías diferenciadas.

Nota. Fuente: Elaboración propia basada en el diseño metodológico e institucional del proyecto.

1.3. Estructura Organizativa y Organigrama Funcional

La gobernanza del seguimiento académico en la FIEI-UNFV se articula a través de una línea jerárquica y funcional clara: Rectorado -> Vicerrectorado Académico (VRAC) -> Decanato de la FIEI -> Direcciones de Escuela Profesional (Informática, Electrónica, Mecatrónica, Telecomunicaciones), articuladas transversalmente con el Comité de Tutoría y Consejería Universitaria de la facultad y la Dirección de Bienestar Universitario. Esta estructura determina los carriles (Lanes) y usuarios de los tableros analíticos.

1.4. Área Involucrada y Matriz de Responsabilidades (RACI)

El seguimiento del estudiante involucra a dependencias académicas, tutoriales y de apoyo bajo el mandato formal de los Artículos 126 (Tutoría Universitaria) y 128 (Servicios de Bienestar) de la Ley Universitaria N° 30220. Se formaliza la matriz RACI del proceso:

Tabla 4

Matriz RACI del Proceso de Seguimiento Académico y Retención

Actividad / Proceso Analítico	Director Escuela	Comité Tutoría	Docente Tutor	Bienestar Univ.	Plataforma BI+IA
1. Consolidación de datos de matrícula y notas (ETL)	I	I	I	I	R / A
2. Emisión y monitoreo del semáforo de riesgo predictivo	A	R	C	I	R
3. Asignación de estudiantes críticos a tutores de escuela	A	R	I	C	Soporte
4. Ejecución de sesiones tutoriales y talleres de nivelación	I	A	R	C	Soporte
5. Asignación de becas comedor y ayudas de bienestar	I	C	C	R / A	Soporte
6. Evaluación global de KPIs y simulación de retención What-If	R / A	C	I	I	Soporte

Nota. Fuente: Elaboración propia basada en el diseño metodológico e institucional del proyecto.

Leyenda RACI: R = Responsable de la ejecución; A = Aprobador final / Dueño de la decisión; C = Consultado para criterio experto; I = Informado de los resultados.

1.5. Descripción del Proceso Actual (AS-IS)

En el régimen operativo actual de la FIEI-UNFV, el seguimiento del rendimiento se ejecuta de forma desarticulada, manual y predominantemente reactiva. A lo largo del ciclo regular de 16 semanas, el flujo se desenvuelve de la siguiente forma:

Tabla 5

Desglose de Actividades del Proceso Tradicional (AS-IS)

N°	Actividad Operativa	Actor	Semana	Salida / Artefacto	Cuello de Botella y Problema Detectado
1	Matrícula regular	Estudiante	Sem. 0	Ficha de matrícula	Solo registra cursos; no captura situación laboral ni horas de trabajo.
2	Desarrollo de clases y prácticas	Docente	Sem. 1-7	Excel personal	Las notas parciales quedan aisladas en laptops de profesores; cero visibilidad.
3	Exámenes parciales	Docente/Alumno	Sem. 8	Exámenes físicos	Primer hito formal; el estudiante ya acumula 2 meses de rezago no detectado.
4	Carga oficial a intranet	Docente	Sem. 9-10	Acta digital	Latencia crítica: frecuentes retrasos en la digitación institucional de notas.
5	Revisión manual de notas	Comité Tutoría	Sem. 10-11	Lista en papel	Diagnóstico post-mortem: filtrado manual de promedios < 10.5 sin análisis multivariable.
6	Citación a tutoría	Docente Tutor	Sem. 11-12	Sesión de tutoría	Acción tardía: el alumno llega con notas de 04 a 07 prácticamente irrecuperables.
7	Exámenes finales y actas	Docente	Sem. 16	Acta final	Consumación del fracaso académico, repitencia o

N°	Actividad Operativa	Actor	Semana	Salida / Artefacto	Cuello de Botella y Problema Detectado
					matrícula condicionada.

Nota. Fuente: Elaboración propia basada en el diseño metodológico e institucional del proyecto.

1.6. Diagrama AS-IS y Catálogo de Dolores de Gestión

El modelado BPMN 2.0 del proceso AS-IS estructurado en tres carriles (Estudiante, Docente de Asignatura y Comité de Tutoría) evidencia cuatro puntos críticos de dolor que motivan la solución:

• DOLOR 1 (Silos de Información): Las notas de evaluaciones continuas se almacenan en archivos Excel personales de los docentes, desconectados de las bases centrales. La facultad permanece a oscuras respecto al desempeño durante las primeras 7 semanas de clases.

• DOLOR 2 (Latencia Informacional Crítica): Retraso de 9 a 10 semanas desde el inicio del semestre para que las autoridades y tutores dispongan de calificaciones consolidadas en el sistema oficial.

• DOLOR 3 (Detección Reactiva 'Post-Mortem'): La identificación de estudiantes en riesgo se efectúa manualmente revisando promedios aritméticos simples (< 10.5) cuando el estudiante ya reprobó el examen parcial.

• DOLOR 4 (Intervención Uniforme e Ineficaz): La citación a tutoría se emite de manera genérica en las semanas 11 y 12, sin identificar si el origen del rezago es socioeconómico, laboral o de base matemática, y sin margen temporal para revertir la reprobación.

1.7. Propuesta del Proceso Futuro (TO-BE) Optimizado con BI + IA

El proceso propuesto TO-BE rediseña radicalmente la dinámica operativa mediante la incorporación de un carril automatizado: la Plataforma BI + IA. El flujo se transforma en un ciclo proactivo y adaptativo estructurado en 4 carriles:

1. Carril Estudiante: Completa la matrícula regular y la ficha socioacadémica digital en semana 0; cursa asignaturas con soporte continuo y participa activamente en el plan de tutoría/nivelación prescrito a su medida.
2. Carril Docente de Asignatura: Carga notas de evaluación continua periódicamente en la

plataforma institucional unificada, erradicando los silos locales.
3. Carril Plataforma BI + IA: Ejecuta pipelines ETL automatizados en Visual Studio SSIS hacia el DataMart SQL Server; calcula la probabilidad de riesgo de abandono en el Momento 1 (Admisión - Semana 2) mediante Python Scikit-Learn; segmenta perfiles mediante K-Means Clustering; re-evalúa el riesgo adaptativamente en el Momento 2 (Cierre de Semestre 1 con notas reales); y actualiza el cubo SSAS y tableros Power BI.
4. Carril Comité de Tutoría y Bienestar: Monitorea el semáforo predictivo de riesgo en Power BI; evalúa estudiantes con P(Dropout) >= 60%; prescribe intervenciones personalizadas mediante la matriz de reglas de negocio; y ejecuta sesiones de tutoría oportuna y asignación de becas de bienestar.

1.8. Matriz Comparativa Exhaustiva: Proceso AS-IS vs. Proceso TO-BE

A continuación, se sintetiza la transformación cualitativa y cuantitativa entre ambos modelos:

Tabla 6

Matriz Comparativa de Transformación: Proceso AS-IS vs. Proceso TO-BE

Dimensión Analítica	Situación Actual (AS-IS)	Situación Propuesta (TO-BE)	Componente Tecnológico	KPI Asociado de Impacto
Tiempo de Detección	Semanas 9 a 11: Detección reactiva tras digitar notas de exámenes parciales.	Semanas 2 a 4 (M1): Diagnóstico preventivo al ingreso y re-evaluación en M2.	Pipeline SSIS + Python ML	Tiempo de detección <= 4 semanas; Recall >= 75%.
Integración de Datos	Archivos Excel dispersos en computadoras personales de los docentes.	DataMart Centralizado en SQL Server: trayectoria, catálogo y contexto ENAHO.	DataMart dimensional (dw)	100% de fuentes integradas; 0 duplicados.
Criterio de Riesgo	Promedio simple post-parcial (< 10.5) sin análisis predictivo multivariable.	Modelo de Machine Learning (Random Forest) que calcula probabilidad continua.	dw.FactPrediccion	F1-Macro >= 0.65; ROC-AUC >= 0.85.
Enfoque Evaluativo	Estático y terminal; sin seguimiento de la	Evaluación Adaptativa Dinámica: re-evaluación	dw.DimEtapa + Cubo SSAS	Delta de probabilidad

Dimensión Analítica	Situación Actual (AS-IS)	Situación Propuesta (TO-BE)	Componente Tecnológico	KPI Asociado de Impacto
	evolución del riesgo.	del riesgo en dos hitos (M1 vs M2).		entre etapas (Delta P).
Intervención Tutorial	Genérica y uniforme para todos los reprobados (aviso o sanción estándar).	Personalización por Perfiles: prescripción según clúster identificado por IA.	K-Means + Matriz de Reglas	Silhouette >= 0.35; Cobertura tutorial 100%.
Herramienta de Control	Actas físicas en papel y listados planos en Excel no interactivos.	Dashboard Inteligente en Power BI Desktop con semáforo interactivo.	Power BI Desktop	100% de directores y tutores consultando en vivo.
Planificación de Gestión	Empírica e intuitiva; sin capacidad de proyectar rescates.	Simulación Interactiva What-If: análisis de capacidad, umbral y efectividad.	Parámetros What-If Power BI	Estudiantes Proyectados Retenidos (KPI-08).

Nota. Fuente: Elaboración propia basada en el diseño metodológico e institucional del proyecto.

Capítulo II: Marco Teórico y Aplicación de Ingeniería

El presente capítulo establece los fundamentos teóricos, matemáticos y metodológicos que sustentan la plataforma. Conforme a las exigencias académicas de la cátedra, cada subtema se desglosa en dos partes esenciales: (1) Fundamentación Conceptual respaldada por literatura científica indexada y obras clásicas de la disciplina, y (2) Justificación y Aplicación de Ingeniería Concreta en los artefactos del sistema.

2.0. Antecedentes de la Investigación

La aplicación de Inteligencia de Negocios y Aprendizaje Automático en educación superior cuenta con un cuerpo sólido de investigación internacional y nacional. Se sintetizan los estudios empíricos directamente vinculados al diseño de nuestra arquitectura:

Tabla 7

Síntesis de Antecedentes Empíricos y Aportes Adoptados

N°	Autores y Año	Contexto / Institución	Técnicas de IA Empleadas	Métricas Reportadas	Aporte Concreto Adoptado en este Proyecto
01	Realinho et al. (2022)	Inst. Politécnico Portalegre (4,424 alumnos, 37 vars).	Random Forest, Gradient Boosting, CatBoost, SMOTE.	Accuracy: 77.1% (3 clases) y 87.2% (binario); F1: 0.64-0.77.	Paper fundacional del dataset: justifica los 37 predictores y el target multiclase (Dropout, Enrolled, Graduate).
02	Aparicio-Montenegro et al. (2026)	UNFV (Universidad Nacional Federico Villarreal, Perú).	Random Forest, Regresión Logística, Árboles C4.5, Naive Bayes.	RF Accuracy: 86.2%; Recall: 83.5%; F1-score: 0.84.	Evidencia empírica directa UNFV: valida la superioridad de Random Forest en estudiantes villarrealinos y el foco en Recall.
03	Aco Tito et al. (2023)	Univ. Nacional de San Agustín	Random Forest, Regresión Logística,	RF Acc: 84.7%, F1: 0.83; LR	Antecedente nacional

N°	Autores y Año	Contexto / Institución	Técnicas de IA Empleadas	Métricas Reportadas	Aporte Concreto Adoptado en este Proyecto
		(UNSA, Arequipa, Perú).	SVM, Árboles CART.	Acc: 78.2%, F1: 0.76.	universitario: fundamenta la comparación técnica obligatoria de LR vs. RF en la rúbrica.
04	Almalawi et al. (2026)	Educación Superior Internacional (evaluación formativa).	Modelos lineales generalizados, clustering adaptativo.	F1: 0.79; Precisión adaptativa: 82.4%.	Pilar Evaluación Adaptativa: fundamenta la Decisión D2 (re-evaluación dinámica del riesgo por etapas M1 y M2).
05	Hidayat et al. (2026)	Análisis longitudinal de cohortes universitarias.	Random Forest, XGBoost, CatBoost, Regresión Logística.	RF ROC-AUC: 0.884; Recall Dropout: 84.1%; F1: 0.812.	Pilar Analítica Prescriptiva y What-If: sustenta el simulador interactivo variando umbrales y efectividad en Power BI.
06	Ali (2026)	Prince Sattam bin Abdulaziz University (PSAU).	Ensemble Stacking (RF + GB), SHAP values, XAI.	Accuracy: 88.6%; Recall: 86.4%; AUC: 0.912.	Pilar Alerta Temprana e IA Explicable: valida la articulación de BI con modelos de IA para comités de tutoría.
07	Navarro Peñaranda et al. (2025)	Facultad de Ingeniería de universidad pública (Colombia).	Regresión Logística binaria y árboles CART.	Accuracy: 79.3%; Odds Ratio en ciencias básicas = 3.42.	Alineación con Ingeniería: confirma que el rezago crítico en ingeniería se concentra en cursos troncales (Cálculo/Física).

N°	Autores y Año	Contexto / Institución	Técnicas de IA Empleadas	Métricas Reportadas	Aporte Concreto Adoptado en este Proyecto
08	Schmidt (2023)	Universidad estatal chilena (análisis longitudinal).	Supervivencia de Kaplan-Meier y Regresión de Cox.	73.8% de deserciones concentradas en los 2 primeros semestres.	Justificación de Hitos: sustenta por qué concentrar los dos cortes analíticos (M1 y M2) en el primer año académico.

Nota. Fuente: Elaboración propia basada en el diseño metodológico e institucional del proyecto.

2.1. Inteligencia de Negocios (Business Intelligence)

2.1.1. Fundamentación Conceptual:

La Inteligencia de Negocios (BI) se define como el conjunto integrado de metodologías, arquitecturas, procesos y tecnologías que transforman datos crudos y fragmentados en información contextualizada, significativa y directamente aplicable a la toma de decisiones estratégicas, tácticas y operativas (Chaudhuri & Dayal, 1997; Sharda et al., 2020). De acuerdo con Golfarelli y Rizzi (2009), el ciclo de vida de la Inteligencia de Negocios abarca cinco etapas fundamentales: (1) Extracción de sistemas transaccionales heterogéneos, (2) Limpieza, estandarización y calidad en área de Staging, (3) Modelado dimensional estructurado en almacenes analíticos (Data Warehouse / DataMart), (4) Procesamiento analítico multidimensional (OLAP) para consultas de agregación instantánea, y (5) Visualización y consumo ejecutivo mediante cuadros de mando interactivos que soportan la monitorización de Indicadores Clave de Rendimiento (KPIs) (Martín-Caro Álamo & Segovia-García, 2025).

2.1.2. Aplicación y Decisión de Ingeniería en el Proyecto:

En la FIEI-UNFV, la plataforma de BI supera la dispersión de registros manuales integrando la arquitectura completa en Microsoft SQL Server y Power BI:

Tabla 8

Articulación de Componentes de BI con los Artefactos del Proyecto

Componente de BI	Tecnología / Herramienta	Artefacto Específico en el Proyecto

Componente de BI	Tecnología / Herramienta	Artefacto Específico en el Proyecto
Fuentes Transaccionales	Archivos planos CSV y consultas relacionales	Extracto académico UCI (data.csv), ENAHO 2023 y catálogo nacional TUNI SUNEDU.
Pipeline ETL	Visual Studio SQL Server Integration Services (SSIS)	Solución ETL_UNFV_Retencion.sln con paquetes independientes de Staging, Dimensiones y Hechos.
Almacén Analítico	Microsoft SQL Server Database Engine	DataMart DM_RetencionAcademica_FIEI con esquemas segregados stg, dw y audit.
Procesamiento OLAP	Microsoft SQL Server Analysis Services (SSAS)	Cubo multidimensional Cubo_RiesgoAcademico.asdatabase con medidas calculadas en MDX y DAX.
Consumo y Visualización	Microsoft Power BI Desktop	Dashboard ejecutivo Dashboard_Retencion_FIEI.pbix estructurado en 4 páginas de control interactivo.

Nota. Fuente: Elaboración propia basada en el diseño metodológico e institucional del proyecto.

2.2. Data Warehouse y DataMart (Metodología Kimball)

2.2.1. Fundamentación Conceptual: Inmon vs. Kimball:

En el diseño de almacenes de datos coexisten dos paradigmas consolidados: (1) El enfoque corporativo Top-Down de Bill Inmon (Corporate Information Factory), que propone construir previamente un gran Data Warehouse corporativo normalizado en Tercera Forma Normal (3FN) para luego desprender DataMarts dependientes, demandando altos presupuestos y prolongados tiempos de desarrollo; y (2) El enfoque dimensional Bottom-Up de Ralph Kimball (Dimensional Data Warehouse), que plantea la construcción iterativa y evolutiva de DataMarts departamentales orientados a procesos de negocio específicos, conectados a través de Dimensiones Conformadas (Conformed Dimensions) mediante una Matriz Bus de Negocio (Kimball & Ross, 2013).

2.2.2. Aplicación y Decisión de Ingeniería en el Proyecto:

Se selecciona formalmente la metodología Bottom-Up de Ralph Kimball. Dado que el objetivo del proyecto es optimizar el proceso de seguimiento y retención estudiantil en la FIEI-UNFV, implementar un Data Warehouse corporativo 3FN de toda la universidad abarcaría áreas ajenas (nóminas, patrimonio, compras estatales) que dispersarían el proyecto. La construcción de

un DataMart departamental garantiza un diseño ágil, granular y optimizado para consultas analíticas de lectura masiva. Para asegurar la gobernanza, se definen tres esquemas lógicos segregados en SQL Server:

• stg (Staging Area): Área de aterrizaje volátil donde se insertan los datos crudos sin restricciones de integridad referencial para su perfilado y limpieza.
• dw (DataMart Dimensional): Área de producción analítica donde residen las dimensiones conformadas y las tablas de hechos con claves foráneas estrictas.
• audit (Auditoría): Bitácora de ejecución de paquetes SSIS que almacena timestamps, conteos de filas leídas, insertadas y rechazadas.

2.3. Modelos Dimensionales y Matriz Bus de Kimball

2.3.1. Fundamentación Conceptual:

El modelado dimensional organiza los datos en Tablas de Hechos (que contienen métricas cuantitativas numéricas de eventos de negocio) y Tablas de Dimensiones (que contienen el contexto descriptivo del evento: quién, cuándo, dónde y por qué). Los diseños estándar abarcan: Esquema Estrella (Star Schema), con una tabla de hechos central rodeada de dimensiones desnormalizadas; Esquema Copo de Nieve (Snowflake Schema), que normaliza dimensiones en subtables jerárquicas reduciendo redundancia a costa de rendimiento; y Esquema Constelación de Hechos (Fact Constellation Schema), donde coexisten múltiples tablas de hechos compartiendo dimensiones conformadas comunes.

2.3.2. Aplicación y Decisión de Ingeniería en el Proyecto:

Se implementa un esquema de Constelación de Hechos (Fact Constellation). Esta decisión es imperativa porque el proceso analítico modela dos eventos de naturaleza y periodicidad distintas: el progreso académico transaccional (créditos y notas continuas) y la inferencia predictiva de Machine Learning (probabilidades continuas y clústeres asignados). Unificarlos en una sola tabla violaría el principio de granularidad de Kimball.

Tabla 9

Matriz Bus Preliminar de Kimball (Procesos vs. Dimensiones Conformadas)

Proceso de Negocio / Tabla de Hechos	DimEstudiante	DimCurso	DimTiempo	DimEtapa	DimPerfilSocioec	DimInstitucion
1. Rendimiento Académico (dw.FactProgreso)	X	X	X	X	X	—
2. Inferencia y Alerta de IA (dw.FactPrediccion)	X	—	X	X	X	—
3. Contexto Nacional SUNEDU (dw.FactContextoNac)	—	—	X	—	X	X

Nota. Fuente: Elaboración propia basada en el diseño metodológico e institucional del proyecto.

Nota: DimEstudiante, DimTiempo, DimEtapa y DimPerfilSocioec son dimensiones conformadas, permitiendo consultas cruzadas (Drill-across) entre el desempeño real del estudiante y su probabilidad predicha de deserción.

2.4. Datos, Información y Conocimiento (Pirámide DIKW)

2.4.1. Fundamentación Conceptual:

La jerarquía DIKW formalizada por Ackoff (1989) y analizada por Rowley (2007) conceptualiza la transformación estructural del valor cognitivo: los Datos crudos carecen de contexto; la Información dota de significado relacional a los datos estructurados; el Conocimiento descubre patrones analíticos transferibles mediante modelos; y la Sabiduría aplica dicho conocimiento para orientar juicios éticos y decisiones institucionales efectivas.

2.4.2. Aplicación Concreta en el Proyecto (Variables Reales):

La transformación se evidencia a través de variables reales del sistema:

Tabla 10

Aplicación de la Jerarquía DIKW con Variables Reales del Proyecto

Nivel DIKW	Definición Teórica	Manifestación Real en el Proyecto	Componente Tecnológico
Dato	Símbolos y valores	Registros numéricos crudos en archivo	Archivo transaccional

Nivel DIKW	Definición Teórica	Manifestación Real en el Proyecto	Componente Tecnológico
	numéricos crudos desprovistos de contexto.	CSV: Curricular_units_1st_sem_approved = 0, Curricular_units_1st_sem_grade = 0.0, Debtor = 1.	data.csv / stg.Staging_Estudiante.
Información	Datos procesados, limpios y estructurados con significado de negocio.	En el DataMart, el registro indica un alumno de Ingeniería con Ratio de Eficiencia Crediticia REC = 0% y deuda económica en etapa S1.	dw.FactProgreso enlazada a dw.DimEtapa y dw.DimPerfilSocioec.
Conocimiento	Patrones inferidos, modelos causales y probabilidades predictivas.	El modelo Random Forest asigna una probabilidad P(Dropout) = 84.7% y K-Means lo clasifica en Clúster 1: Perfil Socioeconómico Crítico.	Pipeline de ML en Python (dw.FactPrediccion).
Sabiduría (Decisión)	Intervención humana y juicio institucional basado en datos.	El Comité de Tutoría y Bienestar aprueba un plan inmediato: asignación de Beca Comedor, reprogramación de matrícula y tutor de pares.	Paneles de Acción y Simulación What-If en Power BI.

Nota. Fuente: Elaboración propia basada en el diseño metodológico e institucional del proyecto.

2.5. Dimensiones, Medidas, Jerarquías y Granularidad

2.5.1. Fundamentación Conceptual:

Kimball y Ross (2013) establecen que declarar el grano de la tabla de hechos es la decisión arquitectónica fundamental. Las medidas se dividen según su aditividad: (1) Totalmente Aditivas (sumables en todas las dimensiones), (2) Semiaditivas (sumables en algunas dimensiones pero no en el tiempo), y (3) No Aditivas (porcentajes, promedios y ratios, que en DAX y MDX deben calcularse como cocientes de sumas).

2.5.2. Aplicación y Declaración Formal de Grano:

• Grano de dw.FactProgreso: 'Un registro individual por cada estudiante evaluado en una asignatura y etapa académica específica (M1 o M2) dentro de un semestre lectivo.'
• Grano de dw.FactPrediccion: 'Un registro individual por cada estudiante evaluado por un modelo analítico en un hito temporal específico (M1 Ingreso vs. M2 Cierre Semestre 1).'

Tabla 11

Catálogo de Medidas y Comportamiento de Aditividad en DAX

Tabla de Hechos	Medida Numérica	Tipo de Aditividad	Fórmula de Agregación DAX / MDX
dw.FactProgreso	creditos_matriculados	Totalmente Aditiva	SUM(dw.FactProgreso[creditos_matriculados])
dw.FactProgreso	creditos_aprobados	Totalmente Aditiva	SUM(dw.FactProgreso[creditos_aprobados])
dw.FactProgreso	Ratio de Eficiencia Crediticia (REC)	No Aditiva	DIVIDE(SUM([creditos_aprobados]), SUM([creditos_matriculados]), 0) * 100
dw.FactProgreso	Promedio Vigesimal Ponderado	No Aditiva	DIVIDE(SUM([nota_vigesimal_x_creditos]), SUM([creditos_matriculados]), 0)
dw.FactPrediccion	probabilidad_dropout	Semiaditiva	AVERAGE(dw.FactPrediccion[prob_dropout])
dw.FactPrediccion	Total Alumnos Riesgo Crítico	Totalmente Aditiva	CALCULATE(DISTINCTCOUNT([estudiante_key]), [prob_dropout] >= 0.60)

Nota. Fuente: Elaboración propia basada en el diseño metodológico e institucional del proyecto.

Jerarquías de Análisis: (1) Jerarquía Institucional: Tipo_Gestion -> Universidad -> Facultad -> Escuela Profesional. (2) Jerarquía Temporal de Evaluación: Periodo_Lectivo -> Semestre -> Etapa_Evaluacion (M1 / M2).

2.6. Cubos OLAP y Procesamiento Multidimensional (SSAS)

2.6.1. Fundamentación Conceptual:

El Procesamiento Analítico en Línea (OLAP), formalizado por Codd et al. (1993), permite consultas complejas de agregación instantánea mediante el precalculo multidimensional. Las arquitecturas estándar son: MOLAP (Multidimensional OLAP, almacenamiento y agregación en cubos de alto rendimiento), ROLAP (Relacional OLAP, resolución mediante SQL relacional) y HOLAP (Híbrido). Las 5 operaciones analíticas esenciales son: Roll-up (agregación

ascendente), Drill-down (desglose descendente), Slice (filtrado en una dimensión), Dice (corte simultáneo en dos o más dimensiones) y Pivot (rotación de ejes de análisis).

2.6.2. Aplicación y Mapeo con Preguntas de Negocio:

Se implementa un Cubo Multidimensional en Microsoft SQL Server Analysis Services (SSAS) bajo modo MOLAP, respondiendo directamente a las preguntas de negocio de la Fase B1:

Tabla 12

Mapeo de Operaciones OLAP con Preguntas de Negocio Institucionales

Operación OLAP	Pregunta de Negocio Resuelta	Dimensiones y Jerarquías Involucradas
Roll-up	PN-01: ¿Cuál es la tasa de deserción comparada entre escuelas de la FIEI?	Agregación desde DimCurso[Escuela] hacia DimInstitucion[Facultad].
Drill-down	PN-02: En Informática, ¿cuáles asignaturas concentran la mayor reprobación?	Desglose desde DimCurso[Escuela] hacia DimCurso[NombreAsignatura].
Slice	PN-06: ¿Qué porcentaje de estudiantes con beca logran promedio aprobatorio?	Corte fijo sobre DimEstudiante[Tiene_Beca = 'Sí'].
Dice	PN-03 y PN-08: ¿Cuántos estudiantes trabajadores (> 20 hrs) están en riesgo crítico en M1?	Cruce simultáneo: DimPerfilSocioec[Horas > 20] x DimEtapa[M1] x DimResultado[Riesgo Crítico].
Pivot	PN-04: Comparar la distribución de clústeres de riesgo frente a las 4 escuelas.	Eje filas: DimPerfilSocioec[Cluster_KMeans]; Eje columnas: DimCurso[Escuela].

Nota. Fuente: Elaboración propia basada en el diseño metodológico e institucional del proyecto.

2.7. Indicadores de Gestión y KPIs Institucionales

2.7.1. Fundamentación Conceptual:

Un KPI institucional es una medida cuantitativa formalmente vinculada a los objetivos estratégicos, dotada de fórmula matemática, meta cuantitativa, semaforización y responsable en la matriz RACI (Parmenter, 2015; Kaplan & Norton, 1996).

2.7.2. Fichas Técnicas de los 8 KPIs Oficiales del Sistema:

Tabla 13

Catálogo de Indicadores Clave de Rendimiento (KPIs) del Sistema

Código y Nombre de KPI	Fórmula Matemática Formal	Meta y Umbral de Semáforo	Responsable RACI
KPI-01: Tasa de Abandono Histórico (TA)	TA = (Estudiantes Dropout / Total Matriculados) * 100	<= 18.0% (Verde <= 18% | Amarillo 18.1%-25% | Rojo > 25%)	Director de Escuela Profesional
KPI-02: Ratio de Eficiencia Crediticia (REC)	REC = (Suma Creditos Aprobados / Suma Creditos Matriculados) * 100	>= 85.0% (Verde >= 85% | Amarillo 70%-84.9% | Rojo < 70%)	Comité de Tutoría y Consejería
KPI-03: Rendimiento Vigesimal Promedio (RVP)	RVP = Suma(Nota Vigesimal [0-20] * Creditos) / Total Creditos Evaluados	>= 13.5 pts (Verde >= 13.5 | Amarillo 11.0-13.4 | Rojo < 11.0)	Docentes Tutores y Directores
KPI-04: Índice de Riesgo Crítico por IA (IRC)	IRC = Conteo de estudiantes con P(Dropout) >= 0.60	<= 15.0% del total de la matrícula activa	Comité de Tutoría / Plataforma BI+IA
KPI-05: Recall en Detección de Dropout	Recall = VP_Dropout / (VP_Dropout + FN_Dropout)	>= 75.0% en M1 (Ingreso) y >= 82.0% en M2 (Cierre S1)	Equipo de Ingeniería de Datos y ML
KPI-06: Cobertura Tutorial a Críticos (CAT)	CAT = (Estudiantes Críticos con Tutor / Total Estudiantes Críticos) * 100	100.0% (Verde 100% | Amarillo 80%-99% | Rojo < 80%)	Coordinador de Tutoría FIEI
KPI-07: Cohesión de Perfiles (Silhouette)	s(i) = (b(i) - a(i)) / max(a(i), b(i)); media s_bar	s_bar >= 0.35 (Estructura de clustering sustancial)	Módulo de Personalización Python
KPI-08: Retención Simulada What-If (EPR)	EPR = Suma[P(Dropout) >= U] * Cobertura_Tutor * Efectividad_Intervención	Maximizar estudiantes retenidos bajo presupuesto	Decanato FIEI y Comité de Calidad

Nota. Fuente: Elaboración propia basada en el diseño metodológico e institucional del proyecto.

2.8. Machine Learning e Inteligencia Artificial Educativa

2.8.1. Fundamentación Conceptual:

La Minería de Datos Educativa (EDM) y la Analítica del Aprendizaje (LA) extraen patrones ocultos en la trayectoria estudiantil (Baker & Inventado, 2014; Ali, 2026). El problema

institucional no es predecir una nota continua marginal (regresión lineal), sino clasificar al estudiante en un estado de riesgo accionable (Dropout, Enrolled, Graduate), formulándose rigurosamente como Clasificación Supervisada Multiclase.

Comparación de Algoritmos (Criterio 5 de la Cátedra): (1) Regresión Logística Multinomial: Baseline lineal de referencia por su rapidez, convexidad matemática y alta interpretabilidad a través de razones de probabilidad (Hosmer et al., 2013); y (2) Random Forest Classifier: Ensamble no lineal que promedia árboles de decisión aleatorizados mediante Bagging, capturando interacciones complejas sin sobreajustar (Breiman, 2001). Para la segmentación no supervisada se utiliza K-Means Clustering.

2.8.2. Protocolo de Validación, Desbalance y Métrica Prioritaria:

• Desbalance de Clases: La deserción es una clase minoritaria; la Exactitud (Accuracy) resulta engañosa en estos contextos.
• Métrica Prioritaria de Negocio: Recall de la clase Dropout. En retención universitaria, el costo de un Falso Negativo (un alumno que desertará y no es advertido) es crítico, provocando el abandono definitivo. En contraste, el costo de un Falso Positivo (citar preventivamente a un alumno que no iba a desertar) es pedagógicamente inocuo. Por ello, la prioridad de ingeniería es maximizar el Recall de Dropout manteniendo un F1-macro equilibrado.
• Blindaje contra Fuga de Datos (Data Leakage): Ninguna variable posterior a la etapa evaluada ni el target final ingresan como predictores en M1 o M2.
• Validación Cruzada y Dashboard Completo: Se utiliza Stratified K-Fold (k=5). Las probabilidades de toda la cohorte (4,424 casos) se calculan mediante predicciones fuera de muestra (out-of-fold), asegurando que el tablero en Power BI muestre a toda la población sin violar la integridad estadística.

2.9. Evaluación Adaptativa, Analítica del Aprendizaje y Personalización

2.9.1. Fundamentación Conceptual y Delimitación Operativa:

La literatura técnica asocia la evaluación adaptativa tanto a pruebas computarizadas ítem a ítem (CAT / TRI) como a sistemas de alerta temprana basados en cohortes longitudinales (Almalawi et al., 2026; Siemens & Baker, 2012). Ante la naturaleza del curso, se formalizan las Definiciones Operativas de la Fase A0:

"Evaluación Adaptativa (Decisión D2): Proceso analítico dinámico de re-evaluación del riesgo académico ejecutado en etapas sucesivas (M1 Ingreso vs. M2 Cierre de Primer Semestre), ajustando el pronóstico conforme se consolida el rendimiento real del alumno." **(Fase A0)**

"Personalización del Aprendizaje (Decisión D3): Segmentación de la población estudiantil en perfiles multidimensionales homogéneos mediante clustering no supervisado (K-Means), articulada con una matriz institucional de recomendaciones pedagógicas y tutoriales diferenciadas por nivel de riesgo." **(Fase A0)**

2.9.2. Matriz de Personalización según Clúster Socioacadémico:

Tabla 14

Matriz de Prescripción de Intervenciones Tutoriales según Clúster

Clúster Identificado	**Rasgos Socioacadémicos Clave**	**Diagnóstico Causal**	**Prescripción Tutorial Personalizada**
Clúster 1: Vulnerabilidad Socioeconómica	Bajos ingresos familiares, padres sin educación superior, condición deudora.	Vulnerabilidad económica de sostenimiento.	Priorización en Beca Comedor, carné universitario de medio pasaje, asistencia de Bienestar y subsidio de útiles.
Clúster 2: Sobrecarga Laboral	Jornada laboral > 20 horas semanales, mayor edad promedio, menor presencialidad.	Incompatibilidad de tiempo estudio-trabajo.	Reorientación de matrícula balanceada (reducción a 16 créditos), acceso a clases grabadas y tutoría nocturna asincrónica.
Clúster 3: Rezago en Ciencias Básicas	Adecuado respaldo socioeconómico pero notas bajas en Cálculo, Álgebra y Física.	Déficit de competencias en ciencias básicas.	Asignación obligatoria a talleres de nivelación intensiva en matemáticas y emparejamiento con tutores de pares de ciclos superiores.

Nota. Fuente: Elaboración propia basada en el diseño metodológico e institucional del proyecto.

Consideraciones Éticas y Privacidad: (1) Las alertas se presentan como indicadores de necesidad de apoyo, erradicando cualquier uso discriminatorio o punitivo; y (2) Se aplica anonimización de identificadores y supresión de celdas con frecuencias menores a 5 (k >= 5) protegiendo la identidad del estudiante bajo la Ley N.° 29733.

2.10. Procesos ETL y Calidad de Datos (Visual Studio SSIS)

2.10.1. Fundamentación Conceptual:

El pipeline ETL representa la columna vertebral de la arquitectura Kimball, siendo responsable de extraer datos heterogéneos, aplicar reglas de calidad, transformar estructuras y cargar dimensiones y hechos (Kimball & Caserta, 2004). En Visual Studio SSIS se combinan tareas de Control Flow (orquestación, transacciones y ejecución de scripts Python) y tareas de Data Flow (transformaciones en memoria y carga masiva a SQL Server).

2.10.2. Catálogo de Reglas de Calidad Implementadas en SSIS:

Tabla 15

Catálogo de Reglas de Calidad y Transformación en SSIS

N° Regla	Nombre de Regla de Calidad	Problema de Origen Detectado	Tratamiento Técnico en SSIS	Artefacto Destino
RC-01	Estandarización de Codificación	Caracteres especiales (tildes/ñ) en UTF-8 vs ANSI.	Configurar CodePage = 1252 (ANSI - Latino) en Flat File Connection Manager.	Paquetes de Staging SSIS.
RC-02	Normalización Vigesimal	Notas UCI en escala portuguesa (0 a 20 con 10 aprobatorio).	Validar consistencia con escala peruana UNFV (0 a 20 con 11 aprobatorio). Campo flag es_aprobado.	dw.FactProgreso.
RC-03	Tratamiento de Calificación Cero	Notas = 0 con 0 evaluaciones rendidas sesgan promedios.	Derivación condicional: tipificar como 'No se presentó / Abandono no formal' si eval = 0.	Columna Derivada SSIS.
RC-04	Miembro Desconocido (-1)	Valores nulos o claves foráneas huérfanas en dimensiones.	Crear fila clave -1 ('No Especificado' / 'Desconocido') en cada dimensión conformada.	Dimensiones dw.
RC-05	Dimensiones de Cambio Lento	Evolución de condición laboral o beca durante el semestre.	Implementar SCD Tipo 1 (Sobrescribir) y Tipo 2 (Versionamiento con fechas de vigencia).	Componente SCD en SSIS.

N° Regla	Nombre de Regla de Calidad	Problema de Origen Detectado	Tratamiento Técnico en SSIS	Artefacto Destino
RC-06	Conciliación de Cargas	Pérdida silenciosa de registros por errores de casteo.	Control de balance en audit.Auditoria_Carga: Filas Origen = Filas Insertadas + Filas Rechazadas.	audit.Auditoria_Carga.

Nota. Fuente: Elaboración propia basada en el diseño metodológico e institucional del proyecto.

Referencias Bibliográficas

Ackoff, R. L. (1989). From data to wisdom. Journal of Applied Systems Analysis, 16(1), 3–9.

Aco Tito, A. E., Hancco Condori, B. O., & Pérez Vera, Y. (2023). Análisis comparativo de Técnicas de Machine Learning para la predicción de casos de deserción universitaria. RISTI - Revista Ibérica de Sistemas e Tecnologias de Informação, 51, 84–98. https://doi.org/10.17013/risti.51.84-98

Ali, G. M. (2026). An explainable AI framework for multimodal student performance prediction and institutional decision support at PSAU. Decision Science Letters, 15(6), 995–1012. https://doi.org/10.5267/j.dsl.2026.8.010

Almalawi, A., Soh, B., Li, A., Alanazi, A., & Samra, H. (2026). An exploratory feasibility study of adaptive assessment: a multivariate, data-driven approach to formative evaluation. Frontiers in Education, 11, Article 1849701. https://doi.org/10.3389/feduc.2026.1849701

Angulo Quiñonez, A. Á. (2022). La autoestima, su relación con el rendimiento académico y la deserción universitaria. Sapienza: International Journal of Interdisciplinary Studies, 3(6), 514–529. https://doi.org/10.51798/sijis.v3i6.514

Aparicio-Montenegro, P., Esparza Silva, M. R., Huapaya Sotero, A., Garcia-Alvarez, M. Y., & De La Cruz Garcia, A. (2026). Predictive model based on machine learning for the early identification of student dropout in a public university. Proceedings of the 24th LACCEI International Multi-Conference for Engineering, Education, and Technology, 1–10. https://doi.org/10.18687/LACCEI2026.1.1.721

Baker, R. S., & Inventado, P. S. (2014). Educational Data Mining and Learning Analytics. En J. Larusson & B. White (Eds.), Learning Analytics: From Research to Practice (pp. 61–75). Springer. https://doi.org/10.1007/978-1-4614-3305-7_4

Barrera-Liévano, J. A., Barrera-Liévano, D. C., Beltrán-Virgüez, J. E., & Castillo-Sánchez, M. (2025). Correlación entre variables de deserción universitaria en programas en modalidad a distancia en Colombia. Estudios Pedagógicos, 51(2), 161–175. https://doi.org/10.4067/S0718-07052025000200161

Breiman, L. (2001). Random Forests. Machine Learning, 45(1), 5–32. https://doi.org/10.1023/A:1010933404324

Castro-Martínez, J. A., & Machuca-Téllez, G. (2023). La deserción universitaria en América Latina: una perspectiva ecológica. Estudios Pedagógicos, 49(2), 87–108. https://doi.org/10.4067/S0718-07052023000200087

Chaudhuri, S., & Dayal, U. (1997). An overview of data warehousing and OLAP technology. ACM SIGMOD Record, 26(1), 65–74. https://doi.org/10.1145/248603.248616

Codd, E. F., Codd, S. B., & Salley, C. T. (1993). Providing OLAP to User-Analysts: An IT Mandate. E. F. Codd & Associates.

Contreras-Bravo, L. E., Nieves-Pimiento, N., & Fuentes-Contreras, J. A. (2022). Predicción del Rendimiento Académico a Nivel Universitario Mediante Mecanismos de Machine Learning y

Métodos Supervisados. Ingeniería, 27(3), Article e19514. https://doi.org/10.14483/23448393.19514

Golfarelli, M., & Rizzi, S. (2009). Data Warehouse Design: Modern Principles and Methodologies. McGraw-Hill.

González, J. A., Carvajal, C. M., Rebolledo, R. A., & González, F. A. (2024). Grado de logro de la competencia digital (GLCD) en relación a la deserción de estudiantes universitarios. Formación Universitaria, 17(3), 153–166. https://doi.org/10.4067/S0718-50062024000300153

Hidayat, N., Afuan, L., & Jannah, H. R. (2026). Prescriptive Learning Analytics for Student Dropout: Integrating Temporal Velocity and Counterfactual Explanations in Longitudinal Data. Journal of Computing Theories and Applications, 3(1), Article 15920. https://doi.org/10.62411/jcta.15920

Hosmer, D. W., Lemeshow, S., & Sturdivant, R. X. (2013). Applied Logistic Regression (3rd ed.). John Wiley & Sons.

Inmon, W. H. (2005). Building the Data Warehouse (4th ed.). John Wiley & Sons.

Instituto Nacional de Estadística e Informática - INEI. (2023). Microdatos de la Encuesta Nacional de Hogares (ENAHO): Módulos de Educación y Empleo (Módulos 300 y 500). INEI, Lima, Perú.

Kaplan, R. S., & Norton, D. P. (1996). The Balanced Scorecard: Translating Strategy into Action. Harvard Business School Press.

Kimball, R., & Caserta, J. (2004). The Data Warehouse ETL Toolkit: Practical Techniques for Extracting, Cleaning, Conforming, and Delivering Data. Wiley.

Kimball, R., & Ross, M. (2013). The Data Warehouse Toolkit: The Definitive Guide to Dimensional Modeling (3rd ed.). Wiley.

Ley Universitaria N.° 30220. (2014, 9 de julio). Diario Oficial El Peruano, Lima, Perú.

Martín-Caro Álamo, E., & Segovia-García, N. (2025). Analítica de Aprendizaje y Retención Estudiantil: un Estudio Longitudinal en Educación Superior Virtual. Revista Fuentes, 27(1), 1–12. https://doi.org/10.12795/revistafuentes.2025.27592

Navarro Peñaranda, J. A., Pérez Castro, J. D., & Rodríguez Rojas, L. A. (2025). Determinants of University Dropout: A Study in the Engineering Faculty of a Public University in Colombia. Proceedings of the 23rd LACCEI International Multi-Conference for Engineering, Education, and Technology, 1–8. https://doi.org/10.18687/LACCEI2025.1.1.2431

Ochoa Cedeño, E. G., Rodríguez Magaña, A., & García Bejar, L. (2024). Implementación y Evaluación del Programa de Mejora Académica en una Universidad Privada del Occidente de México. European Public & Social Innovation Review, 9(1), 45–65. https://doi.org/10.31637/epsir-2024-555

Parmenter, D. (2015). Key Performance Indicators: Developing, Implementing, and Using Winning KPIs (3rd ed.). John Wiley & Sons.

Parra-Sánchez, J. S., Torres Pardo, I. D., & Martínez de Merino, C. Y. (2023). Factores explicativos de la deserción universitaria abordados mediante inteligencia artificial. Revista Electrónica de

Investigación Educativa (REDIE), 25, Article e18. https://doi.org/10.24320/REDIE.2023.25.E18.4455

Realinho, V., Machado, J., Baptista, L., & Martins, M. V. (2022). Predicting Student Dropout and Academic Success. Data, 7(11), Article 146. https://doi.org/10.3390/data7110146

Romero-Tenorio, J.-M., Riccardi, D., & de Yzaguirre, F. (2026). Teatro del oprimido y sociograma. Acción colectiva contra la deserción universitaria. Revista Iberoamericana de Educación Superior, 17(49), 112–131. https://doi.org/10.22201/iisue.20072872e.2026.49.1985

Rowley, J. (2007). The wisdom hierarchy: representations of the DIKW hierarchy. Journal of Information Science, 33(2), 163–180. https://doi.org/10.1177/0165551506070706

Salazar Alberto, R. A., Guzman Aquije, E. H., & Lozada Flores, R. M. (2024). Application of artificial intelligence to predict academic performance in order to prevent dropout in high school students: Systematic Literature Review. Proceedings of the 22nd LACCEI International Multi-Conference for Engineering, Education, and Technology, 1–8. https://doi.org/10.18687/LACCEI2024.1.1.1426

Schmidt, B. J. (2023). Factores que influyen en la deserción universitaria: El caso de una universidad estatal chilena. Revista Portuguesa de Educação, 36(1), Article e23002. https://doi.org/10.21814/rpe.23401

Sharda, R., Delen, D., & Turban, E. (2020). Analytics, Data Science, & Artificial Intelligence: Systems for Decision Support (11th ed.). Pearson.

Siemens, G., & Baker, R. S. (2012). Learning analytics and educational data mining: towards a public conversation. Proceedings of the 2nd International Conference on Learning Analytics and Knowledge (LAK '12), 252–254. https://doi.org/10.1145/2330601.2330661

Superintendencia Nacional de Educación Superior Universitaria - SUNEDU. (2019). Resolución del Consejo Directivo N° 035-2019-SUNEDU/CD: Licenciamiento Institucional de la Universidad Nacional Federico Villarreal. Lima, Perú.

Superintendencia Nacional de Educación Superior Universitaria - SUNEDU. (2024). Sistema de Información Universitaria (TUNI): Catálogo Oficial de Programas y Matrículas 2024-2025. Lima, Perú.

Torres, H. V., et al. (2023). Modelo de clasificación para la deserción estudiantil en una universidad pública del Perú. Salud, Ciencia y Tecnología - Serie de Conferencias, 2(2), Article 175. https://doi.org/10.56294/sctconf2023175

Vega Velásquez, M., Bastardo Contreras, X., & Giraldo de López, M. (2025). Factores Socioemocionales y Deserción Universitaria. Análisis correlacional en grupos desertores en los años 2021 y 2022. European Public & Social Innovation Review, 10(1), 1–14. https://doi.org/10.31637/epsir-2025-1173